

# Fundamentals of Machine Learning and Analyzing Data with Python

## A Practical Approach



ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร  
และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน  
ด้วยวิธีฝึกปฏิบัติ

Olarik Surinta



# Fundamentals of Machine Learning and Analyzing Data with Python

## A Practical Approach

ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร  
และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน  
ด้วยวิธีฝึกปฏิบัติ



# Fundamentals of Machine Learning and Analyzing Data with Python

## A Practical Approach

ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร  
และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน  
ด้วยวิธีฝึกปฏิบัติ

**Olarik Surinta**

Department of Information Technology  
Faculty of Informatics, Mahasarakham University  
Maha Sarakham, Thailand



# คำนำ

เทคโนโลยีสารสนเทศสมัยใหม่ทำให้โลกเกิดการปฏิวัติทำให้มนุษย์พัฒนาเรื่องวัตกรรม ไม่ว่าจะเป็นสิ่งประดิษฐ์ที่สามารถจับต้องได้ ไปจนถึงซอฟต์แวร์ที่สามารถใช้กันอย่างแพร่หลายผ่านระบบเครือข่ายอินเทอร์เน็ต ทำให้เกิดระบบที่ทำงานผ่านโลกออนไลน์มีอัตราการเจริญเติบโตสูงขึ้นอย่างก้าวกระโดดในทุกปี อีกทั้งยังเกิดข้อมูลมหาศาลที่อยู่บนโลกออนไลน์ ดังนั้น จึงทำให้สามารถนำข้อมูลเหล่านี้มาวิเคราะห์ และประมวลผล (Data Analytics) เพื่อนำแบบจำลองไปใช้เป็นตัวช่วยในการวิเคราะห์และพัฒนาธุรกิจ ทำให้สามารถมีสารสนเทศที่จะใช้สำหรับแข่งขันกับคู่แข่งทางธุรกิจ การวิเคราะห์ข้อมูลนั้นต้องอาศัยความรู้ทางด้านต่าง ๆ มากมาย เช่น เมืองข้อมูล (Data Mining) การเรียนรู้เครื่องจักร (Machine Learning) และวิทยาการข้อมูล (Data Science) ซึ่งเป็นแนวโน้ม (Trend) ใหม่ของโลกในยุคปัจจุบัน ซึ่งความรู้เหล่านี้มีส่วนช่วยให้สามารถเลือกใช้อัลกอริธึมได้ถูกต้อง ตรงกับปัญหา และตอบโจทย์ทางธุรกิจมากที่สุด ในหนังสือเล่มนี้ได้นำเสนอเกี่ยวกับการใช้โปรแกรมภาษาไพธอน (Python) ซึ่งเป็นภาษาที่นิยมใช้งานกันในกลุ่มนักวิเคราะห์ข้อมูล (Data Analyst) ซึ่งมีไลบรารี (Library) และเครื่องมือ (Tool) ให้เลือกใช้มากมาย

# สารบัญ

|   |           |
|---|-----------|
| <b>บทที่ 1 Jupyter Notebook.....</b>  | <b>1</b>  |
| วิธีการติดตั้งโปรแกรม Jupyter Notebook.....                                     | 1         |
| วิธีการเรียกใช้โปรแกรม Jupyter Notebook.....                                    | 2         |
| ไฟล์นามสกุล (File Extension) ของโปรแกรม Jupyter.....                            | 3         |
| <b>บทที่ 2 การโหลดข้อมูล (Loading Data).....</b>                                | <b>5</b>  |
| Iris Dataset.....   | 5         |
| ลักษณะของชุดข้อมูล Iris.....  | 7         |
| MNIST Dataset.....  | 9         |
| การ Visualization เพื่อดูรูปภาพตัวเลข.....                                      | 13        |
| ช้อมูลที่นำไปใช้ใน scikit-learn.....  | 14        |
| โหลดชุดข้อมูล MNIST ด้วย Scipy.....   | 15        |
| การ Visualization ชุดข้อมูล MNIST.....  | 18        |
| <b>บทที่ 3 ข้อมูลชุดเรียนรู้และข้อมูลชุดทดสอบ (Training and Test Data).....</b> | <b>20</b> |
| การกำหนดอัตราที่ใช้สำหรับแบ่งช้อมูล.....  | 21        |
| การแสดงช้อมูลในรูปแบบของกราฟ.....   | 21        |
| <b>บทที่ 4 ไลบรารี Matplotlib (Matplotlib Library).....</b>                     | <b>25</b> |
| การบันทึกกราฟ (Figure).....   | 27        |
| การแสดงรูปภาพ (Image Show).....   | 28        |
| วิธีการแสดงรูปภาพโดยใช้อินเทอร์เฟซ (Interface) ที่ต่างกัน.....                  | 28        |
| การเพิ่มเส้นตาราง (Grid) ในการplot.....   | 30        |
| การกำหนดวิธีการplot: Line Color และ Style.....                                  | 34        |
| การกำหนด Axes Limit.....  | 37        |
| การplot Label.....  | 39        |
| การplot Legend.....   | 39        |
| การกำหนดการplot Legend.....   | 40        |
| การplotแบบ Scatter.....   | 45        |
| การตกแต่ง Scatter.....  | 49        |
| การplot Histograms, Binnings และ Density.....                                   | 52        |
| การคำนวณค่า Histogram.....  | 54        |
| การplotชุดข้อมูล MNSIT ที่อยู่ใน scikit-learn.....                              | 55        |
| การplotชุดข้อมูล MNIST ในรูปแบบ 2 มิติ โดยใช้วิธี IsoMap.....                   | 55        |
| <b>บทที่ 5 ไลบรารี Seaborn (Seaborn Library).....</b>                           | <b>57</b> |
| การแสดงชุดข้อมูล Iris แบบ Visualization.....                                    | 58        |
| การทำงานร่วมกันระหว่าง seaborn และ scikit-learn.....                            | 59        |
| <b>บทที่ 6 การวิเคราะห์การลด削除เชิงเส้น (Linear Regression).....</b>             | <b>62</b> |
| การจำลองชุดข้อมูลเพื่อใช้ในการคำนวณ Linear Regression.....                      | 63        |
| การเรียกใช้โมดูล LinearRegression.....  | 63        |
| จัดการช้อมูลเพื่อใช้ในการคำนวณ.....   | 64        |
| การเรียนรู้เพื่อสร้างโมเดล (Train the model).....                               | 64        |

|   |            |
|---|------------|
| การพยากรณ์ผลลัพธ์จากข้อมูลใหม่ (Predict Labels for Unknown Data).....                             | 65         |
| การพยากรณ์ข้อมูล Diabetes ด้วย Linear Regression.....   | 66         |
| การพยากรณ์ข้อมูล Housing ด้วย Linear Regression.....  | 71         |
| <b>บทที่ 7 ตัวจำแนกแบบไบนารี (Binary Classifier).....</b>   | <b>79</b>  |
| Stochastic Descent.....   | 81         |
| สร้างโมเดล Stochastic Descent.....  | 82         |
| การพยากรณ์ด้วยโมเดล Stochastic Descent.....   | 82         |
| การวัดประสิทธิภาพ (Performance Measurement).....  | 84         |
| การประเมินประสิทธิภาพของอัลกอริธึมด้วย Confusion Matrix.....                                      | 84         |
| การนำเสนอโมเดลไปทดสอบกับข้อมูลชุดทดสอบ.....   | 87         |
| <b>บทที่ 8 การคำนวณเพื่อนบ้านใกล้ที่สุด k ตัวแรก (K-Nearest Neighbors).....</b>                   | <b>89</b>  |
| การสร้างโมเดลของ KNN.....   | 90         |
| การพยากรณ์โดยใช้โมเดลของ KNN.....   | 91         |
| การทดสอบประสิทธิภาพของโมเดล KNN.....  | 92         |
| การแสดงผลการทดลองด้วย Confusion Matrix.....   | 92         |
| การใช้งานอัลกอริธึม KNN กับข้อมูลโรคเบาหวาน (Diabetes Dataset).....                               | 95         |
| สร้างโมเดล KNN ด้วยค่า n_neighbor ที่ได้จากการทดลอง.....  | 97         |
| คำสั่ง Pandas Crosstab.....   | 98         |
| แสดงผลลัพธ์จากการทดลองด้วย Classification Report.....   | 98         |
| การทดสอบค่าพารามิเตอร์ (Hyperparameter Tuning) ด้วยวิธี Grid Search.....                          | 99         |
| การจัดหมวดหมู่ชุดข้อมูล MNIST ด้วยอัลกอริธึม KNN.....   | 100        |
| KNN Classifier.....   | 101        |
| <b>บทที่ 9 การจัดหมวดหมุนข้อมูลด้วย Naive Bayes (Naive Bayes Classification).....</b>             | <b>105</b> |
| การเตรียมข้อมูลเพื่อใช้ในการเรียนรู้.....   | 107        |
| สร้างโมเดล Naive Bayes.....   | 108        |
| พยากรณ์ข้อมูลด้วยโมเดล Naive Bayes และแสดงประสิทธิภาพของโมเดล.....                                | 108        |
| <b>บทที่ 10 การวิเคราะห์องค์ประกอบหลัก (Principal Component Analysis).....</b>                    | <b>111</b> |
| การสร้างโมเดล PCA.....  | 111        |
| การเพิ่มข้อมูลจากตัวแปรเข้าไปเก็บเพิ่มใน DataFrame.....   | 112        |
| สร้างโมเดล Naive Bayes ด้วยคุณลักษณะพิเศษที่ได้จาก PCA.....                                       | 115        |
| การพยากรณ์คุณลักษณะพิเศษที่ได้จาก PCA ด้วยอัลกอริธึม Naive Bayes และประสิทธิภาพจากการพยากรณ์..... | 117        |
| <b>บทที่ 11 การจัดกลุ่มด้วยอัลกอริธึม K-Means (K-Means Clustering).....</b>                       | <b>119</b> |
| จำลองข้อมูลเพื่อใช้ในการอัลกอริธึม K-Means.....   | 120        |
| สร้างโมเดลของอัลกอริธึม K-Means.....  | 121        |
| การพยากรณ์ด้วยอัลกอริธึม K-Means.....   | 121        |
| สร้างข้อมูลใหม่เพื่อทดสอบการแบ่งกลุ่มด้วยอัลกอริธึม K-Means.....                                  | 123        |
| พยากรณ์ข้อมูลที่สร้างขึ้นมาใหม่ด้วยอัลกอริธึม K-Means.....  | 124        |
| <b>บทที่ 12 การรู้จำใบหน้า (Face Recognition).....</b>  | <b>127</b> |
| สร้างโมเดลของอัลกอริธึม SVM.....  | 128        |
| การวัดประสิทธิภาพของการรู้จำใบหน้า (Classification Report).....                                   | 130        |
| การแสดงความลูกค้อง (Confusion Matrix) ของการพยากรณ์รูปภาพใบหน้า.....                              | 131        |
| อัตราความถูกต้อง (Accuracy Result) ของการพยากรณ์รูปภาพใบหน้า.....                                 | 131        |

|   |            |
|---|------------|
| <b>บทที่ 13 การรู้จำตัวอักษร (Character Recognition).....</b> | <b>133</b> |
| สร้างโมเดลของอัลกอริธึม MLP.....                              | 136        |
| การวัดประสิทธิภาพของการเรียนรู้.....                          | 136        |
| การพยากรณ์และวัดประสิทธิภาพของการรู้จำ.....                   | 137        |
| การ Visualization รูปภาพตัวเลข และแสดงผลการพยากรณ์.....       | 138        |

สามารถดาวน์โหลดตัวอย่างโปรแกรม และบทเรียนนี้ในรูปแบบของ Jupyter Notebook ได้จากเว็บไซต์  [github](https://github.com/mrolarik/basic-machine-learning-using-scikit-learn)

<https://github.com/mrolarik/basic-machine-learning-using-scikit-learn>

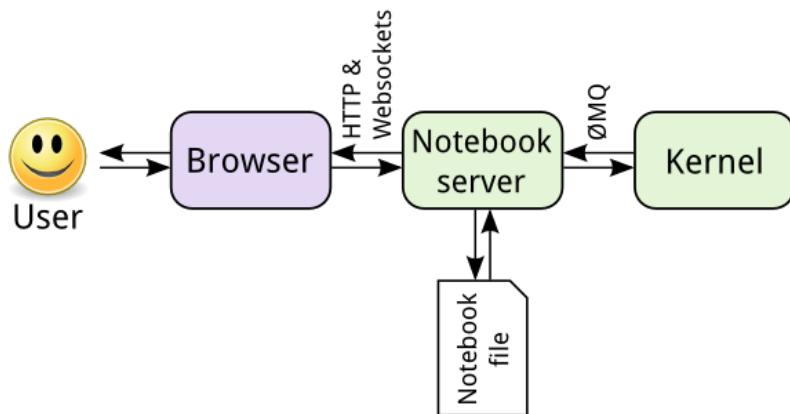
# สารบัญภาพประกอบ

|  |     |
|--|-----|
| ภาพประกอบที่ 1: สักขีดการทำงานของโปรแกรม Jupyter Notebook.....   | 1   |
| ภาพประกอบที่ 2: ตัวอย่างการเรียกใช้ jupyter notebook ผ่านหน้าจอ Terminal.....  | 2   |
| ภาพประกอบที่ 3: ตัวอย่างโปรแกรม Jupyter.....   | 3   |
| ภาพประกอบที่ 4: ตัวอย่างโครงสร้างการเก็บข้อมูลของ Jupyter โดยจัดเก็บในรูปแบบ JSON.....                                   | 3   |
| ภาพประกอบที่ 5: ชุดข้อมูลดอกไม้ Iris ประกอบด้วยดอกไม้ 3 สายพันธุ์ ได้แก่ Versicolor, Setosa และ Virginica.....           | 5   |
| ภาพประกอบที่ 6: ตัวอย่างการเก็บข้อมูลของชุดข้อมูล iris.....  | 8   |
| ภาพประกอบที่ 7: ตัวอย่างของข้อมูลชุด MNIST.....  | 10  |
| ภาพประกอบที่ 8: การ Visualization ชุดข้อมูล MNIST พร้อมทั้งแสดง label ของแต่ละตัวเลข.....                                | 19  |
| ภาพประกอบที่ 9: แสดงสมการลดด้อยเชิงเส้น Linear Regression.....   | 62  |
| ภาพประกอบที่ 10: เส้น Hyperplane ที่ได้จากการคำนวณด้วยวิธี Linear Regression.....  | 66  |
| ภาพประกอบที่ 11: แสดงการผลลัพธ์ค่า target จริง (Actual Target) และค่า target ที่ได้จากการพยากรณ์ (Predicted Target)..... | 70  |
| ภาพประกอบที่ 12: ตัวอย่างข้อมูลที่จัดเก็บในรูปแบบของ pandas DataFrame.....   | 73  |
| ภาพประกอบที่ 13: แสดงเส้น Hyperplane ที่ใช้แบ่งข้อมูลออกเป็นสองส่วน.....   | 79  |
| ภาพประกอบที่ 14: แสดงลักษณะการทำงานของอัลกอริズึม KNN.....  | 89  |
| ภาพประกอบที่ 15: กราฟแสดงประสิทธิภาพของอัลกอริซึม KNN เมื่อเปลี่ยนค่าพารามิเตอร์ n_neighbors.....                        | 97  |
| ภาพประกอบที่ 16: ตัวอย่างการจัดกลุ่มด้วยวิธี K-Means โดยแสดงให้ดูทีลังชั้นตอน.....                                       | 119 |
| ภาพประกอบที่ 17: ตัวอย่างใบหน้าจากชุดข้อมูล lfw ที่นำมาใช้ในการรู้จำใบหน้า.....  | 128 |
| ภาพประกอบที่ 18: ผลลัพธ์ที่ได้จากการพยากรณ์ใบหน้าด้วยวิธี PCA และ SVM.....   | 130 |
| ภาพประกอบที่ 19: ตัวอย่างโครงสร้างของ Multi-Layer Perceptron (MLP).....  | 133 |
| ภาพประกอบที่ 20: เปรียบเทียบระหว่างค่าที่แท้จริง และค่าที่ได้จากการพยากรณ์.....  | 139 |



# บทที่ 1 Jupyter Notebook

Jupyter หรือ Jupyter Notebook เป็นเดอร์นอล (Kernel) ของโปรแกรมภาษา Python ที่ทำให้สามารถคำนวณและติดต่อสื่อสารกับส่วนติดต่อภายนอก (Frontend) ได้สะดวก และเป็นการทำงานผ่านเว็บบราวเซอร์ (Browser)



ภาพประกอบที่ 1: ลักษณะการทำงานของโปรแกรม Jupyter Notebook

## วิธีการติดตั้งโปรแกรม Jupyter Notebook

การติดตั้งโปรแกรม Jupyter Notebook สามารถติดตั้งผ่านเทอร์มินัล (Terminal) โดยใช้คำสั่ง

```
$ pip install jupyter
```

2 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน

ตัวอย่างข้างต้นเป็นการติดตั้งสำหรับ Python เวอร์ชัน 2 แต่สำหรับ Python เวอร์ชัน 3 จะต้องใช้คำสั่ง ดังนี้

```
$ pip3 install jupyter
```

## วิธีการเรียกใช้โปรแกรม Jupyter Notebook

เมื่อติดตั้งโปรแกรม Jupyter เสร็จเรียบร้อย สามารถเรียกใช้โปรแกรม Jupyter โดยพิมพ์คำสั่งผ่าน Terminal ดังนี้

```
$ jupyter notebook
```

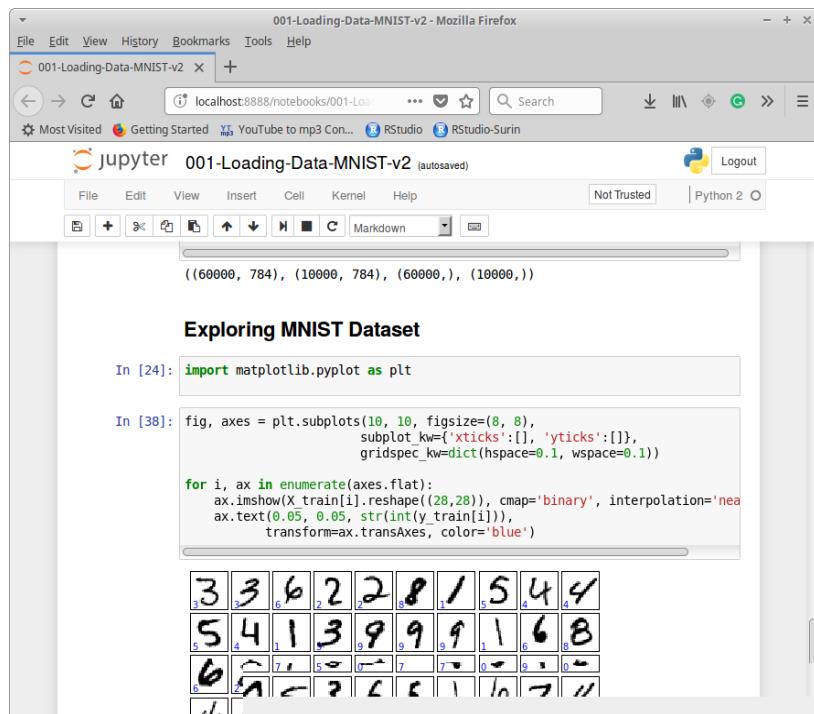
เมื่อเรียกใช้คำสั่ง \$ jupyter notebook จากนั้นโปรแกรมจะทำการจำลองเป็นเซิร์ฟเวอร์ (Server) เพื่อให้สามารถทำงานผ่านเว็บбраузอร์ โดยจะเปิดเว็บбраузอร์ ณ ตำแหน่งที่อยู่ปัจจุบัน ดังนั้น หากต้องการที่จะให้โปรแกรม Jupyter ทำงานในโฟลเดอร์ที่ต้องการ ให้เปิด Terminal และไปยังตำแหน่งที่ต้องการ จากนั้นจึงจะเรียกใช้คำสั่ง \$ jupyter notebook (ดังภาพประกอบที่ 2) เช่น

```
$ cd /home/user/work_space  
$ jupyter notebook
```

จากตัวอย่าง เมื่อเรียกใช้โปรแกรม jupyter โปรแกรมจะเปิดเว็บбраузอร์และทำงาน ณ ตำแหน่ง /home/user/work\_space โดย user เป็นโฟลเดอร์ที่เปลี่ยนไปตามชื่อผู้ใช้งาน โดย jupyter notebook จะจำลองตัวเป็นเซิร์ฟเวอร์เพื่อให้สามารถเปิดและทำงานผ่านเว็บбраузอร์ (ดังภาพประกอบที่ 3)

The screenshot shows a terminal window titled "Terminal - mrolarik@olarik: ~/work\_space". The user has navigated to their workspace directory and run the command \$ jupyter notebook. The terminal output shows the server starting up, creating a cookie secret, serving notebooks from the local directory, and listing active kernels. It then provides a URL for login: http://localhost:8888/?token=5091f7f4041df5c5306104c48036c280a82414d1a0edab2c. The terminal prompt [C 10:19:56.663 NotebookApp] is visible at the bottom.

ภาพประกอบที่ 2: ตัวอย่างการเรียกใช้ jupyter notebook ผ่านหน้าจอ Terminal



ภาพประกอบที่ 3: ตัวอย่างโปรแกรม Jupyter

## ไฟล์นามสกุล (File Extension) ของโปรแกรม Jupyter

โปรแกรม Jupyter จะมีนามสกุล (Extension) เป็น .ipynb ซึ่งจะแตกต่างจากโปรแกรมภาษา Python ที่ว่าไปที่จะใช้นามสกุล .py โดยโปรแกรม Jupyter จะเก็บข้อมูลทั้งหมดในรูปแบบของ JSON และแสดงดังภาพประกอบที่ 4

```
{
  "cells": [
    {
      "attachments": {},
      "cell_type": "markdown",
      "metadata": {},
      "source": [
        "# Jupyter\n",
        "\n",
        "Jupyter Notebook เป็น Kernel ของโปรแกรม Python ที่ทำให้สามารถคำนวณ และติดต่อสื่อสารกับ frontend interface โดยเป็นการทำงานผ่านเว็บбра�เซอร์\n",
        "\n",
        "! [alt text]\n(http://jupyter.readthedocs.io/en/latest/\_images/notebook\_components.png\n"Kernel\""
      ]
    },
  ],
  "metadata": {},
  "nbformat": 4,
  "nbformat_minor": 2
}
```

ภาพประกอบที่ 4: ตัวอย่างโครงสร้างการเก็บข้อมูลของ Jupyter โดยจัดเก็บในรูปแบบ JSON

#### **4 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทยสอน**

# บทที่ 2

## การโหลดข้อมูล (Loading Data)

ในบทนี้ นำเสนอชุดข้อมูล (Dataset) ที่ใช้กันอย่างแพร่หลายในงานด้านการเรียนรู้เครื่องจักร (Machine Learning) โดยข้อมูลดังกล่าว ประกอบด้วย Iris และ MNSIT dataset ซึ่งได้นำเสนอลักษณะของข้อมูล และวิธีการเรียกใช้ข้อมูล

### Iris Dataset

ชุดข้อมูลดอกไม้ Iris (Iris Dataset) เป็นชุดข้อมูลพื้นฐานที่ใช้อย่างแพร่หลายทั้งทางด้านการเรียนรู้เครื่องจักร และทางสถิติ (Statistics) หากติดตั้งโปรแกรม scikit-learn จะสามารถเรียกใช้ชุดข้อมูล Iris ได้ทันที ด้วยอย่างรูปภาพดอกไม้ Iris แสดงดังภาพประกอบที่ 5



ภาพประกอบที่ 5: ชุดข้อมูลดอกไม้ Iris ประกอบด้วยดอกไม้ 3 สายพันธุ์ ได้แก่ Versicolor, Setosa และ Virginica

## 6 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน

หากติดตั้งโปรแกรม scikit-learn สามารถเรียกใช้ชุดข้อมูล Iris ซึ่งเป็นชุดข้อมูลดอกไม้ ทำได้ดังต่อไปนี้

วิธีที่ 1

```
from sklearn import datasets  
iris_dataset = datasets.load_iris()
```

วิธีที่ 2

```
from sklearn.datasets import load_iris  
iris_dataset = load_iris()
```

จากตัวอย่างข้างต้นฟังก์ชัน (Function) load\_iris() เป็นฟังก์ชันที่อยู่ในโมดูล (Module) สามารถเรียกใช้ได้เมื่อติดตั้งและอิมพอร์ต (Import) scikit-learn มาใช้งาน เมื่อเรียกใช้ฟังก์ชัน load\_iris() จะคืนค่า (Return) ออกมาเป็น Bunch object ซึ่งเป็นโครงสร้างแบบ dictionary ในภาษา Python ประกอบไปด้วย keys และ values การใช้งานสามารถทำได้ดังต่อไปนี้

```
print("Keys of iris_dataset: \\\n{}".format(iris_dataset.keys()))
```

Keys of iris\_dataset:

```
['target_names', 'data', 'target', 'DESCR', 'feature_names']
```

จากตัวอย่าง DESCR คือ key ที่เก็บค่า (Value) โดยค่านั้นคือรายละเอียดของชุดข้อมูล Iris แสดงดังต่ออย่างต่อไปนี้

```
print(iris_dataset['DESCR'])
```

Iris Plants Database

=====

Notes

-----

Data Set Characteristics:

```
:Number of Instances: 150 (50 in each of three classes)  
:Number of Attributes: 4 numeric, predictive attributes and the class  
:Attribute Information:  
    - sepal length in cm  
    - sepal width in cm  
    - petal length in cm  
    - petal width in cm  
    - class:  
        - Iris-Setosa  
        - Iris-Versicolour  
        - Iris-Virginica  
:Summary Statistics:
```

```
=====
      Min   Max   Mean    SD  Class Correlation
=====
sepal length:  4.3  7.9   5.84   0.83   0.7826
sepal width:  2.0  4.4   3.05   0.43  -0.4194
petal length: 1.0  6.9   3.76   1.76   0.9490 (high!)
petal width:  0.1  2.5   1.20   0.76   0.9565 (high!)
=====
```

:Missing Attribute Values: None  
:Class Distribution: 33.3% for each of 3 classes.  
:Creator: R.A. Fisher  
:Donor: Michael Marshall (MARSHALL%PLU@io.arc.nasa.gov)  
>Date: July, 1988

## ลักษณะของชุดข้อมูล Iris

ชุดข้อมูล iris มีเอาท์พุท หรือ target อยู่ 3 กลุ่ม ประกอบด้วย versicolor, setosa และ virginica สามารถเรียกดูโดยใช้คำสั่ง

```
print("Target names: \
\n{}".format(iris_dataset['target_names']))
```

Target names:

```
['setosa' 'versicolor' 'virginica']
```

หากต้องการแสดงรายชื่อของ feature หรือ attribute ของชุดข้อมูล iris สามารถทำได้โดย

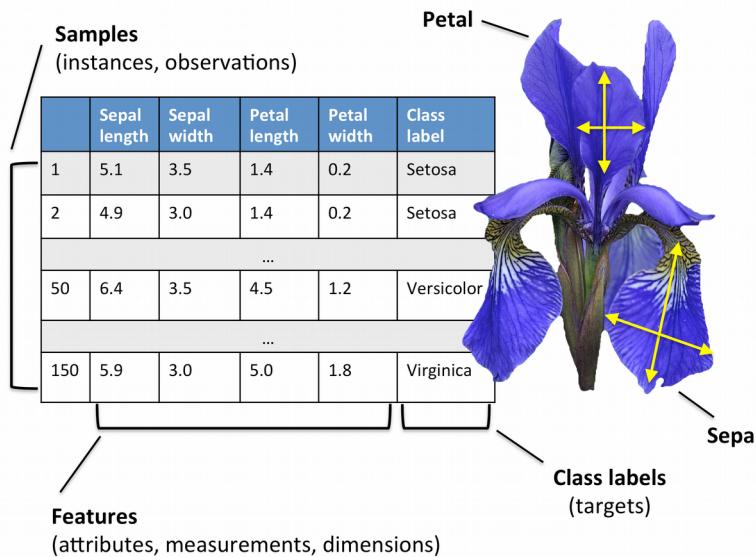
```
print("Feature names: \
\n{}".format(iris_dataset['feature_names']))
```

Feature names:

```
['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']
```

ในแต่ละ feature ที่ปรากฏในชุดข้อมูล iris คือการวัดความกว้างและความยาวของกลีบใบที่เรียกว่า Sepal และ Petal โดยมีหน่วยเป็นเซนติเมตร (cm.) ตัวอย่างของการเก็บข้อมูลแสดงดังภาพประกอบ 6

## 8 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทย



#### ภาพประกอบที่ 6: ตัวอย่างการเก็บข้อมูลของชุดข้อมูล iris

การเรียกดูข้อมูลสามารถทำได้โดยเรียกใช้ Key ที่ห่อ data โดยตัวอย่างดังต่อไปนี้ แสดงให้เห็นถึงการเรียกใช้ข้อมูลจำนวน 10 ชุด

```
print("First ten rows of data:\n \
      {}".format(iris_dataset['data'][0:10]))
```

First ten rows of data:

```

[[5.1 3.5 1.4 0.2]
[4.9 3. 1.4 0.2]
[4.7 3.2 1.3 0.2]
[4.6 3.1 1.5 0.2]
[5. 3.6 1.4 0.2]
[5.4 3.9 1.7 0.4]
[4.6 3.4 1.4 0.3]
[5. 3.4 1.5 0.2]
[4.4 2.9 1.4 0.2]
[4.9 3.1 1.5 0.1]]

```

หากต้องการเรียกดูข้อมูล class สามารถทำได้โดยเรียกใช้ key ที่มีอยู่ target ดังตัวอย่างต่อไปนี้

```
# តារាយចំណាំលក្ខណៈ ឬ class ទាំងអស់  
print("Target:\n{}".format(iris dataset['target']))
```

Target:

จากตัวอย่างข้างต้น

- 0 หมายถึง iris setosa
- 1 หมายถึง iris versicolor
- 2 หมายถึง virginica

หากต้องการเรียกดูขนาดของ target หรือจำนวนของข้อมูลสามารถทำได้โดย

```
# แสดงจำนวนของผลลัพธ์
print("shape of target: \
{}".format(iris_dataset['target'].shape))
```

shape of target: (150, )

หากต้องการเรียกดูประเภทของข้อมูลที่ใช้จัดเก็บสามารถทำได้โดย

```
# ประเภทของข้อมูลของ target
print("Type of target: \
{}".format(type(iris_dataset['target'])))
```

Type of target: <type 'numpy.ndarray'>

ประเภทของข้อมูล (Data Type) ที่ใช้จัดเก็บคือ numpy.ndarray ซึ่ง numpy เป็นไลบรารีที่ใช้จัดการข้อมูลประเภทตัวเลขมีการจัดเก็บแบบอาร์เรย์ (Array)

## MNIST Dataset

ข้อมูลชุด MNIST เป็นชุดข้อมูลลายมือตัวเลขอารบิก (ตัวเลข 0-9) โดยรูปภาพมีขนาด 28x28 พิกเซล และมีข้อมูลในชุดเรียนรู้จำนวน 60,000 รูปภาพ และข้อมูลชุดทดสอบจำนวน 10,000 รูปภาพ สำหรับ scikit-learn นั้น MNIST เป็นชุดข้อมูลตัวอย่างที่กำหนดให้รูปภาพตัวอักษรลายมือตัวเลขอารบิกในแต่ละรูปมีขนาด 8x8 พิกเซล และมีจำนวน 5,620 ชุดเท่านั้น ตัวอย่างข้อมูลชุด MNIST แสดงดังภาพประกอบที่ 7



ภาพประกอบที่ 7: ตัวอย่างของข้อมูลชุด MNSIT

การเรียกใช้ชุดข้อมูล MNIST ที่มาพร้อมกับ scikit-learn สามารถทำได้ดังต่อไปนี้

```
from sklearn import datasets  
digits = datasets.load_digits()
```

ดังนั้น หากต้องการดูรายชื่อของ key ของชุดข้อมูล MNSIT สามารถทำได้โดย

```
print("Keys of digits: \\\n{}".format(digits.keys()))
```

Keys of digits:

```
['images', 'data', 'target_names', 'DESCR', 'target']
```

หากต้องการดูรายละเอียดของชุดข้อมูล MNIST ทำได้โดย

```
print(digits['DESCR'])
```

Optical Recognition of Handwritten Digits Data Set

```
=====
```

Notes

```
-----
```

Data Set Characteristics:

```
:Number of Instances: 5620  
:Number of Attributes: 64  
:Attribute Information: 8x8 image of integer pixels in the range 0..16.  
:Missing Attribute Values: None
```

```
:Creator: E. Alpaydin (alpaydin '@' boun.edu.tr)
:Date: July; 1998
```

This is a copy of the test set of the UCI ML hand-written digits datasets  
<http://archive.ics.uci.edu/ml/datasets/Optical+Recognition+of+Handwritten+Digits>

The data set contains images of hand-written digits: 10 classes where each class refers to a digit.

หากต้องการดูขนาดของชุดข้อมูล MNIST สามารถใช้คำสั่ง shape ซึ่งเป็นเมธอด (Method) หนึ่งที่ใช้ร่วมกับไลบรารี numpy

```
print("size of the MNIST dataset", digits.images.shape)
('size of the MNIST dataset', (1797, 8, 8))
```

สามารถเรียกดูข้อมูลชื่อของ target ได้ดังนี้

```
print("target name", digits.target_names)
('target name', array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9]))
```

รูปภาพตัวเลขอารบิกที่จัดเก็บมีขนาด 8x8 พิกเซล หากต้องการตรวจสอบข้อมูลของแต่ละตัวเลขสามารถเรียกดูได้ดังนี้

```
print("Shape of each image", \
      digits.images[0].shape)
digits.images[0]
```

```
('Shape of each image', (8, 8))
array([[ 0.,  0.,  5., 13.,  9.,  1.,  0.,  0.],
       [ 0.,  0., 13., 15., 10., 15.,  5.,  0.],
       [ 0.,  3., 15.,  2.,  0., 11.,  8.,  0.],
       [ 0.,  4., 12.,  0.,  0.,  8.,  8.,  0.],
       [ 0.,  5.,  8.,  0.,  0.,  9.,  8.,  0.],
       [ 0.,  4., 11.,  0.,  1., 12.,  7.,  0.],
       [ 0.,  2., 14.,  5., 10., 12.,  0.,  0.],
       [ 0.,  0.,  6., 13., 10.,  0.,  0.,  0.]])
```

คำสั่ง digits.images[0].shape ใช้เพื่อดูขนาดของตัวเลขในตำแหน่งที่ 0 และคำสั่ง digits.images[0] เป็นการแสดงข้อมูลทั้งหมดของตัวเลขในตำแหน่งที่ 0 ดังนั้น หากต้องการดูรายละเอียดของข้อมูลมากกว่า 1 ชุด สามารถใช้คำสั่งดังต่อไปนี้

## 12 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน

```
#แสดงตัวอย่างข้อมูลจำนวน 2 ชุด ตั้งแต่ชุดที่ 0 ถึง 2
print("Sample image 0 to 2")
digits.images[0:2]
```

Sample image 0 to 2

```
array([[[ 0.,  0.,  5., 13.,  9.,  1.,  0.,  0.],
       [ 0.,  0., 13., 15., 10., 15.,  5.,  0.],
       [ 0.,  3., 15.,  2.,  0., 11.,  8.,  0.],
       [ 0.,  4., 12.,  0.,  0.,  8.,  8.,  0.],
       [ 0.,  5.,  8.,  0.,  0.,  9.,  8.,  0.],
       [ 0.,  4., 11.,  0.,  1., 12.,  7.,  0.],
       [ 0.,  2., 14.,  5., 10., 12.,  0.,  0.],
       [ 0.,  0., 13., 10.,  0.,  0.,  0.]],

      [[ 0.,  0.,  0.,  4., 15., 12.,  0.,  0.],
       [ 0.,  0.,  3., 16., 15., 14.,  0.,  0.],
       [ 0.,  0.,  8., 13.,  8., 16.,  0.,  0.],
       [ 0.,  0.,  1.,  6., 15., 11.,  0.,  0.],
       [ 0.,  1.,  8., 13., 15.,  1.,  0.,  0.],
       [ 0.,  9., 16., 16.,  5.,  0.,  0.,  0.],
       [ 0.,  3., 13., 16., 16., 11.,  5.,  0.],
       [ 0.,  0.,  0.,  3., 11., 16.,  9.,  0.]])
```

การดูข้อมูล target ทั้งหมดสามารถทำได้โดยใช้คำสั่ง

```
print("target (y / label / class) from 0 to 20")
digits.target[:20]
```

target (y / label / class) from 0 to 20

```
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```

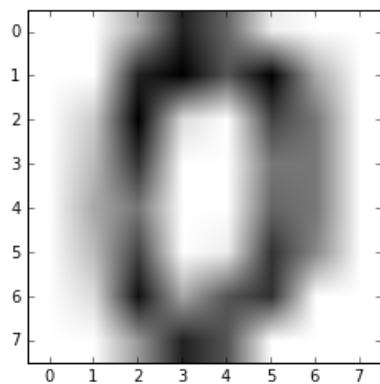
จากตัวอย่างข้างต้น คำสั่ง digits.target[:20] หมายถึงเรียกดูข้อมูลตั้งแต่ตำแหน่งที่ 0 ถึงตำแหน่งที่ 20

## การ Visualization เพื่อดูรูปภาพตัวเลข

การแสดงข้อมูล (Visualization) สามารถทำได้หลากหลายวิธี เช่น ใช้ฟังก์ชันจาก scikit-image, matplotlib และ pylab การแสดงข้อมูลสามารถทำได้ดังต่อไปนี้

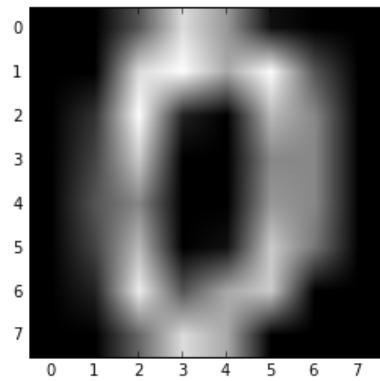
### การแสดงข้อมูลด้วย pylab

```
import pylab
pylab.imshow(digits.images[0], cmap=pylab.cm.gray_r)
pylab.show()
```

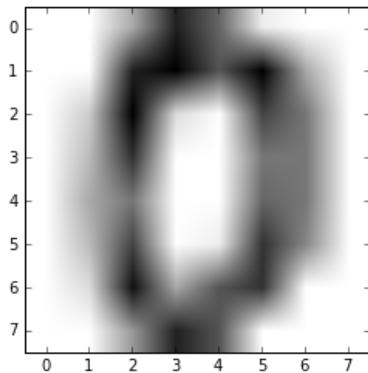


### การแสดงข้อมูลด้วย matplotlib

```
import matplotlib.pyplot as plt
plt.imshow(digits.images[0], cmap=plt.get_cmap('gray'))
plt.show()
```



```
import matplotlib.pyplot as plt  
plt.imshow(digits.images[0], cmap=plt.cm.gray_r)  
plt.show()
```



## ข้อมูลที่นำไปใช้ใน scikit-learn

ข้อมูลที่จะนำไปใช้ใน scikit-learn จะต้องแปลงให้เป็นเวกเตอร์ (Vector) ใน 1 ตัวเลขของ ชุดข้อมูล MNIST จัดเก็บแบบ array 2 มิติ จึงต้องแปลงให้อยู่ในรูปแบบของ vector ดังนั้น รูปภาพขนาด 8x8 พิกเซล เมื่อแปลงให้เป็น vector จึงเป็นเวกเตอร์ขนาด 64 การแปลงให้เป็นเวกเตอร์ในกรณีนี้ใช้คำสั่ง reshape สามารถทำได้ดังต่อไปนี้

```
data = digits.images.reshape((digits.images.shape[0], -1))  
print("size of the data", data.shape)
```

```
('size of the data', (1797, 64))
```

จากตัวอย่างข้างต้น การปรับเปลี่ยนรูปร่างข้อมูลทำได้โดยใช้คำสั่ง reshape จากนั้นสามารถ ใช้คำสั่ง data.shape เพื่อดูขนาดของข้อมูลหลังจากการปรับเปลี่ยน โดยข้อมูลใหม่จะมีขนาดเป็น (1797, 64) สามารถเรียกดูข้อมูลในแต่ละแถวดังต่อไปนี้

```
print("size of each row", data[0].shape)
```

```
data[0]
```

```
('size of each row', (64,))
```

```
array([ 0.,  0.,  5., 13.,  9.,  1.,  0.,  0.,  0.,  0., 13., 15., 10.,  
     15.,  5.,  0.,  0.,  3., 15.,  2.,  0., 11.,  8.,  0.,  0.,  4.,  
     12.,  0.,  0.,  8.,  8.,  0.,  0.,  5.,  8.,  0.,  0.,  9.,  8.,  
     0.,  0.,  4., 11.,  0.,  1., 12.,  7.,  0.,  0.,  2., 14.,  5.,  
    10., 12.,  0.,  0.,  0.,  6., 13., 10.,  0.,  0.,  0.])
```

## โหลดชุดข้อมูล MNIST ด้วย Scipy

เนื่องจากการโหลดชุดข้อมูล MNIST จาก scikit-learn สามารถใช้ได้เพียงชุดข้อมูล ตัวอย่างที่มีขนาดของรูปภาพเพียง  $8 \times 8$  พิกเซล และมีจำนวน 5,620 ชุดข้อมูลเท่านั้น ดังนั้น หากต้องการใช้ชุดข้อมูล MNIST ชุดสมบูรณ์จะต้องใช้ข้อมูลจากแหล่งอื่น สามารถดาวน์โหลด MNIST ได้จากลิงก์ต่อไปนี้

<https://github.com/AMPLab/datascience-sp14/blob/master/lab7/mldata/mnist-original.mat>

ไฟล์ที่โหลดจะมีนามสกุล .mat ซึ่งจัดเก็บอยู่ในฟอร์แมต (Format) ของโปรแกรม MATLAB ไฟล์มีขนาด 55.4 MB ซึ่งมีขนาดใหญ่พอสมควร เมื่อดาวน์โหลดไฟล์เสร็จเรียบร้อย สามารถเรียกใช้ ดังคำสั่งดังต่อไปนี้

```
from scipy.io import loadmat
mnist_raw = loadmat("mldata/mnist-original.mat")
mnist = {
    "data": mnist_raw["data"].T,
    "target": mnist_raw["label"][0],
    "COL_NAMES": ["label", "data"],
    "DESCR": "mldata.org dataset: mnist-original",
}
```

จากคำสั่ง `loadmat("mldata/mnist-original.mat")` จะต้องระบุตำแหน่งของไฟล์ให้ถูกต้อง ในตัวอย่างไฟล์ .mat จัดเก็บอยู่ที่โฟลเดอร์ mldata

สามารถดูรายละเอียดของข้อมูล MNSIT โดยพิมพ์คำสั่ง `mnist` ดังตัวอย่างต่อไปนี้

**mnist**

```
{'COL_NAMES': ['label', 'data'],
'DESCR': 'mldata.org dataset: mnist-original',
'data': array([[0, 0, 0, ..., 0, 0, 0],
   [0, 0, 0, ..., 0, 0, 0],
   [0, 0, 0, ..., 0, 0, 0],
   ...,
   [0, 0, 0, ..., 0, 0, 0],
   [0, 0, 0, ..., 0, 0, 0],
   [0, 0, 0, ..., 0, 0, 0]], dtype=uint8),
'target': array([0., 0., 0., ..., 9., 9., 9.])}
```

## 16 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน

ตัวแปร mnist จัดเก็บในรูปแบบของ dictionary โดยจะให้เก็บข้อมูลที่มีจำนวน 70,000 รูปภาพ โดยที่รูปภาพที่ 1-60,000 ใช้สำหรับการเรียนรู้ (Training Set) และรูปภาพที่ 60,001-70,000 ใช้สำหรับการทดสอบ (Test Set) แต่ละรูปภาพถูกกำหนดให้มีขนาด  $28 \times 28$  พิกเซล และแต่ละพิกเซลจะเก็บค่า 0 (white) และ 255 (black)

รายละเอียดของ key ที่อยู่ในตัวแปร mnsit แสดงดังต่อไปนี้

|               |  |
|---------------|--|
| <b>data</b>   | ใช้เก็บข้อมูลพิกเซลของรูปภาพทั้งหมด            |
| <b>target</b> | ใช้เก็บ target / class / label ของรูปภาพตัวเลข |

จากนั้นสร้างตัวแปร X,y เพื่อจัดเก็บข้อมูลจากตัวแปร mnsit เพื่อนำไปใช้งาน

```
X, y = mnist['data'], mnist['target']  
X.shape, y.shape
```

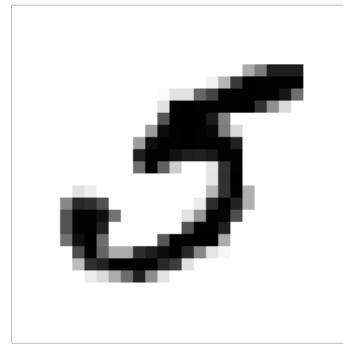
```
((70000, 784), (70000,))
```

โดยตัวแปร X ใช้สำหรับจัดเก็บข้อมูล (data) ตัวเลขทั้งหมด และตัวแปร y ใช้สำหรับเก็บข้อมูล label

จากตัวอย่างข้างต้น ตัวแปร x จะมีขนาด  $(70000, 784)$  นั่นหมายถึงมีจำนวน 70,000 ตัวเลข แต่ละตัวเลขมีขนาด 784 attribute ( $28 \times 28$ ) และตัวแปร y มีขนาด 70000 label ซึ่งต้องสัมพันธ์กับจำนวนของตัวแปร x

ตัวเลขแต่ละตัวถูกจัดเก็บเป็นแบบ vector ดังนั้น การแสดงข้อมูลจะต้องแปลงกลับให้เป็น array 2 มิติโดยใช้คำสั่ง reshape จากนั้นจึงจะสามารถแสดงข้อมูลแบบ Visualization ได้

```
import matplotlib.pyplot as plt  
some_digit = X[36000]  
some_digit_image = some_digit.reshape(28, 28)  
  
plt.imshow(  
    some_digit_image,  
    cmap = plt.cm.binary,  
    interpolation="nearest")  
  
plt.axis("off")  
plt.show()  
  
y[36000]
```



5.0

เพื่อสะดวกต่อการแสดงผล สามารถสร้างเป็นฟังก์ชันในการ Visualization ชื่อมุม  
ตั้งตัวอย่างต่อไปนี้

```
import matplotlib.pyplot as plt

def plot_digit(X, y):
    digit_image = X.reshape(28, 28)

    plt.imshow(
        digit_image,
        cmap = plt.cm.binary,
        interpolation="nearest")

    plt.axis("off")
    plt.show()

print("Label", y)
```

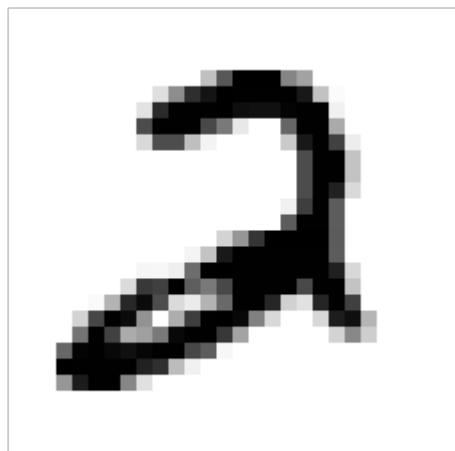
โดย

|                         |   |
|-------------------------|---|
| <b>def</b>              | คือการประกาศฟังก์ชันในภาษา Python   |
| <b>plot_digit</b>       | คือชื่อของฟังก์ชัน  |
| <b>plot_digit(X, y)</b> | คือการประกาศว่าฟังก์ชัน plot_digit กำหนดให้รับค่า<br>พารามิเตอร์จำนวน 2 ค่า คือ X และ y |

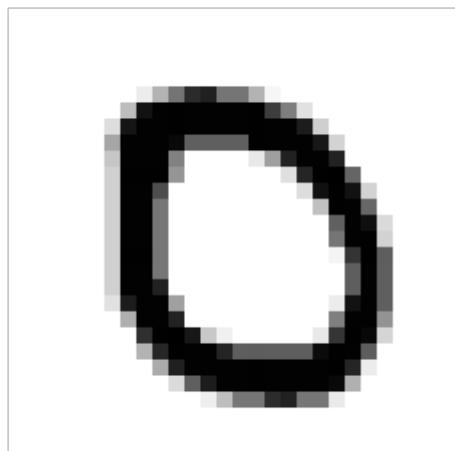
## 18 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทย

จากนั้นสามารถเรียกใช้ฟังก์ชัน `plot_digit` ดังตัวอย่างต่อไปนี้

```
plot_digit(X[15000], y[15000])
plot_digit(X[2000], y[2000])
```



('Label', 2.0)



('Label', 0.0)

## การ Visualization ข้อมูล MNIST

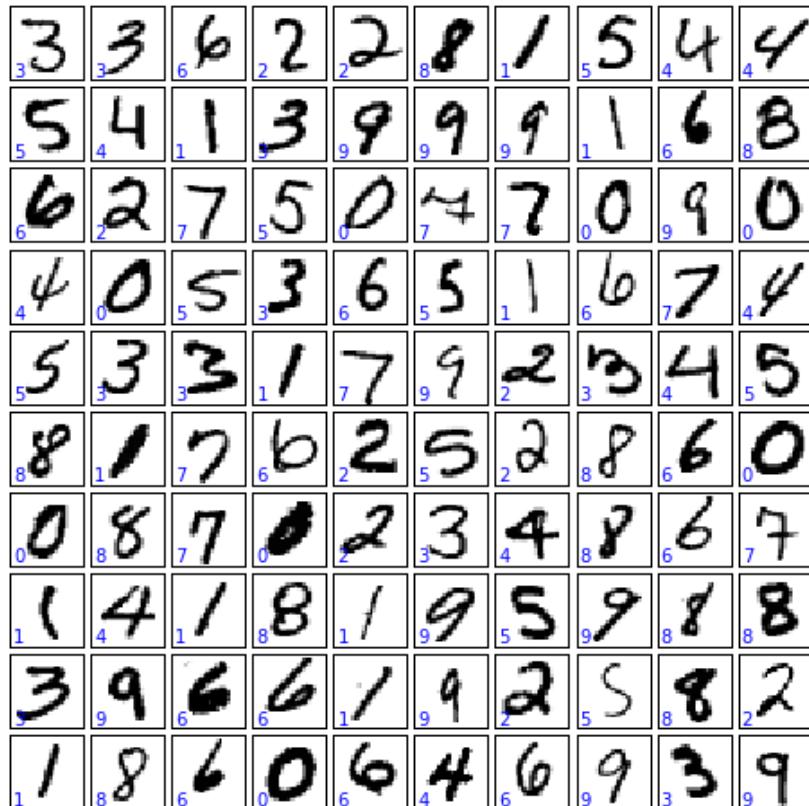
ชุดข้อมูล MNIST เป็นชุดข้อมูลตัวเลขอารบิก ที่มีจำนวน 70,000 ตัวเลข หากต้องการที่จะ Visualization เพื่อให้เห็นข้อมูลได้อย่างชัดเจน และง่ายต่อการเข้าใจสามารถทำได้โดย คำสั่งต่อไปนี้

```

import matplotlib.pyplot as plt
fig, axes = plt.subplots(10, 10, figsize=(8, 8),
                        subplot_kw={'xticks':[], 'yticks':[]},
                        gridspec_kw=dict(hspace=0.1, wspace=0.1))

for i, ax in enumerate(axes.flat):
    ax.imshow(X_train[i].reshape((28,28)), cmap='binary',
interpolation='nearest')
    ax.text(0.05, 0.05, str(int(y_train[i])),
            transform=ax.transAxes, color='blue')

```



ภาพประกอบที่ 8: การ Visualization ชุดข้อมูล MNIST พร้อมทั้งแสดง label ของแต่ละตัวเลข

จากภาพประกอบที่ 8 แสดงให้เห็นถึงการ Visualization ข้อมูลตัวเลขทั้งสิ้น 100 รูปภาพ พร้อมทั้งแสดง target/class ที่ถูกต้องของข้อมูลทั้งหมด

20 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทย

## บทที่ 3

# ข้อมูลชุดเรียนรู้และข้อมูลชุดทดสอบ (Training and Test Data)

กระบวนการเรียนรู้ของเครื่องจักรจะต้องแบ่งข้อมูลออกเป็นสองส่วน ประกอบด้วย ข้อมูลชุดเรียนรู้ (Training Set) และข้อมูลชุดทดสอบ (Test Set) ซึ่งข้อมูลชุดเรียนรู้จะถูก拿来ไปเรียนด้วยวิธีการเรียนรู้เครื่องจักรเพื่อสร้างอุปกรณ์เป็นโมเดล (Model) จากนั้นจึงทดสอบโมเดลที่สร้างด้วยข้อมูลชุดทดสอบ หากโมเดลที่สร้างมีประสิทธิภาพดีจึงนำมาใช้งานจริง บางชุดข้อมูลอาจไม่ได้แบ่งข้อมูลออกเป็นสองชุดที่ชัดเจน ดังนั้นจึงมีความจำเป็นที่จะต้องเขียนโปรแกรมเพื่อแบ่งข้อมูลออกเป็นสองส่วน

โปรแกรม scikit-learn มีเครื่องมือที่ช่วยในการแบ่ง (Split) และสลับ (Shuffle) ข้อมูลโดยใช้ฟังก์ชันดังต่อไปนี้

```
from sklearn.model_selection import train_test_split
# Loading iris dataset
from sklearn.datasets import load_iris
iris_dataset = load_iris()

# split and shuffle data
X_train, X_test, y_train, y_test = \
    train_test_split(iris_dataset['data'], \
                     iris_dataset['target'], random_state=0)
```

จากตัวอย่างข้างต้น เมื่อใช้คำสั่ง train\_test\_split โปรแกรมจะแบ่งข้อมูล และนำมาจัดเก็บลงในตัวแปร 4 ตัวประกอบด้วย X\_train, X\_test, y\_train และ y\_test โดยเป็นข้อมูลประเภท numpy.ndarray โปรแกรมจะแบ่งข้อมูลออกเป็น 75% สำหรับเรียนรู้ และเก็บอยู่ในตัวแปร X\_train และ y\_train ส่วนที่เหลืออีก 25% สำหรับทดสอบ จะถูกจัดเก็บในตัวแปร X\_test และ y\_test

สามารถเรียกดูขนาดของข้อมูลด้วยคำสั่ง shape ดังตัวอย่างต่อไปนี้

```
print("X_train shape: {}".format(X_train.shape))
print("y_train shape: {}".format(y_train.shape))
print("X_test shape: {}".format(X_test.shape))
print("y_test shape: {}".format(y_test.shape))
```

```
X_train shape: (112, 4)
y_train shape: (112, )
X_test shape: (38, 4)
y_test shape: (38, )
```

## การกำหนดอัตราที่ใช้สำหรับแบ่งข้อมูล

โปรแกรม scikit-learn อนุญาตให้ผู้ใช้แบ่งขนาดของข้อมูลชุดเรียนรู้และชุดทดสอบได้ โดยใช้ keyword คือ test\_size สามารถทำได้ดังต่อไปนี้

```
# กำหนดให้ test set มีจำนวนข้อมูล 50% จากข้อมูลทั้งหมด
X_train, X_test, y_train, y_test =
    train_test_split(iris_dataset['data'], \
        iris_dataset['target'], test_size=0.5, \
        random_state=0)
```

จากตัวอย่างกำหนดให้ test\_size = 0.5 คือการระบุขนาดของ Train set และ Test set ให้มีขนาดเป็น 50% สามารถตรวจสอบขนาดของข้อมูลได้ดังนี้

```
print("X_train shape: {}".format(X_train.shape))
print("y_train shape: {} \n".format(y_train.shape))
print("X_test shape: {}".format(X_test.shape))
print("y_test shape: {}".format(y_test.shape))
```

```
X_train shape: (75, 4)
y_train shape: (75, )
X_test shape: (75, 4)
y_test shape: (75, )
```

## การแสดงข้อมูลในรูปแบบของกราฟ

จากตัวอย่างข้างต้นได้กำหนด test\_size = 50 ทำให้แบ่งข้อมูลออกเป็น Training set และ Test set ชุดละเท่า ๆ กัน ข้อมูลทั้งสองส่วนสามารถ Visualization ให้เห็นข้อมูลเข้าใจชัด โดยแสดงในลักษณะของกราฟ โดยกราฟที่จะนำเสนอเป็นกราฟ 2 มิติ ประกอบด้วยแกน X และแกน Y ดังนั้น จึงต้องเลือกข้อมูลจากชุดข้อมูล iris ที่มีทั้งหมด 4 attribute มาแสดงเพียง 2 attribute

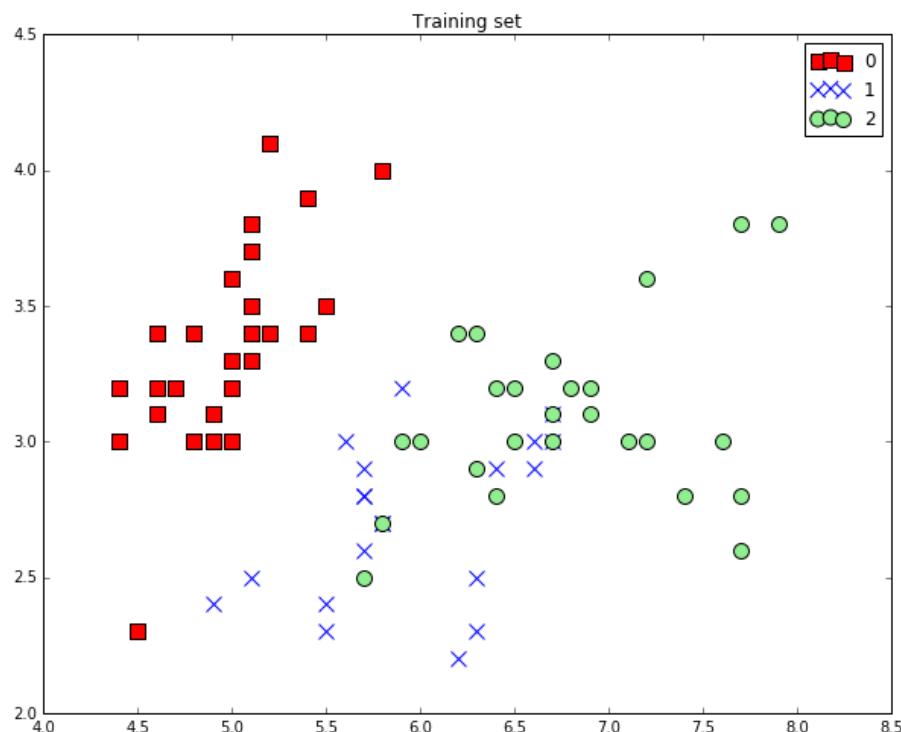
การแสดงข้อมูล Training set สามารถทำได้ดังนี้

```
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.colors import ListedColormap

markers = ('s', 'x', 'o')
colors = ('red', 'blue', 'lightgreen')
cmap = ListedColormap(colors[:len(np.unique(y_test))])
plt.figure(figsize=(10, 8))

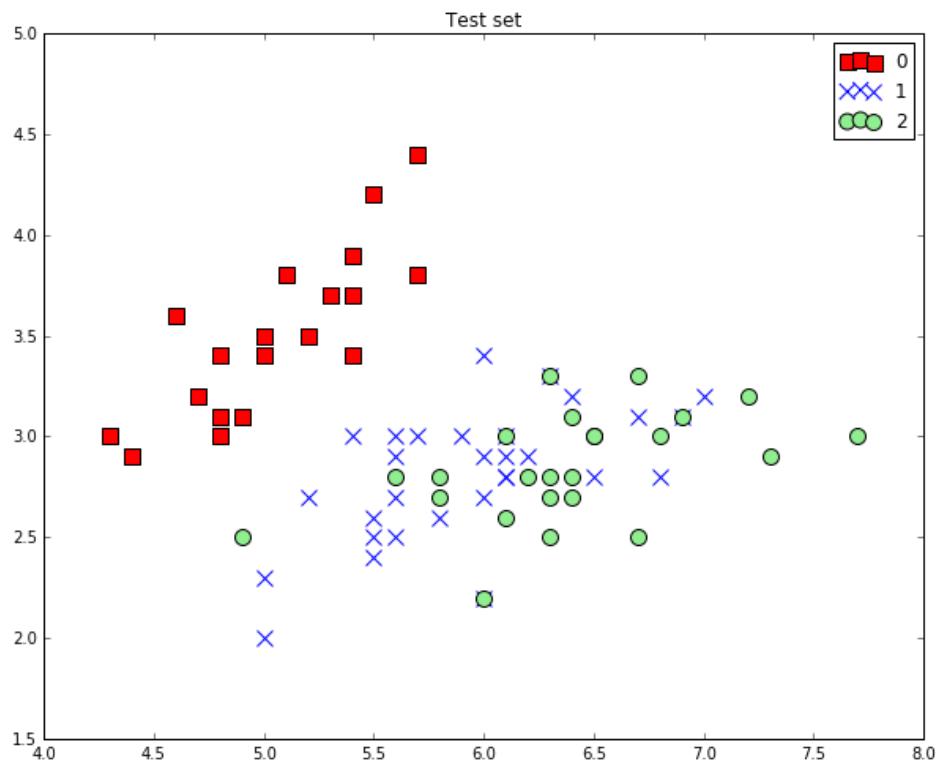
for idx, cl in enumerate(np.unique(y_train)):
    plt.scatter(x=X_train[y_train == cl, 0],
                y=X_train[y_train == cl, 1],
                c=cmap(idx), marker=markers[idx],
                label=cl, s=100)

plt.title('Training set')
plt.legend()
plt.show()
```



## 24 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทยตอน

เช่นเดียวกับข้อมูล Test set สามารถแสดงในรูปแบบของกราฟ โดยต้องเปลี่ยนตัวแปรจาก X\_train และ y\_train ให้เป็น X\_test และ y\_test ตามลำดับ การแสดงข้อมูล Test set แสดงดังที่อย่างต่อไปนี้



# บทที่ 4

## ไลบรารี Matplotlib (Matplotlib Library)

Matplotlib เป็นไลบรารีที่ใช้ในโปรแกรมภาษา Python สำหรับการ Visualize ข้อมูล (Data Visualization) หรือplot (Plot) ข้อมูลทั้งในรูปแบบ 2 มิติ และ 3 มิติ การติดตั้งไลบรารี Matplotlib ในลินุกซ์ (Linux) สามารถทำได้โดยพิมพ์คำสั่งลงไปในเทอร์มินัล ดังนี้

```
$ pip install matplotlib
```

ทั้งนี้ยังสามารถติดตั้งผ่าน Jupyter โดยพิมพ์คำสั่งดังต่อไปนี้

```
$ ! pip install matplotlib
```

หลังจากติดตั้ง Matplotlib เสร็จเรียบร้อยสามารถเรียกใช้ภายในโปรแกรมภาษา Python โดยใช้คำสั่งดังต่อไปนี้เพื่ออิมพอร์ตไลบรารี Matplotlib เข้ามาใช้งาน

```
import matplotlib.pyplot as plt
```

ตัวอย่างของการสร้างกราฟโดยใช้ Matplotlib และแสดงดังตัวอย่างต่อไปนี้

```
# -----file: my_plot.py -----
import matplotlib.pyplot as plt
import numpy as np

x = np.linspace(0, 10, 100)

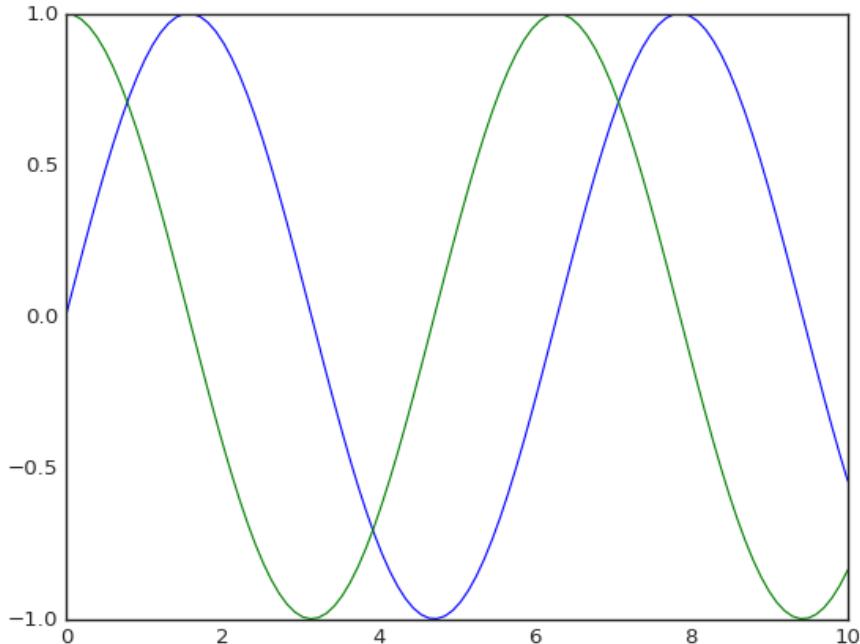
plt.plot(x, np.sin(x))
plt.plot(x, np.cos(x))

plt.show()
```

จากตัวอย่างข้างต้นเป็นสคริปต์ (Script) ภาษา Python ที่บันทึกไว้ในไฟล์ชื่อ my\_plot.py ดังนั้น หากต้องการจะเรียกใช้ไฟล์ภาษา Python เพื่อทำงาน (Run) จะต้องพิมพ์คำสั่งที่ Terminal ดังตัวอย่างต่อไปนี้

```
$ python my_plot.py
```

โปรแกรมจะแสดงกราฟออกทางจอภาพ ดังตัวอย่างต่อไปนี้



โปรแกรม Matplotlib อนุญาตให้ทำการปรับเปลี่ยนรูปแบบของกราฟได้ตามต้องการ ดังตัวอย่างต่อไปนี้

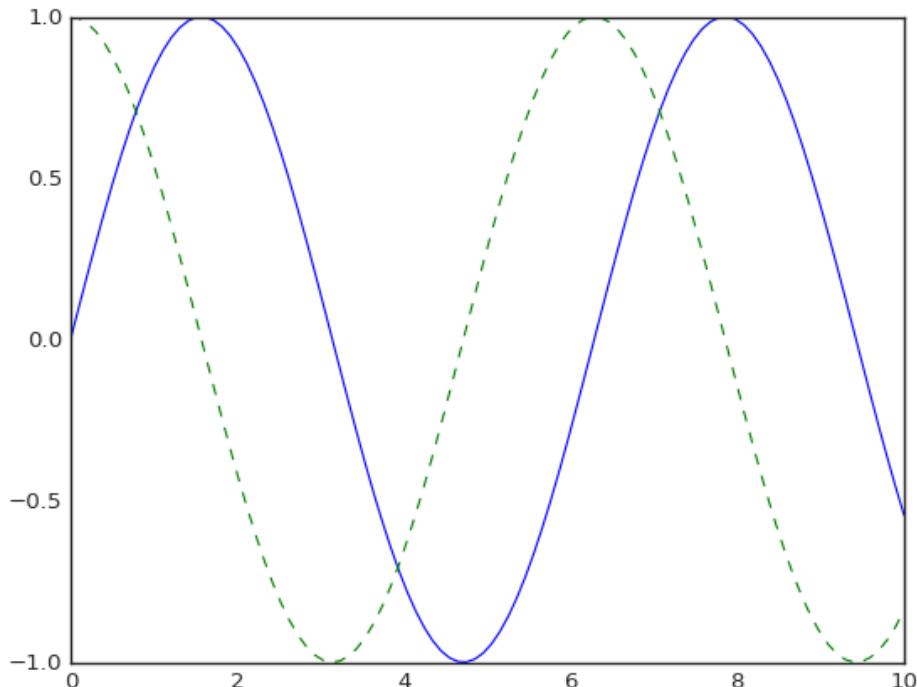
```
import matplotlib.pyplot as plt
import numpy as np

x = np.linspace(0, 10, 100)

fig = plt.figure()
plt.plot(x, np.sin(x), '-')
plt.plot(x, np.cos(x), '--')

plt.show()
```

ผลลัพธ์ที่ได้แสดงดังตัวอย่างต่อไปนี้



## การบันทึกกราฟ (Figure)

ในโปรแกรม Matplotlib สามารถบันทึกกราฟให้เป็นรูปภาพ โดยใช้คำสั่ง `savefig()` โดยการบันทึก จะบันทึกในรูปแบบของไฟล์ PNG ตัวอย่างการบันทึกแสดงดังตัวอย่างต่อไปนี้

```
fig.savefig('my_figure.png')
```

จากตัวอย่างข้างต้น เมื่อบันทึกรูปภาพเก็บลงมาในโฟลเดอร์ หากต้องการที่จะตรวจสอบรูปภาพ (ในกรณีนี้ชื่อที่ถูกกำหนดคือ `my_figure.png`) จากนั้นสามารถตรวจสอบรูปภาพ `my_figure.png` ที่บันทึกลงมา สามารถทำได้โดยใช้คำสั่ง `ls` เพื่อดูข้อมูล แต่ในการนี้ที่ต้องการดูผ่าน Jupyter Notebook จะต้องใช้เครื่องหมาย "!" เข้ามาช่วย ดังนั้น เครื่องหมาย "!" จึงเปรียบเสมือนการทำงานผ่านหน้าจอเทอร์มินัล

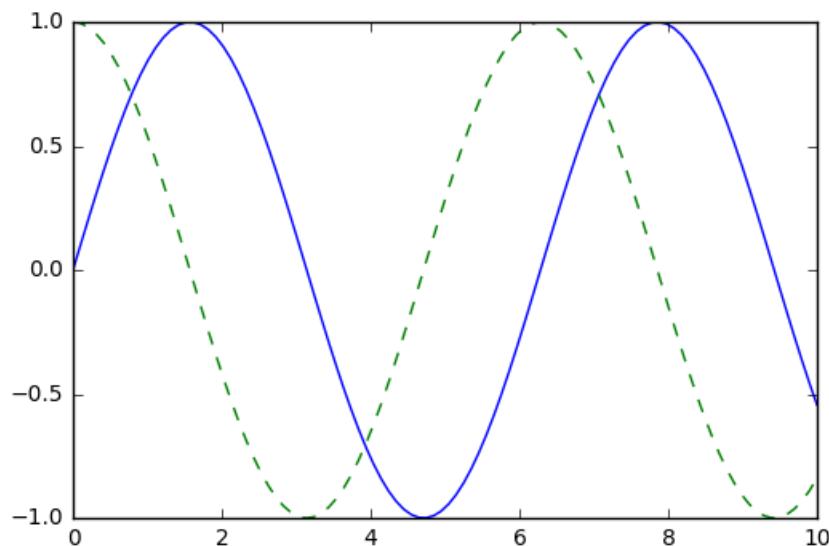
```
! ls -lh my_figure.png
```

```
-rw-rw-r-- 1 mrolarik mrolarik 26K Jul 19 00:12
my_figure.png
```

## การแสดงรูปภาพ (Image Show)

ในโปรแกรม Python สามารถเลือกใช้ไลบรารีต่างๆ เพื่อใช้สำหรับการเปิดรูปภาพจากไฟล์แสดงดังต่อไปนี้

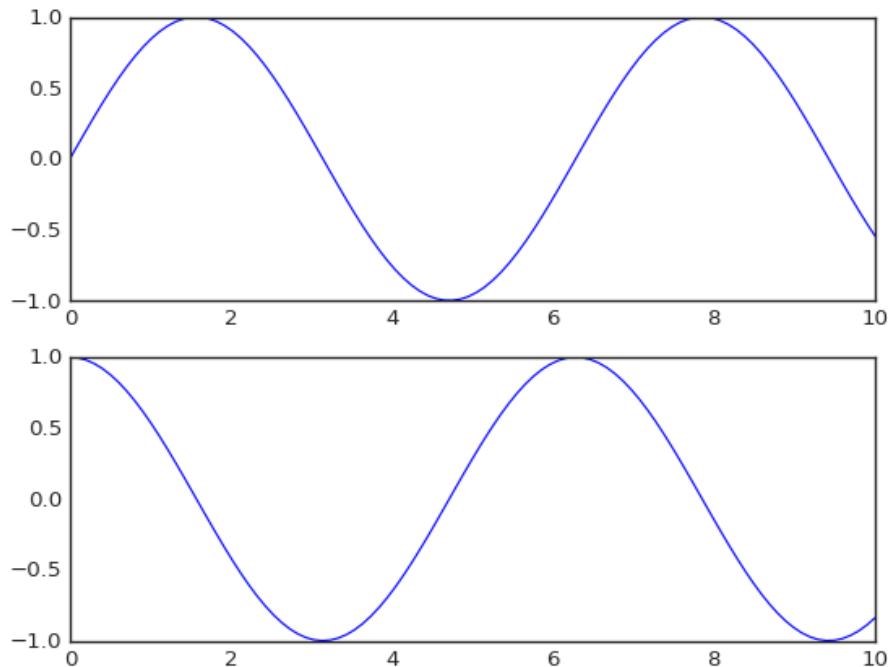
```
from IPython.display import Image  
Image('my_figure.png')
```



## วิธีการแสดงรูปภาพโดยใช้อินเทอร์เฟซ (Interface) ที่ต่างกัน

### Matlab-style Interface

```
plt.figure()      # สร้าง plot figure  
  
# สร้าง panel แรกจากทั้งหมด 2 panel และเซ็ต axis ให้กับกราฟแรก  
plt.subplot(2, 1, 1) # (rows, columns, panel number)  
plt.plot(x, np.sin(x))  
  
# สร้าง panel ที่ 2 และเซ็ต axis  
plt.subplot(2, 1, 2)  
plt.plot(x, np.cos(x))  
  
plt.show()
```

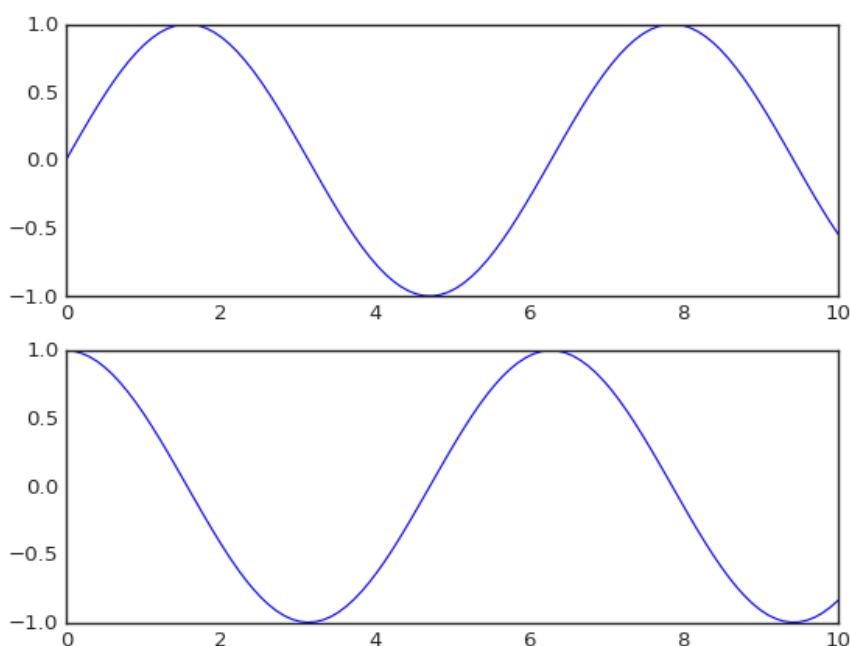


## Object-oriented Interface

```
# สร้าง grid
# ax จะเป็น array ของ Axes object
fig, ax = plt.subplots(2) # สร้าง Axes จำนวน 2 object

# เรียกใช้เมธอด (Method) plot()
ax[0].plot(x, np.sin(x))
ax[1].plot(x, np.cos(x))

plt.show()
```



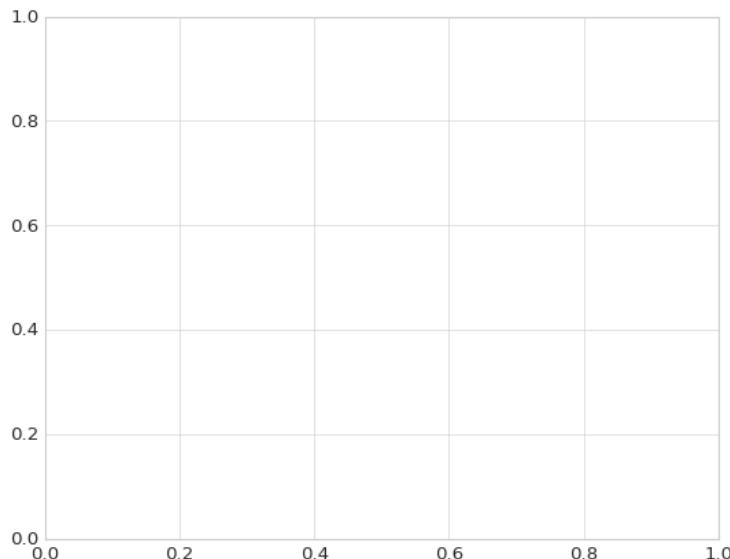
## การเพิ่มเส้นตาราง (Grid) ในการplot

การเพิ่มเส้นตาราง หรือ Grid ในการplotทำได้โดยใช้คำสั่ง plt.style.use('seaborn-whitegrid') แสดงดังต่อไปนี้

```
import numpy as np
import matplotlib.pyplot as plt

plt.style.use('seaborn-whitegrid')
fig = plt.figure()
ax = plt.axes()
```

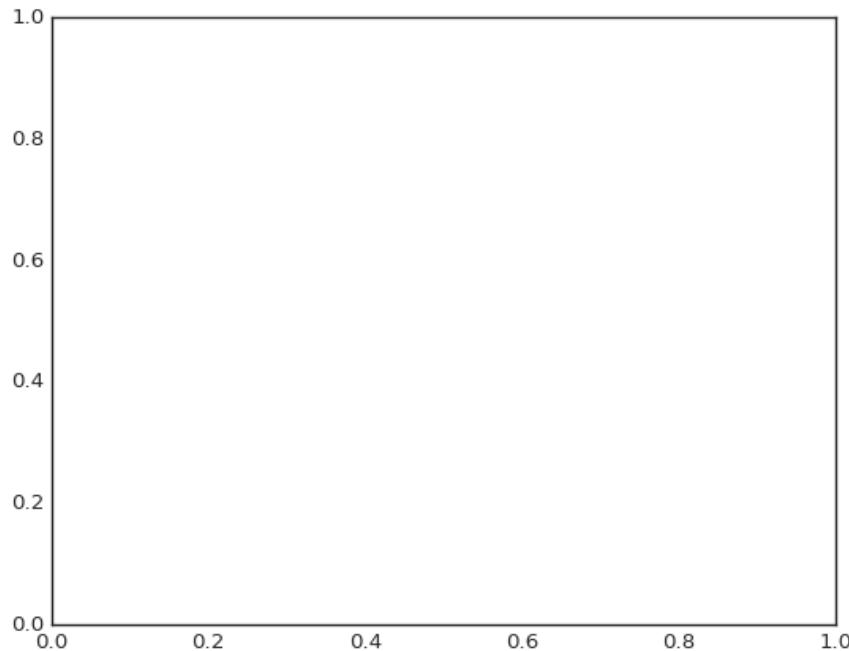
ผลลัพธ์ที่ได้คือกราฟที่แสดงจะมีเส้น Grid ทั้งในแนวตั้งและแนวนอน



หากไม่ต้องการแสดงเส้น Grid สามารถใช้คำสั่ง plt.style.use('seaborn-white') ตั้งแต่อย่างต่อไปนี้

```
plt.style.use('seaborn-white')
fig = plt.figure()
ax = plt.axes()

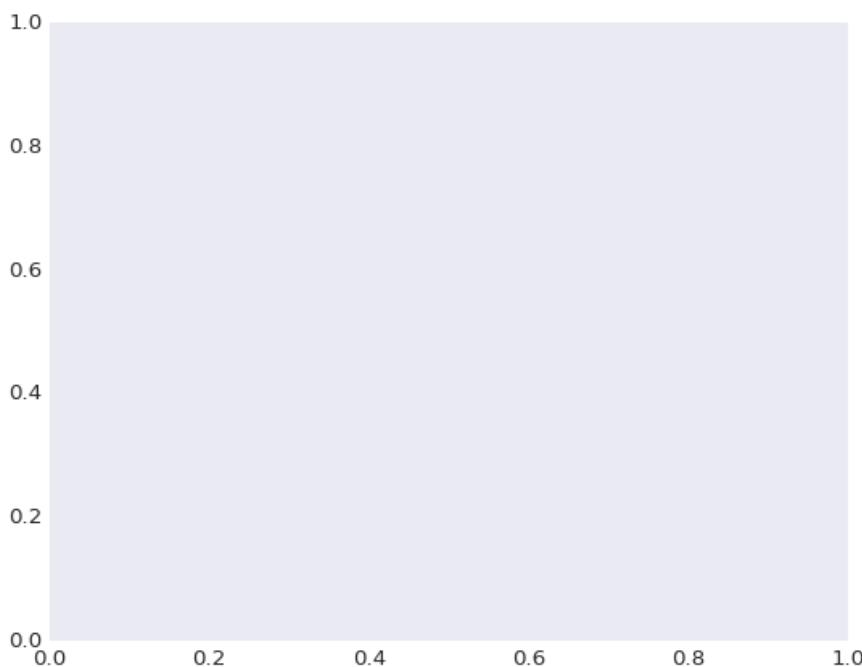
plt.show()
```



หากต้องการให้พื้นหลังมืด (Dark) สามารถใช้คำสั่ง `plt.style.use('seaborn-dark')` พื้นหลังของgrafจะเปลี่ยนจากสีขาวเป็นโทนสีฟ้า

```
plt.style.use('seaborn-dark')
fig = plt.figure()
ax = plt.axes()

plt.show()
```

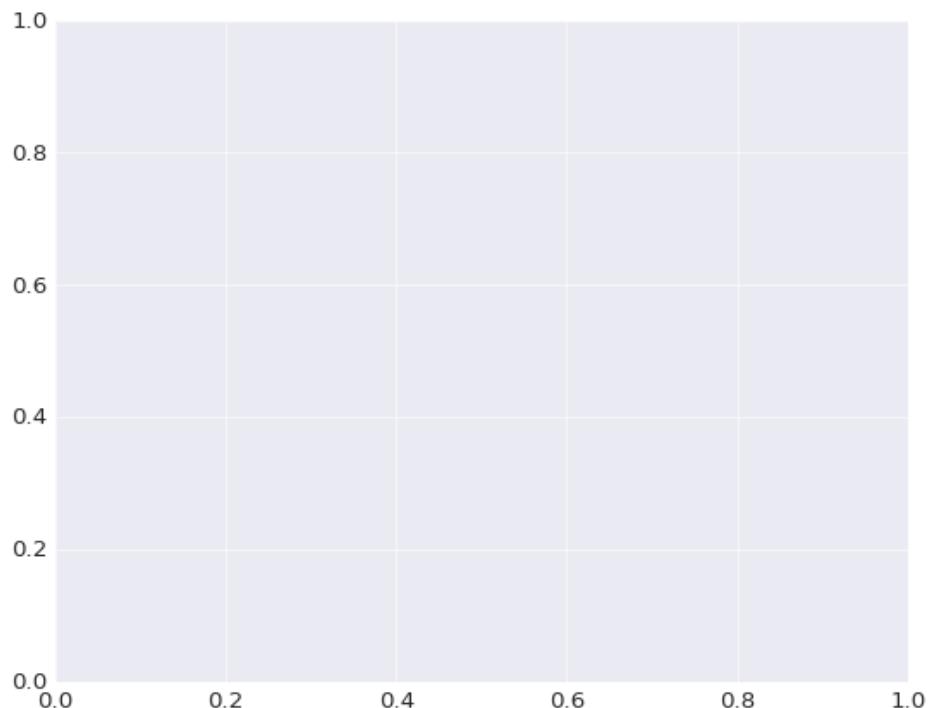


32 គាមរូពីន្ទានทางជានការរើយនូវគេថា និងការវិគរាល់ដែលបានធ្វើឡើងនៅក្នុងកម្មវិធីការការពារការណ៍។

ហាកតួនការใหំភឿនលំអី (Dark) និងមីស៊ីន Grid សាមារបានប្រើបានការការពារការណ៍។

```
plt.style.use('seaborn-darkgrid')
fig = plt.figure()
ax = plt.axes()

plt.show()
```



ตัวอย่างการพลอตกราฟเส้น

```
plt.style.use('seaborn-whitegrid')
fig = plt.figure()
ax = plt.axes()

x = np.linspace(0, 10, 1000)
ax.plot(x, np.sin(x))
plt.show()
```

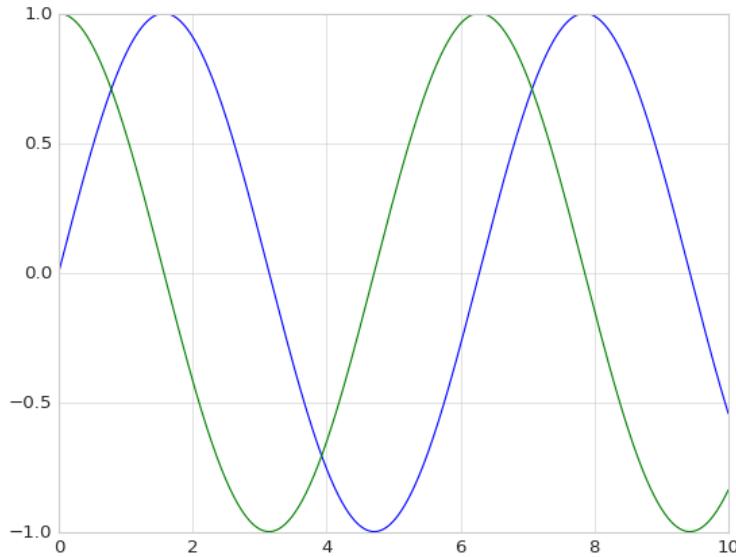


หากต้องการให้พลอตจำนวนสองเส้นใน Figure เดียวกัน สามารถทำได้โดยใช้คำสั่ง plt.plot() ได้มากกว่า 1 ครั้ง ดังต่อไปนี้

```
plt.style.use('seaborn-whitegrid')
plt.figure()
plt.axes()

x = np.linspace(0, 10, 1000)
plt.plot(x, np.sin(x))
plt.plot(x, np.cos(x))

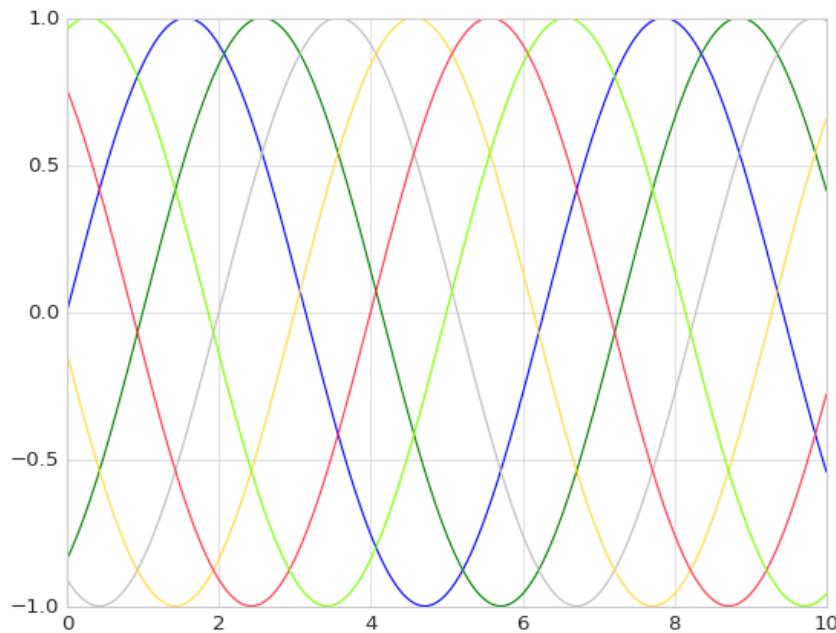
plt.show()
```



## การกำหนดวิธีการplot: Line Color และ Style

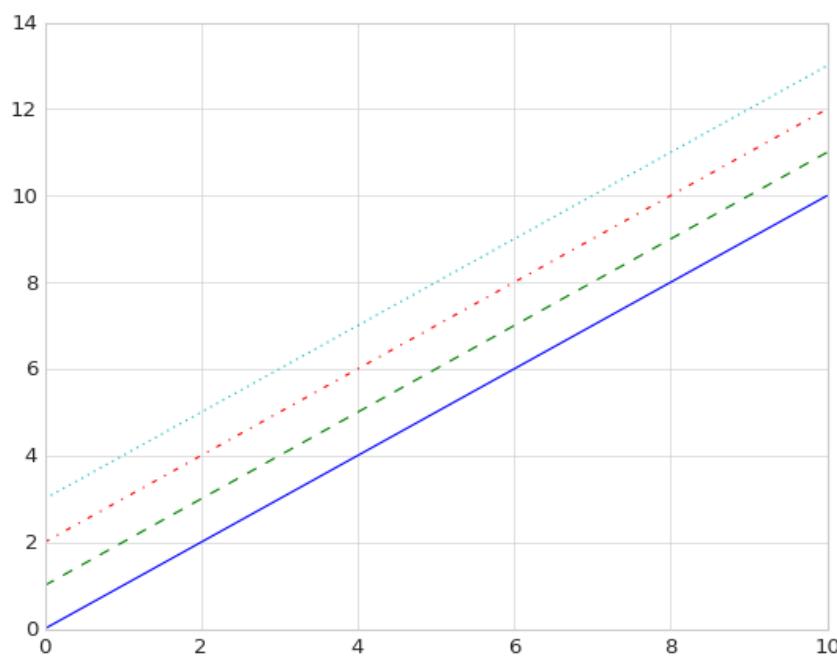
กำหนด Line Color

```
plt.style.use('seaborn-whitegrid')
plt.plot(x, np.sin(x-0), color='blue')           # กำหนดสีโดยใช้ชื่อ
plt.plot(x, np.sin(x-1), color='g')              # กำหนดสีโดยใช้ชื่อย่อ จากโหมดสี rgbcmyk
plt.plot(x, np.sin(x-2), color='0.75')            # กำหนดสีโดยใช้ค่าสีเทา ระหว่าง 0 ถึง 1
plt.plot(x, np.sin(x-3), color='#FFDD44')          # กำหนดสีโดยใช้ Hex code (RRGGBB จาก 00 ถึง FF)
plt.plot(x, np.sin(x-4), color=(1.0,0.2,0.3))      # กำหนดสีโดยใช้ค่าสี RGB tuple, ค่าจาก 0 ถึง 1
plt.plot(x, np.sin(x-5), color='chartreuse')        # กำหนดสีโดยใช้ค่าสี HTML
plt.show()
```



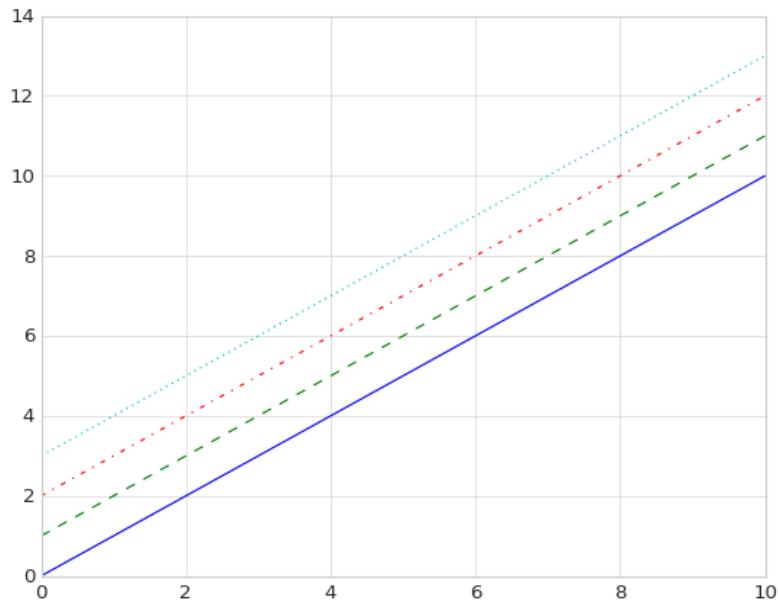
### ກຳໜາດ Line Style

```
plt.plot(x, x + 0, linestyle='solid')
plt.plot(x, x + 1, linestyle='dashed')
plt.plot(x, x + 2, linestyle='dashdot')
plt.plot(x, x + 3, linestyle='dotted')
plt.show()
```

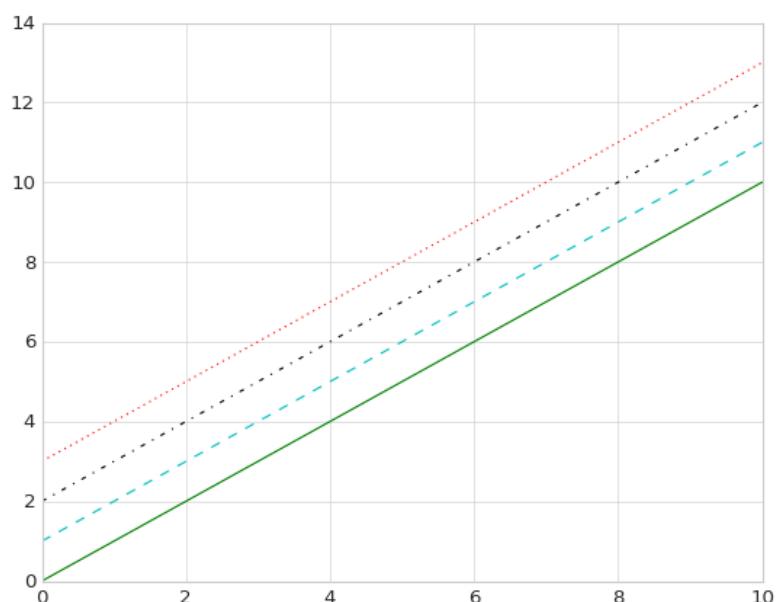


36 គាមរូពីន្ទានทางជានការរើនក្នុងកំរិះទំនួរ និងការវិគ្រាប់អំពីក្រុមការការខ្លួន

```
plt.plot(x, x + 0, linestyle='-' )          # solid
plt.plot(x, x + 1, linestyle='--' )         # dashed
plt.plot(x, x + 2, linestyle='-.-' )        # dashdot
plt.plot(x, x + 3, linestyle=':' )           # dotted
plt.show()
```



```
plt.plot(x, x + 0, '-g')      # solid green
plt.plot(x, x + 1, '--c')     # dashed cyan
plt.plot(x, x + 2, '-.k')     # dashdot black
plt.plot(x, x + 3, ':r')      # dotted red
plt.show()
```



## การกำหนด Axes Limit

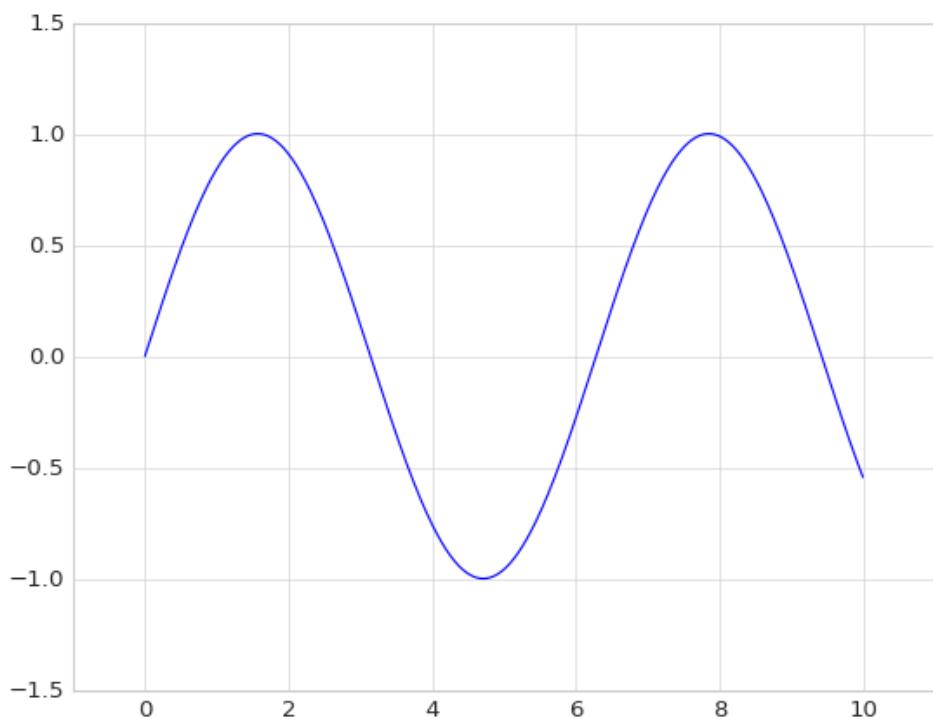
```
plt.plot(x, np.sin(x))  
plt.show()
```



จากตัวอย่างข้างต้น กราฟที่แสดงจะมีขนาดพอๆกับเส้นกราฟ หากต้องการกำหนด Axes Limit สามารถทำได้โดยใช้คำสั่ง plt.xlim(), plt.ylim() แสดงดังต่อไปนี้

```
plt.plot(x, np.sin(x))  
plt.xlim(-1,11)  
plt.ylim(-1.5, 1.5)  
plt.show()
```

38 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทยตอน

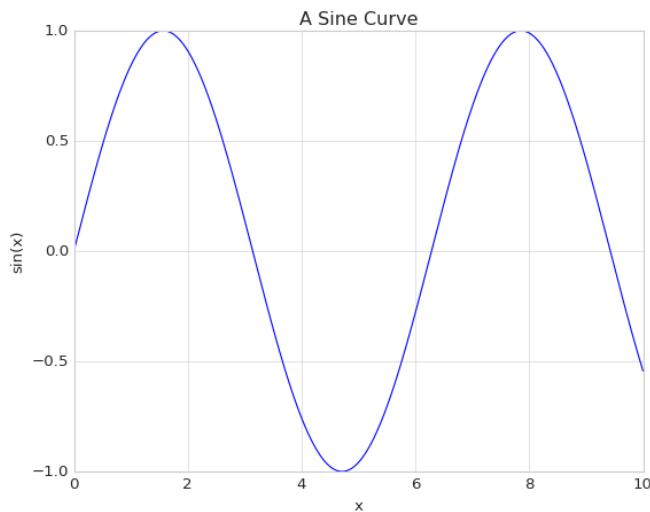


จากตัวอย่างข้างต้น Scale ของแกน X และแกน Y จะเปลี่ยนไปตามที่กำหนดไว้ใน  
plt.xlim(-1, 11) และ plt.ylim(-1.5, 1.5)

## การplot Label

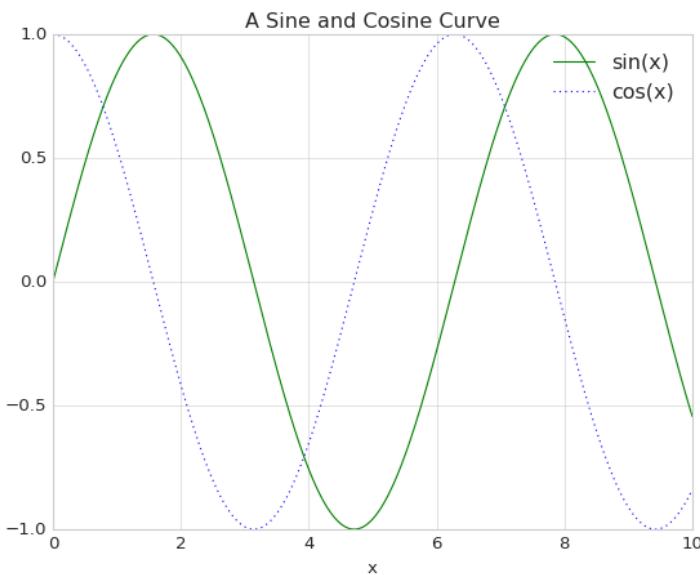
หากต้องการเพิ่ม Label ให้กับกราฟ เช่น title, x-axis, y-axis สามารถทำได้โดย

```
plt.plot(x, np.sin(x))
plt.title("A Sine Curve")
plt.xlabel("x")
plt.ylabel("sin(x)")
plt.show()
```



## การplot Legend

```
plt.plot(x, np.sin(x), '-g', label='sin(x)')
plt.plot(x, np.cos(x), ':b', label='cos(x)')
plt.title("A Sine and Cosine Curve")
plt.xlabel("x")
plt.legend()
plt.show()
```

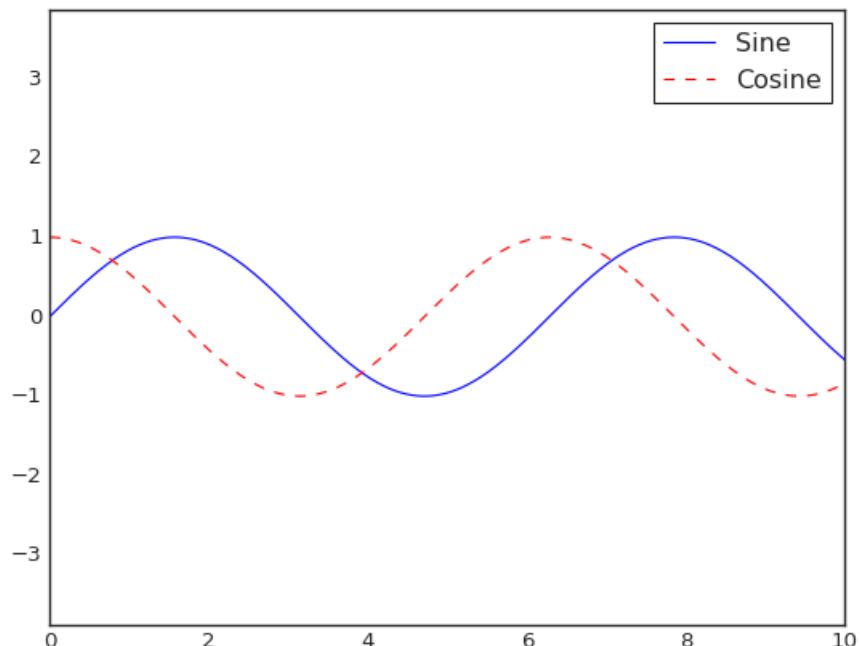


## การกำหนดการplot Legend

การเพิ่มกรอบในกับ Legeng

```
import numpy as np
import matplotlib.pyplot as plt
plt.style.use('seaborn-white')

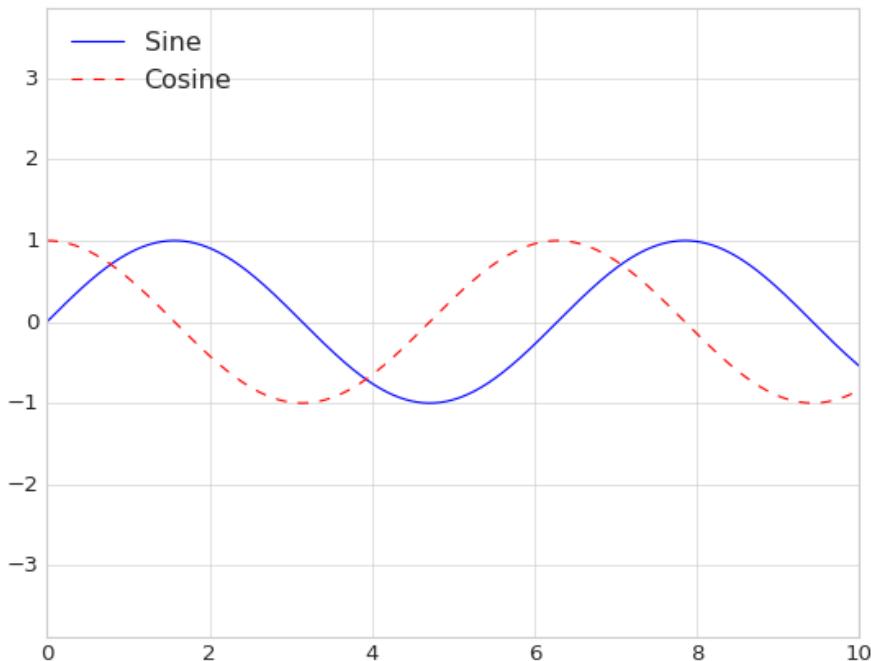
x = np.linspace(0, 10, 1000)
fig, ax = plt.subplots()
ax.plot(x, np.sin(x), '-b', label='Sine')
ax.plot(x, np.cos(x), '--r', label='Cosine')
ax.axis('equal')
leg = ax.legend(frameon=True)
```



การเปลี่ยนตำแหน่ง Legend ให้อยู่มุมบนซ้าย

```
import numpy as np
import matplotlib.pyplot as plt
plt.style.use('seaborn-whitegrid')

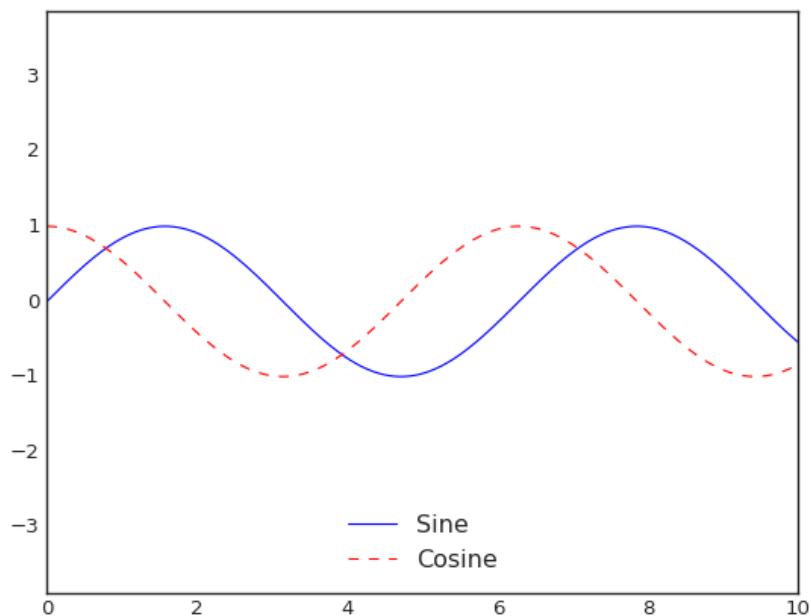
x = np.linspace(0, 10, 1000)
fig, ax = plt.subplots()
ax.plot(x, np.sin(x), '-b', label='Sine')
ax.plot(x, np.cos(x), '--r', label='Cosine')
ax.axis('equal')
ax.legend(loc='upper left', frameon=False)
plt.show()
```



### การเปลี่ยนตำแหน่ง Legend ให้อยู่ด้านล่างตรงกลาง

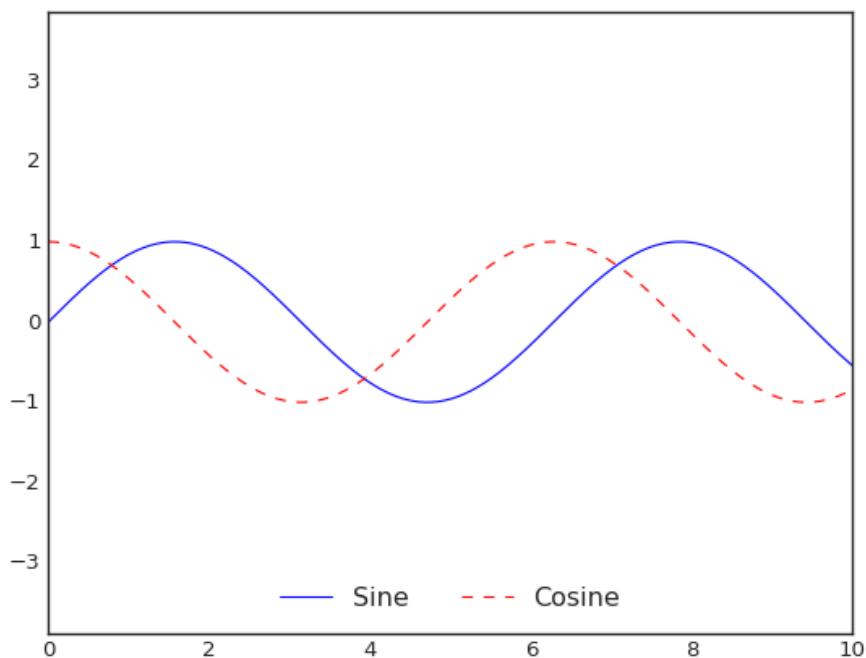
```
import numpy as np
import matplotlib.pyplot as plt
plt.style.use('seaborn-white')

x = np.linspace(0, 10, 1000)
fig, ax = plt.subplots()
ax.plot(x, np.sin(x), '-b', label='Sine')
ax.plot(x, np.cos(x), '--r', label='Cosine')
ax.axis('equal')
ax.legend(loc='lower center', frameon=False)
plt.show()
```



```
import numpy as np
import matplotlib.pyplot as plt
plt.style.use('seaborn-white')

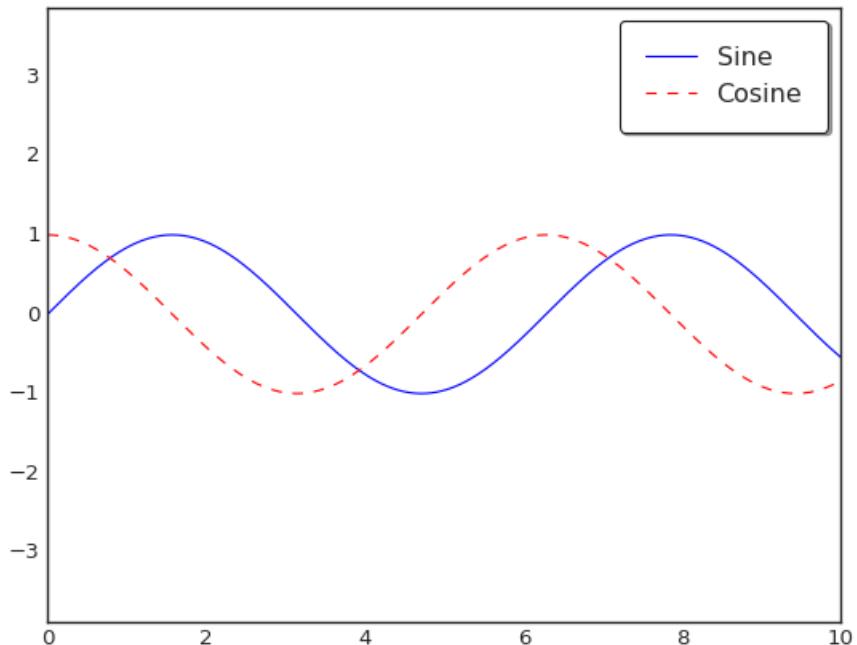
x = np.linspace(0, 10, 1000)
fig, ax = plt.subplots()
ax.plot(x, np.sin(x), '-b', label='Sine')
ax.plot(x, np.cos(x), '--r', label='Cosine')
ax.axis('equal')
ax.legend(loc='lower center', ncol=2, frameon=False)
plt.show()
```



### การตกแต่ง Legend

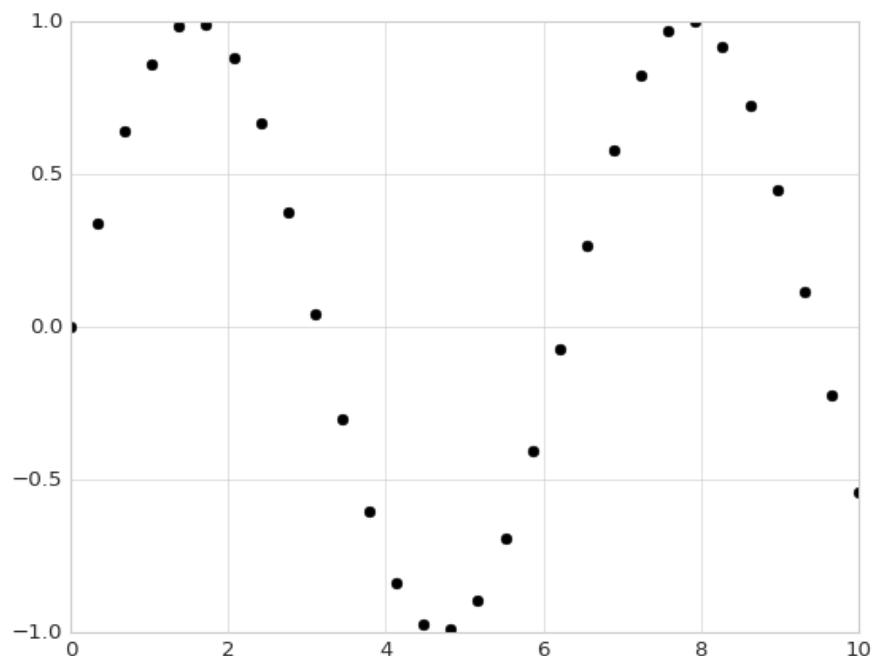
```
import numpy as np
import matplotlib.pyplot as plt
plt.style.use('seaborn-white')

x = np.linspace(0, 10, 1000)
fig, ax = plt.subplots()
ax.plot(x, np.sin(x), '-b', label='Sine')
ax.plot(x, np.cos(x), '--r', label='Cosine')
ax.axis('equal')
leg = ax.legend(frameon=True, fancybox=True, framealpha=1,
                 shadow=True, borderpad=1)
plt.show()
```



## การplotแบบ Scatter

```
import numpy as np  
  
x = np.linspace(0, 10, 30)  
y = np.sin(x)  
  
plt.plot(x, y, 'o', color='black')  
plt.show()
```

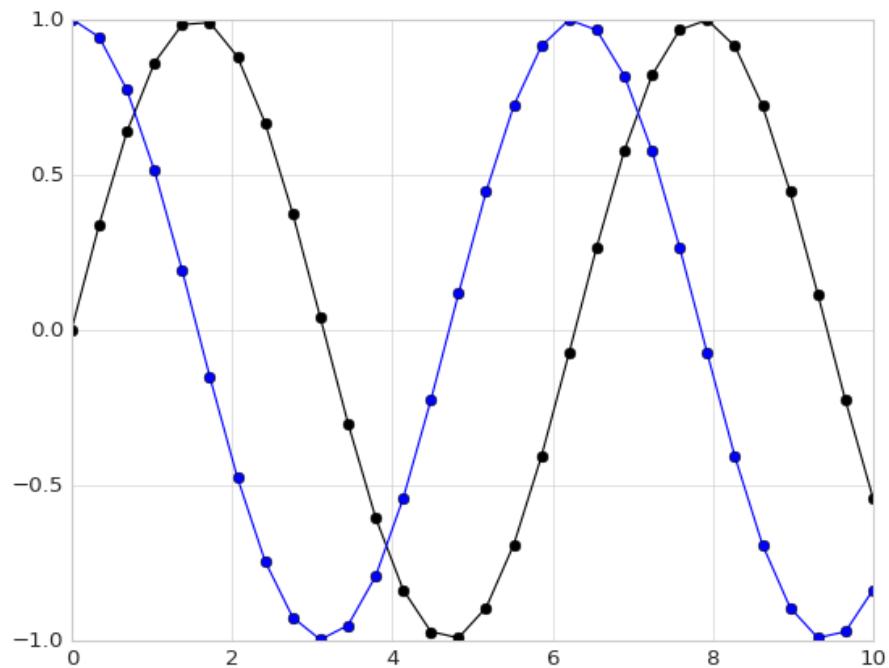


46 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทยตอน

```
import numpy as np

x = np.linspace(0, 10, 30)
y = np.sin(x)
z = np.cos(x)

plt.plot(x, y, '-ok') # line (-), circle marker (o), black (k)
plt.plot(x, z, '-o', color='blue')
plt.show()
```

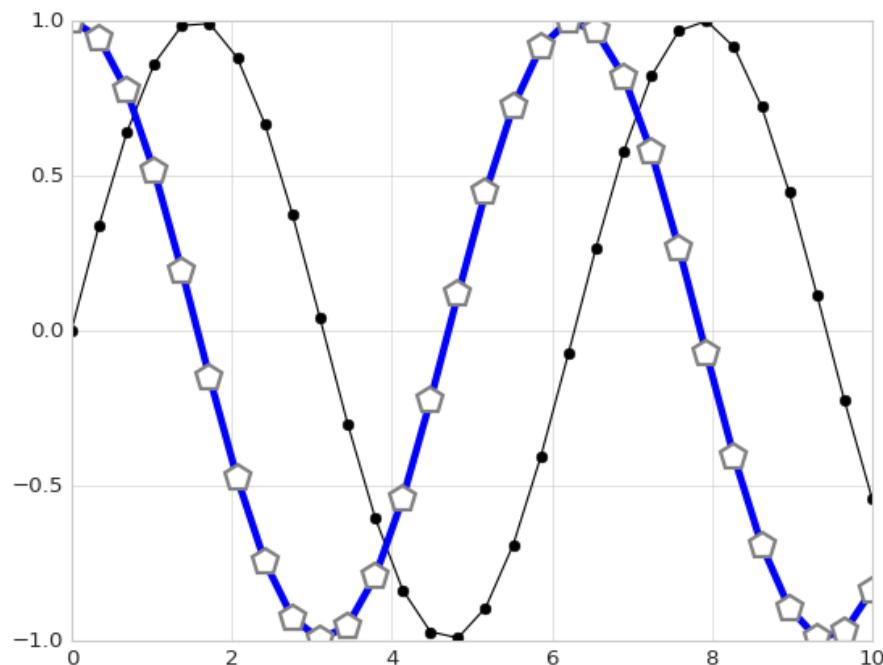


```
import numpy as np

x = np.linspace(0, 10, 30)
y = np.sin(x)
z = np.cos(x)

plt.plot(x, y, '-ok') # line (-), circle marker (o), black (k)
plt.plot(x, z, '-pb',
          markersize=15, linewidth=4,
          markerfacecolor='white',
          markeredgecolor='gray',
          markeredgewidth=2)

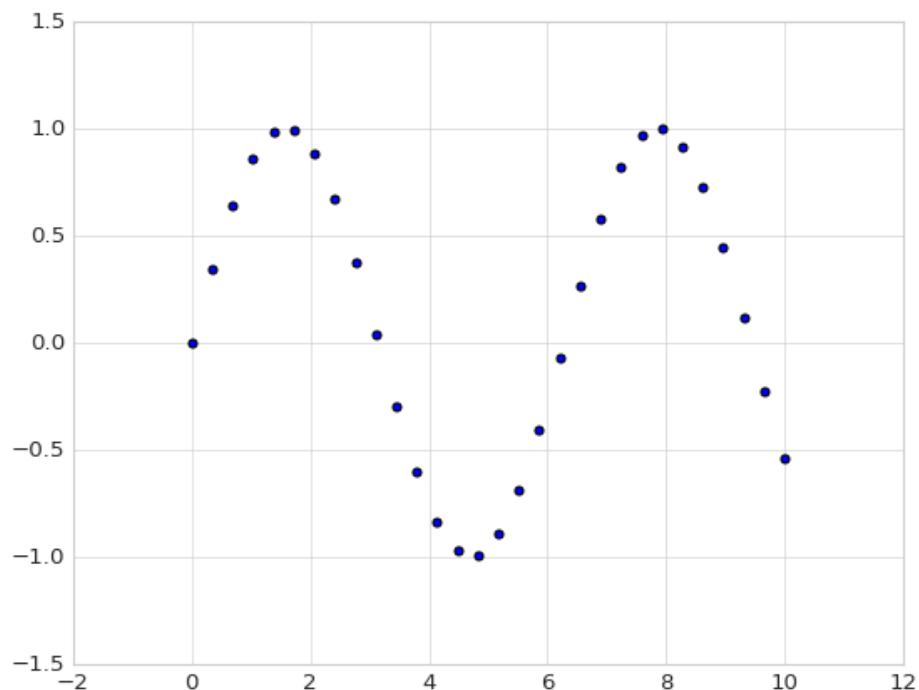
plt.show()
```



48 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทยตอน

```
x = np.linspace(0, 10, 30)
y = np.sin(x)

plt.scatter(x, y, marker='o')
plt.show()
```

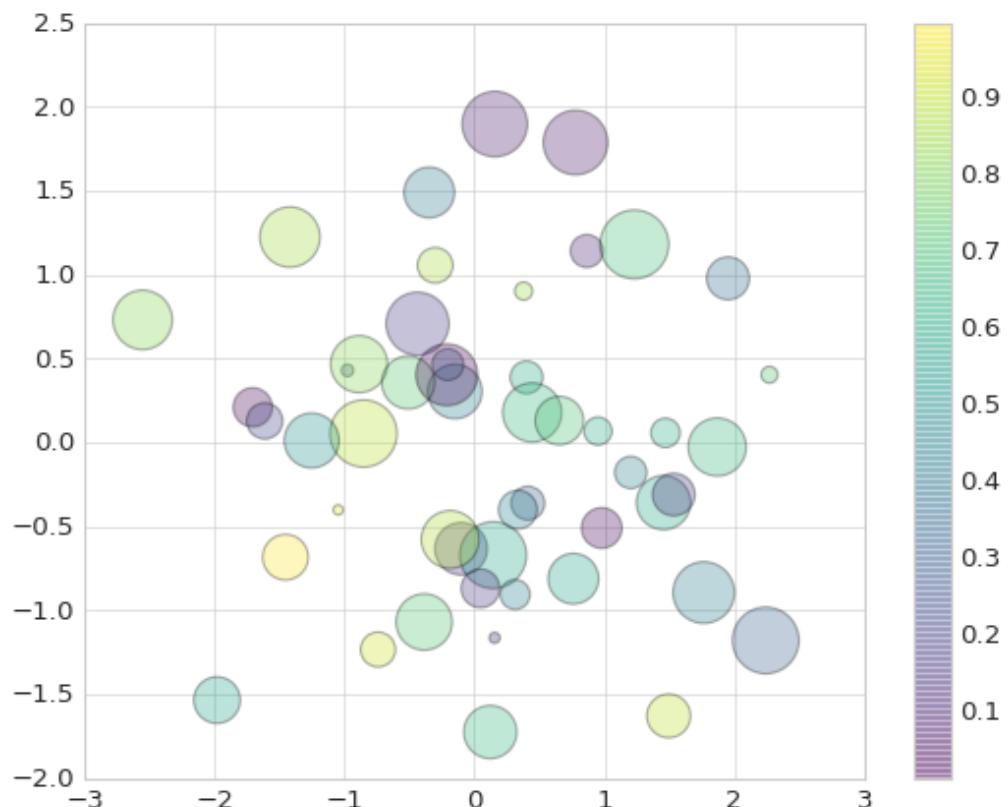


## การตกแต่ง Scatter

```
rng = np.random.RandomState(0)

no_plot = 50
x = rng.randn(no_plot)
y = rng.randn(no_plot)
colors = rng.rand(no_plot)
sizes = 1000 * rng.rand(no_plot)

plt.scatter(x, y, c=colors, s=sizes, alpha=0.3,
            cmap='viridis')
plt.colorbar()
plt.show()
```



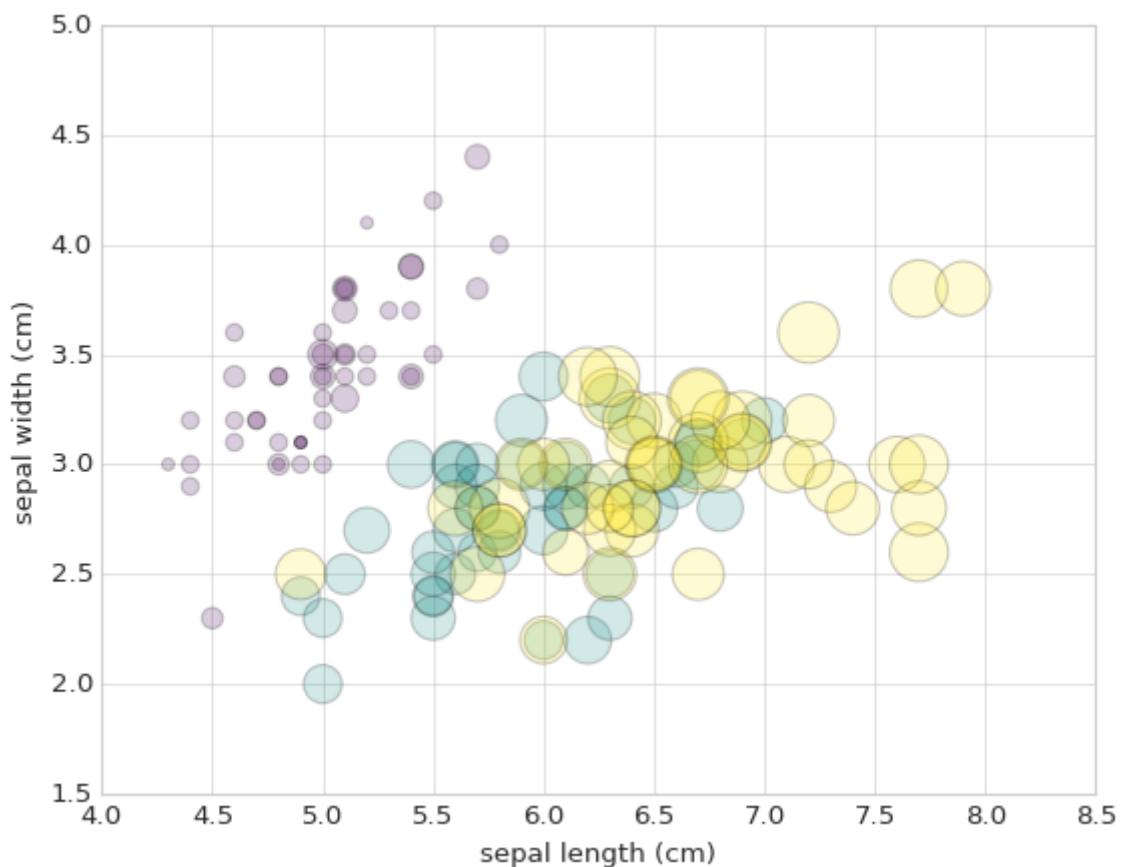
50 គាមរូពីន្ទានេងបានការរើសរាល់ក្នុងការបង្កើតមែនភាព និងការវិគោរាប់ដែលបានបង្កើតឡើងដោយកិច្ចការណ៍

```
from sklearn.datasets import load_iris

iris_dataset = load_iris()
features = iris_dataset.data.T # T = Matrix Transpose

plt.scatter(features[0], features[1], alpha=0.2,
            s=300*features[3], c=iris_dataset.target,
            cmap='viridis')

plt.xlabel(iris_dataset.feature_names[0])
plt.ylabel(iris_dataset.feature_names[1])
plt.show()
```

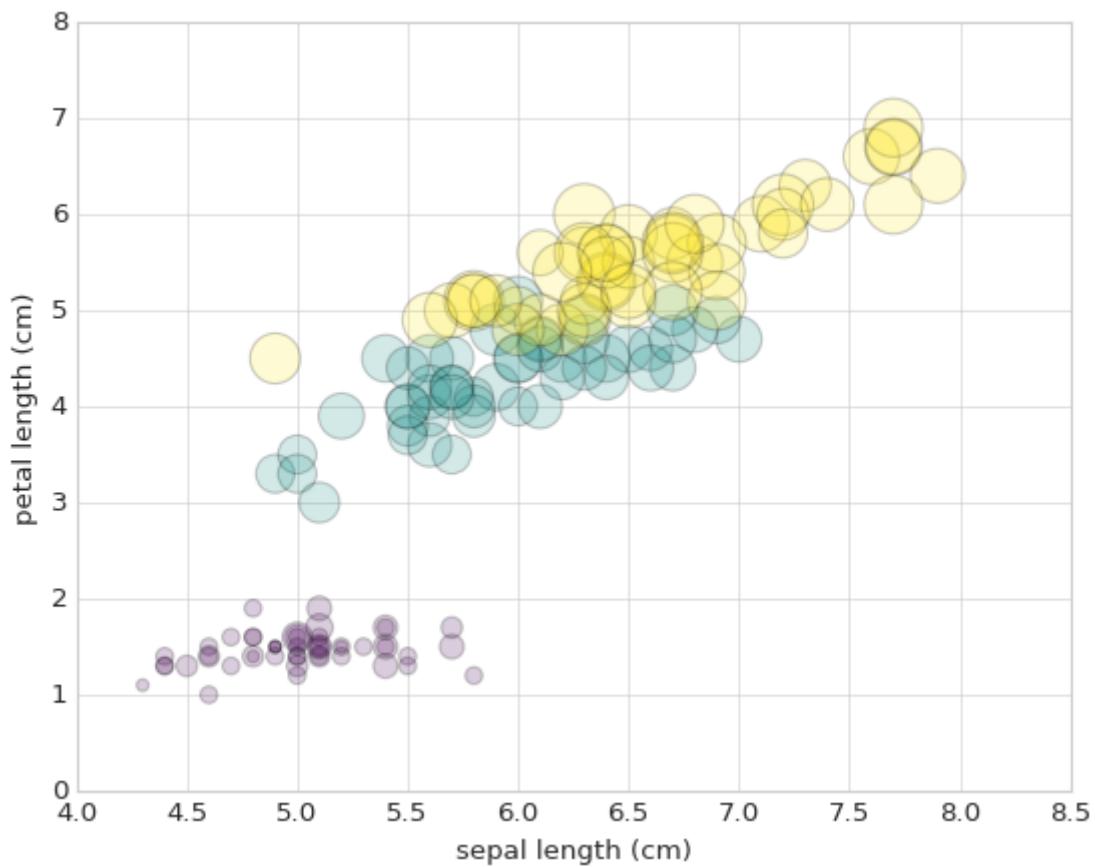


```
from sklearn.datasets import load_iris

iris_dataset = load_iris()
features = iris_dataset.data.T # T = Matrix Transpose

plt.scatter(features[0], features[2], alpha=0.2,
            s=300*features[3], c=iris_dataset.target,
            cmap='viridis')

plt.xlabel(iris_dataset.feature_names[0])
plt.ylabel(iris_dataset.feature_names[2])
plt.show()
```

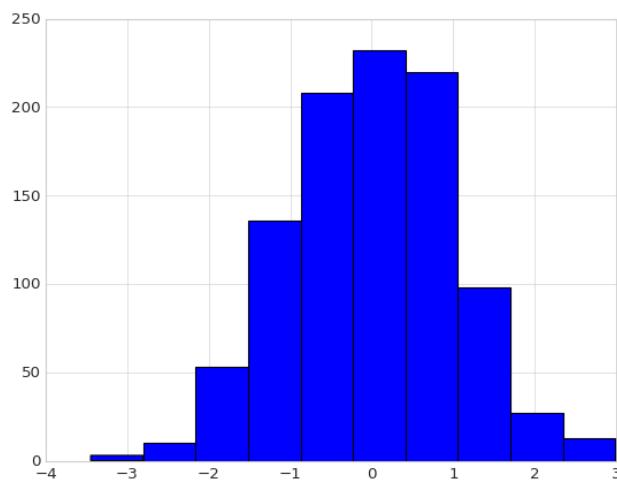


## การplot Histograms, Binnings และ Density

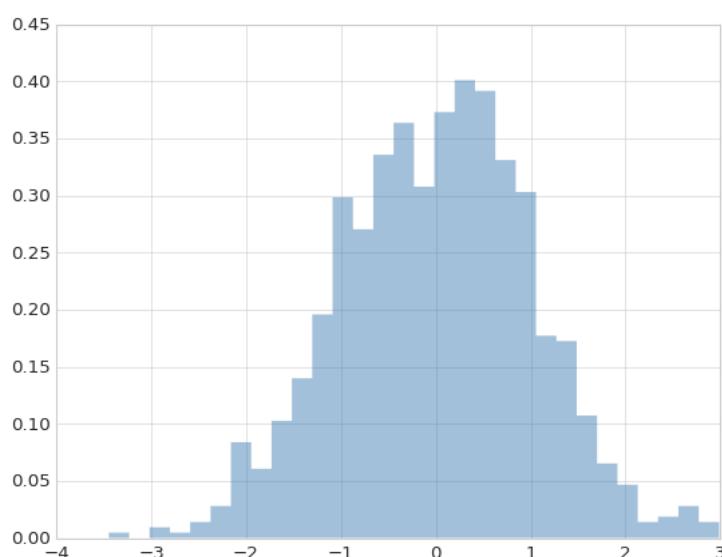
```
import numpy as np
import matplotlib.pyplot as plt

data = np.random.randn(1000)

# simple histogram
plt.hist(data)
plt.show()
```



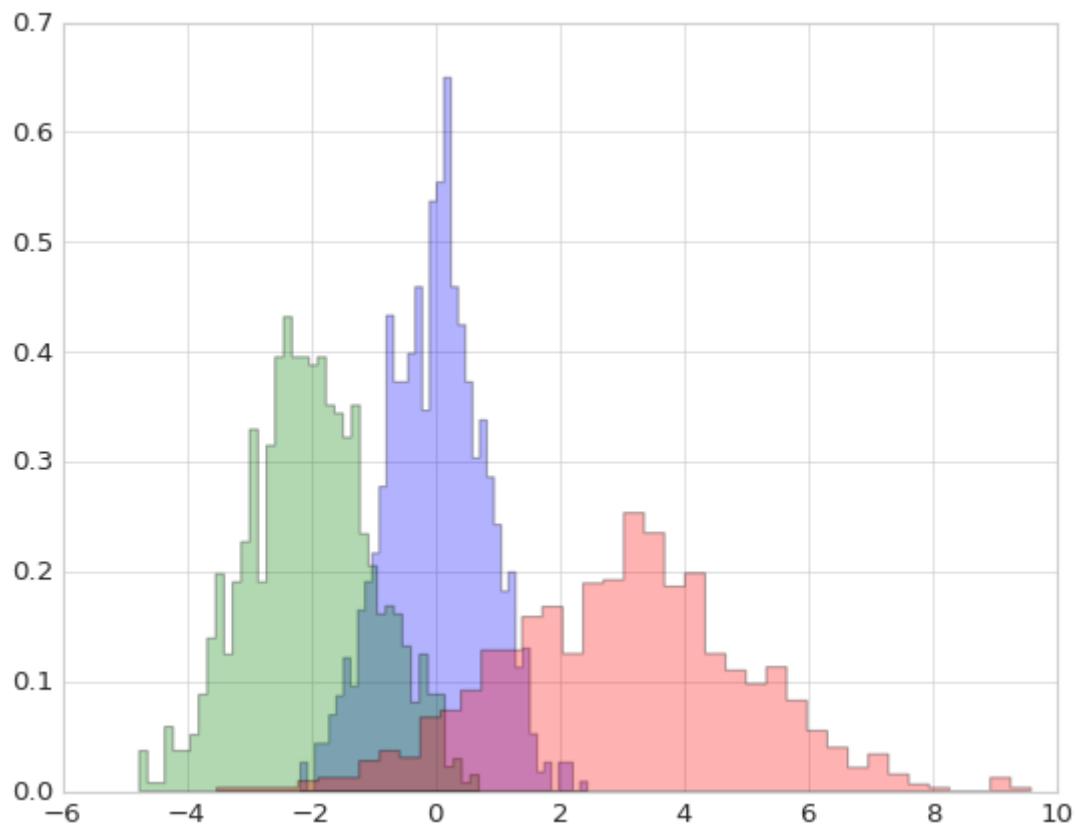
```
plt.hist(data, bins=30, normed=True, alpha=0.5,
          histtype='stepfilled', color='steelblue',
          edgecolor='none')
plt.show()
```



```
# over-plotting multiple histograms
x1 = np.random.normal(0, 0.8, 1000)
x2 = np.random.normal(-2, 1, 1000)
x3 = np.random.normal(3, 2, 1000)

kwargs = dict(histtype='stepfilled', alpha=0.3,
              normed=True, bins=40)

plt.hist(x1, **kwargs)
plt.hist(x2, **kwargs)
plt.hist(x3, **kwargs)
plt.show()
```



## การคำนวณค่า Histogram

```
counts, bin_edges = np.histogram(data, bins=5)
print(counts)

counts, bin_edges = np.histogram(data, bins=7)
print(counts)

[ 33 202 534 219 12]
[ 14 65 231 397 224 65 4]
```

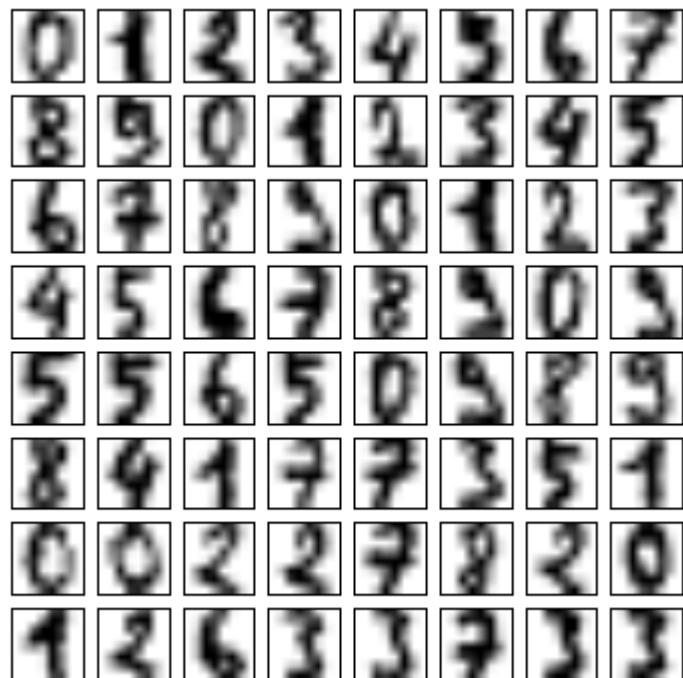
## การพลอตชุดข้อมูล MNSIT ที่อยู่ใน scikit-learn

การพลอตชุดข้อมูล MNSIT ที่เรียกใช้จากโปรแกรม scikit-learn สามารถทำได้ดังนี้

```
from sklearn import datasets

digits = datasets.load_digits()
fig, ax = plt.subplots(8, 8, figsize=(6,6))
for i, axi in enumerate(ax.flat):
    axi.imshow(digits.images[i], cmap='binary')
    axi.set(xticks=[], yticks=[])

```



## การplotชุดข้อมูล MNIST ในรูปแบบ 2 มิติ โดยใช้วิธี IsoMap

```
from sklearn import datasets
digits = datasets.load_digits(n_class=5)
```

ตัวอย่างข้างต้น แสดงวิธีการดึงข้อมูล MNIST โดยกำหนดให้ n\_class=5 นั่นหมายถึงให้ลดเดพาของ class 0-4 เท่านั้น

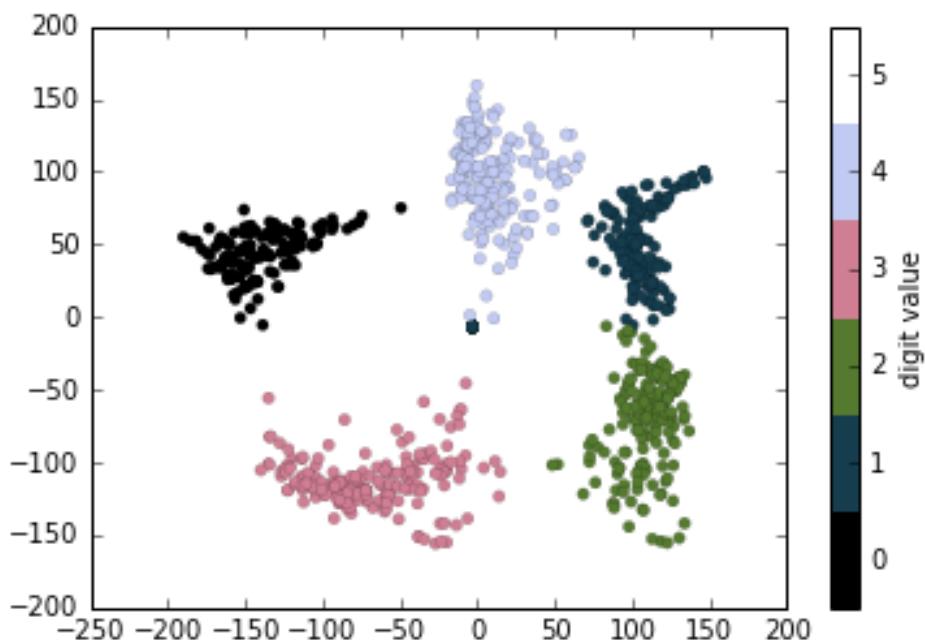
```
from sklearn.manifold import Isomap

iso = Isomap(n_components=2)
projection = iso.fit_transform(digits.data)
```

จากนั้นเรียกใช้เมธอด Isomap เพื่อคำนวณหาค่าสหสัมพันธ์โดยกำหนดให้ components = 2

```
plt.scatter(projection[:, 0], projection[:, 1], lw=0.1,
            c=digits.target,
            cmap=plt.cm.get_cmap('cubehelix', 6))
plt.colorbar(ticks=range(6), label='digit value')
plt.clim(-0.5, 5.5)

plt.show()
```



56 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทยตอน

# บทที่ 5

## ไลบรารี Seaborn (Seaborn Library)

Seaborn Library เป็นไลบรารีที่ใช้งานร่วมกับ Python เพื่อใช้แสดงข้อมูลทางสถิติ (statistical data visualization) การติดตั้งไลบรารี Seaborn ทำได้โดยเปิดโปรแกรม Terminal และพิมพ์คำสั่งดังต่อไปนี้

```
$ pip install seaborn
```

หากต้องการติดตั้งผ่าน Jupyter สามารถทำได้โดย

```
! pip install seaborn
```

ไลบรารี seaborn จะทำงานควบคู่กับไลบรารี Pandas ดังนั้น หากยังไม่ได้ติดตั้ง Pandas สามารถทำได้โดยใช้คำสั่งดังต่อไปนี้

```
$ pip install pandas
```

เมื่อติดตั้ง seaborn เป็นที่เรียบร้อย สามารถทดสอบโดยอิมพอร์ตไลบรารี seaborn มาใช้งาน ดังนี้

```
import seaborn as sns
```

ทดสอบการใช้ไลบรารี seaborn โดยเรียกใช้ชุดข้อมูล Iris ทำได้ดังต่อไปนี้

```
import seaborn as sns
iris_dataset = sns.load_dataset('iris')
iris_dataset.head()
```

เมื่อโหลดชุดข้อมูล iris เสร็จแล้ว ตัวแปร iris\_dataset จะถูกจัดเก็บให้อยู่ในรูปแบบของ pandas DataFrame หากต้องการดูข้อมูลที่อยู่ใน DataFrame สามารถใช้คำสั่ง head() เพื่อดูราย

58 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน

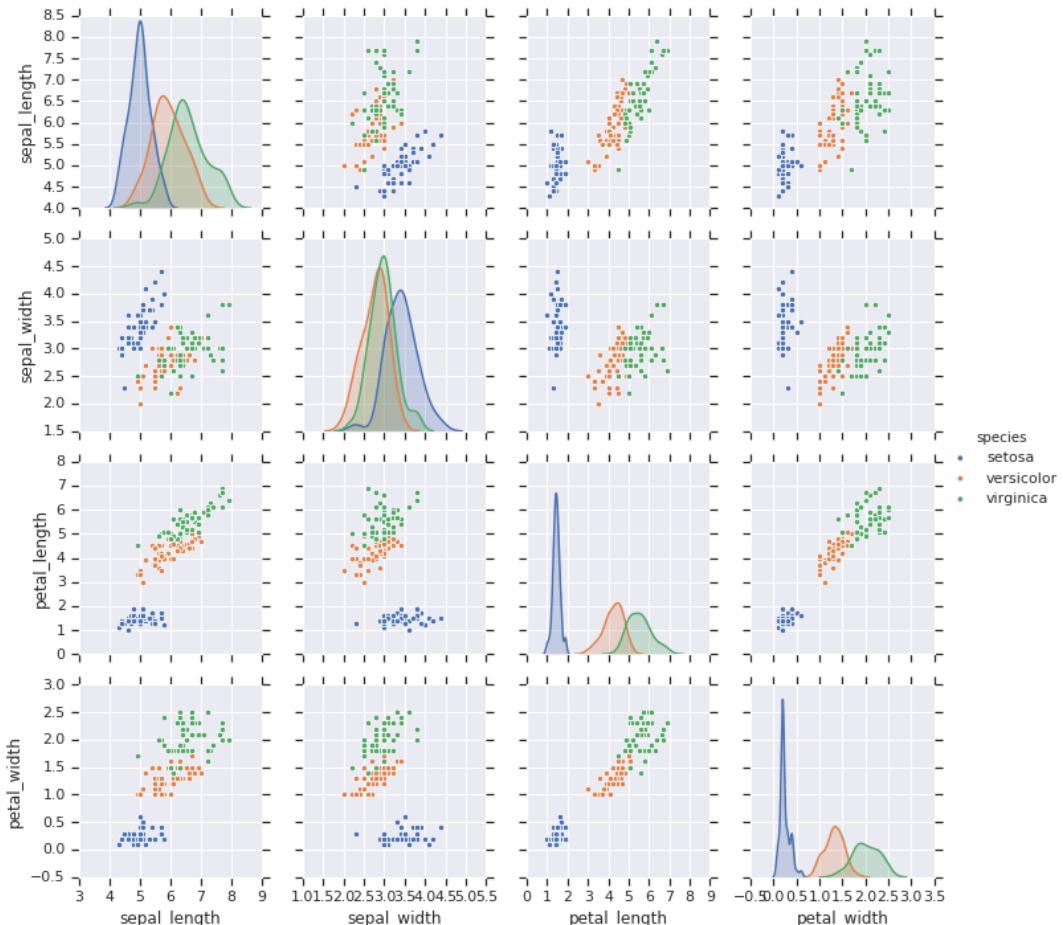
จะอธิบายโดยคำสั่ง head() จะแสดงตัวอย่างจำนวน 5 ตัวอย่างเท่านั้น ผลลัพธ์ที่ได้จากการใช้คำสั่ง iris\_dataset.head() แสดงดังต่อไปนี้

|   | sepal_length | sepal_width | petal_length | petal_width | species |
|---|--------------|-------------|--------------|-------------|---------|
| 0 | 5.1          | 3.5         | 1.4          | 0.2         | setosa  |
| 1 | 4.9          | 3.0         | 1.4          | 0.2         | setosa  |
| 2 | 4.7          | 3.2         | 1.3          | 0.2         | setosa  |
| 3 | 4.6          | 3.1         | 1.5          | 0.2         | setosa  |
| 4 | 5.0          | 3.6         | 1.4          | 0.2         | setosa  |

## การแสดงชุดข้อมูล Iris แบบ Visualization

```
import seaborn as sns
import matplotlib.pyplot as plt

sns.set()
sns.pairplot(iris_dataset, hue='species', size=2.5)
plt.show()
```



## การทำงานร่วมกันระหว่าง seaborn และ scikit-learn

ในกรณีที่ใช้ seaborn โหลดข้อมูลมาใช้งาน ข้อมูลจะถูกจัดเก็บในรูปแบบของ DataFrame ดังนั้นหากต้องการดึงข้อมูล (Extract) อาร์เรย์ feature และ target ออกจาก DataFrame สามารถทำได้ดังนี้

```
X_iris = iris_dataset.drop('species', axis=1)
X_iris.shape
```

(150, 4)

จากตัวอย่างข้างต้น คำสั่ง `iris_dataset.drop('species', axis=1)` เป็นการลบข้อมูลของ 'species' ในแนวคอลัมน์ ซึ่งมีทั้งหมด 1 attribute ออกจาก `iris_dataset`

```
y_iris = iris_dataset['species']
y_iris.shape
```

(150, )

จากตัวอย่างข้างต้น เลือกคอลัมน์ 'species' ซึ่งมีทั้งหมด 1 attribute เพื่อใช้เป็นข้อมูล y หรือ label

หากต้องการดูประเภทของข้อมูลสามารถใช้คำสั่ง `type()` และดังตัวอย่างต่อไปนี้

```
type(X_iris)
```

`pandas.core.frame.DataFrame`

จากตัวอย่างข้างต้นแสดงให้เห็นว่าตัวแปร `X_iris` เป็นข้อมูลประเภท DataFrame ดังนั้นสามารถใช้คำสั่ง `head()` เพื่อดูข้อมูลของ `X_iris`

```
X_iris.head()
```

|   | sepal_length | sepal_width | petal_length | petal_width |
|---|--------------|-------------|--------------|-------------|
| 0 | 5.1          | 3.5         | 1.4          | 0.2         |
| 1 | 4.9          | 3.0         | 1.4          | 0.2         |
| 2 | 4.7          | 3.2         | 1.3          | 0.2         |
| 3 | 4.6          | 3.1         | 1.5          | 0.2         |
| 4 | 5.0          | 3.6         | 1.4          | 0.2         |

หากต้องการเรียกดูข้อมูลที่ละล่วน (Slice) สามารถทำได้ดังต่อไปนี้

```
X_iris.iloc[1] # row 1
```

```
sepal_length    4.9  
sepal_width     3.0  
petal_length    1.4  
petal_width     0.2  
Name: 1, dtype: float64
```

สามารถใช้ index ในการเรียกดูข้อมูล ซึ่งคล้ายกับอาร์เรย์ จากตัวอย่างต่อไปนี้ คือการเรียกดูข้อมูลที่ row = 0 และ col = 0

```
X_iris.iloc[0,0] # row 0, col 0
```

5.1

หากต้องการเรียกดูข้อมูลในทุก ๆ row ที่ col = 1 สามารถทำได้โดย

```
X_iris.iloc[:,1]
```

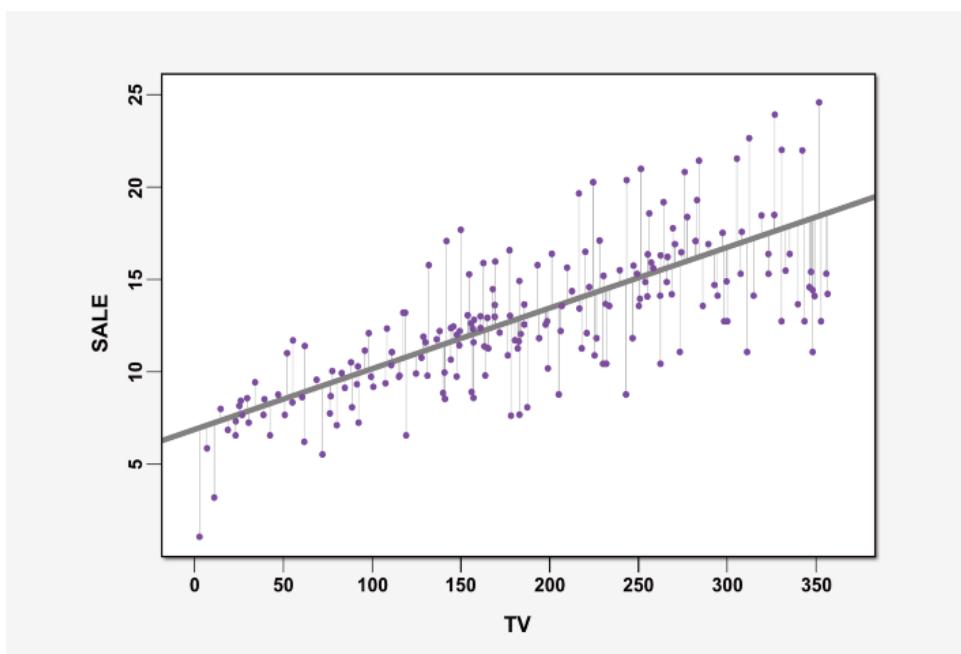
```
0      3.5  
1      3.0  
2      3.2  
3      3.1  
4      3.6  
5      3.9  
...  
144    3.3  
145    3.0  
146    2.5  
147    3.0  
148    3.4  
149    3.0  
Name: sepal_width, dtype: float64
```

# บทที่ 6

## การวิเคราะห์การลดด้อยเชิงเส้น (Linear Regression)

การวิเคราะห์การลดด้อยเชิงเส้น (Linear Regression) เป็นการคำนวณหาความสัมพันธ์ระหว่างตัวแปรตั้งแต่ 2 ตัวแปร โดยเป็นการประมาณการ (Predictor, X) และตัวตอบสนอง (Response, y) ซึ่งเป็นความสัมพันธ์แบบเชิงเส้น (Linear) ซึ่งเป็นการคำนวณจากค่า X และ y ที่มีความสัมพันธ์กัน เพื่อคำนวณออกมาเป็นสมการความสัมพันธ์ สมการของ Linear Regression แสดงดังต่อไปนี้

$$y = ax + b$$



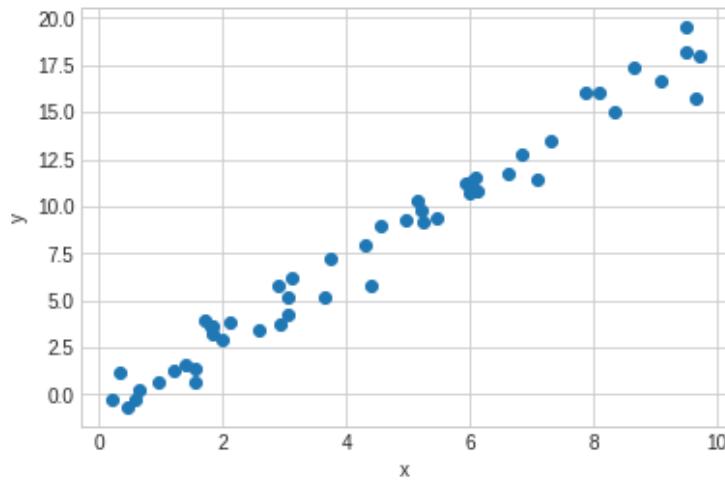
ภาพประกอบที่ 9: แสดงสมการลดด้อยเชิงเส้น Linear Regression  
ที่มา : <https://goo.gl/QL6rCo>

## การจำลองชุดข้อมูลเพื่อใช้ในการคำนวณ Linear Regression

```
import matplotlib.pyplot as plt
import numpy as np
plt.style.use('seaborn-whitegrid')

# create random data
rng = np.random.RandomState(42)
x = 10 * rng.rand(50)
y = 2 * x - 1 + rng.randn(50)

plt.scatter(x,y)
plt.xlabel('x')
plt.ylabel('y')
plt.show()
```



## การเรียกใช้โมดูล LinearRegression

การเรียกใช้ Linear Regression ในโปรแกรม scikit-learn สามารถทำได้ดังนี้

```
from sklearn.linear_model import LinearRegression
```

จากนั้นสามารถกำหนดค่าพารามิเตอร์ (Hyperparameter) เช่น

```
model = LinearRegression(fit_intercept=True)
print(model)
```

```
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=1, normalize=False)
```

## จัดการข้อมูลเพื่อใช้ในการคำนวณ

```
X = x[:, np.newaxis]
print(X.shape)
```

(50, 1)

จากตัวอย่างข้างต้นข้อมูลที่จะนำไปใช้ในการคำนวณ Linear Regression กำหนดให้มีขนาดเป็น (50, 1) นั่นหมายถึงมีตัวแปร X เพียงตัวแปรเดียว ซึ่งเรียกว่าการคำนวณแบบ Simple Linear Regression หากมีตัวแปร X มากกว่า 1 ตัวจะเรียกว่า Multiple Linear Regression

```
print X[:10]
```

```
[[ 3.74540119]
 [ 9.50714306]
 [ 7.31993942]
 [ 5.98658484]
 [ 1.5601864 ]
 [ 1.5599452 ]
 [ 0.58083612]
 [ 8.66176146]
 [ 6.01115012]
 [ 7.08072578]]
```

หากต้องการแสดงข้อมูลของตัวแปร X สามารถทำได้โดยใช้คำสั่ง print และสามารถ Slice ข้อมูลออกมาดูโดยกำหนด index ที่ต้องการ เช่น X[:10] หมายถึง การแสดงข้อมูล X ตั้งแต่ ข้อมูลลำดับที่ 0 ถึง 10

## การเรียนรู้เพื่อสร้างโมเดล (Train the model)

```
model.fit(X,y)
```

```
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=1, normalize=False)
```

ในโปรแกรม scikit-learn สามารถใช้คำสั่ง fit เพื่อที่จะสร้างโมเดลขึ้นมาใช้งาน ดังตัวอย่าง ข้างต้น

## การพยากรณ์ผลลัพธ์จากข้อมูลใหม่ (Predict Labels for Unknown Data)

เนื่องจากตัวอย่างข้างต้นได้จำลองข้อมูลเพื่อนำมาใช้ในการเรียนรู้ของ Linear Regression ดังนั้นในส่วนของการพยากรณ์ข้อมูลจึงทำการจำลองข้อมูลชุดใหม่อีก 1 ชุด เพื่อใช้สำหรับการพยากรณ์ การจำลองข้อมูลสามารถทำได้ดังนี้

```
xfit = np.linspace(-1, 11)  
  
# Xfit = unknown data  
Xfit = xfit[:, np.newaxis]  
  
print(Xfit.shape)  
print(Xfit[:10])
```

(50, 1)

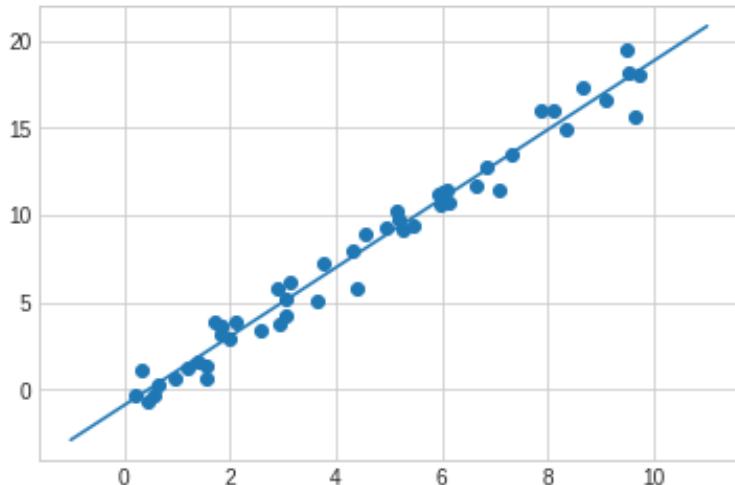
```
[[ -1.  
[-0.75510204]  
[-0.51020408]  
[-0.26530612]  
[-0.02040816]  
[ 0.2244898]  
[ 0.46938776]  
[ 0.71428571]  
[ 0.95918367]  
[ 1.20408163]]
```

ตัวอย่างข้างต้นได้จำลองข้อมูลจำนวน 50 จุดเพื่อใช้สำหรับการพยากรณ์ จากนั้นนำข้อมูลที่ได้ไปพยากรณ์ด้วยคำสั่ง predict ดังตัวอย่างต่อไปนี้

```
yfit = model.predict(Xfit)
```

ผลการพยากรณ์จะถูกเก็บไว้ในตัวแปร yfit ดังนั้นสามารถนำผลลัพธ์ที่ได้มาผลิตกราฟเพื่อแสดงเส้น Linear ที่ได้จากการพยากรณ์ ดังตัวอย่างต่อไปนี้

```
plt.scatter(x, y)
plt.plot(xfit, yfit)
plt.show()
```



ภาพประกอบที่ 10: เส้น Hyperplane ที่ได้จากการคำนวณด้วยวิธี Linear Regression

## การพยากรณ์ข้อมูล Diabetes ด้วย Linear Regression

อัมพอร์ตไลบรารีที่จำเป็นสำหรับการทำ Linear Regression

```
import matplotlib.pyplot as plt
import numpy as np
from sklearn import datasets, linear_model
from sklearn.metrics import mean_squared_error, r2_score
```

โหลดชุดข้อมูล Diabetes

```
diabetes = datasets.load_diabetes()
```

ตรวจสอบขนาดของข้อมูล

```
print("shape of the dataset", diabetes.data.shape)
```

```
('shape of the dataset', (442, 10))
```

## 66 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน

ตรวจสอบข้อมูลตั้งแต่ row ลำดับที่ 0 ถึง 5 และ column ลำดับที่ 0 ถึง 5

**diabetes.data[0:5, 0:5]**

```
array([[ 0.03807591,  0.05068012,  0.06169621,  0.02187235, -0.0442235 ],
       [-0.00188202, -0.04464164, -0.05147406, -0.02632783, -0.00844872],
       [ 0.08529891,  0.05068012,  0.04445121, -0.00567061, -0.04559945],
       [-0.08906294, -0.04464164, -0.01159501, -0.03665645,  0.01219057],
       [ 0.00538306, -0.04464164, -0.03638469,  0.02187235,  0.00393485]])
```

ในการนี้ค่า X จะถูกกำหนดให้ใช้ข้อมูล diabetes ใน column ที่ 2

```
diabetes_X = diabetes.data[:, np.newaxis, 2] # column 2
diabetes_X[:10]
```

```
array([[ 0.06169621],
       [-0.05147406],
       [ 0.04445121],
       [-0.01159501],
       [-0.03638469],
       [-0.04069594],
       [-0.04716281],
       [-0.00189471],
       [ 0.06169621],
       [ 0.03906215]])
```

เนื่องจากข้อมูล diabetes มีจำนวน 442 instance และไม่ได้แบ่งข้อมูลออกเป็นชุดทดสอบ และชุดเรียนรู้ จึงต้องแบ่งข้อมูลออกเป็นสองส่วน

```
# Split the data into training/testing sets
diabetes_X_train = diabetes_X[:-20]
diabetes_X_test = diabetes_X[-20:]

# Split the targets into training/testing sets
diabetes_y_train = diabetes.target[:-20]
diabetes_y_test = diabetes.target[-20:]
```

ในการนี้ไม่ได้ใช้ฟังก์ชัน train\_test\_split เพื่อแบ่งข้อมูล แต่ได้กำหนดให้ข้อมูลตั้งแต่ row ลำดับที่ 0 ถึงลำดับที่ 422 เป็นข้อมูลสำหรับการเรียนรู้ และลำดับที่ 423 ถึง 442 เป็นข้อมูลสำหรับการทดสอบ ดังนั้น `[:-20]` จึงหมายถึงข้อมูลตั้งแต่ลำดับแรกไปจนถึงลำดับสุดท้าย แต่นับด้วย 20 ( $442-20 = 422$ )

ขั้นตอนต่อไป ทำการสร้างโมเดลด้วยคำสั่ง `LinearRegression()` และเรียนรู้ (Train) ด้วย ข้อมูลชุดเรียนรู้ ซึ่งก็คือ `diabetes_X_train`

```
regr = linear_model.LinearRegression()
regr.fit(diabetes_X_train, diabetes_y_train)
```

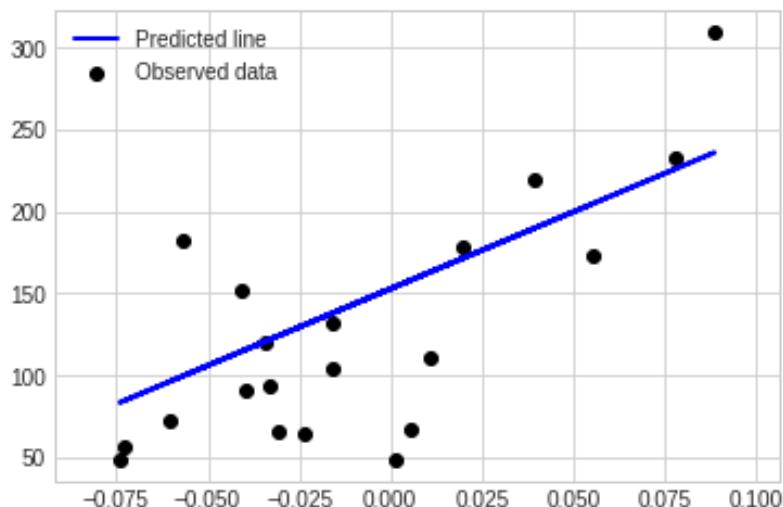
```
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=1,
normalize=False)
    จากนั้น ทำการพยากรณ์ข้อมูลชุดทดสอบ diabetes_X_test ด้วยคำสั่ง predict()
    diabetes_y_pred = regr.predict(diabetes_X_test)
```

ทำการผลลัพธ์กราฟเพื่อดูข้อมูล และเส้น Hyperplane ที่ได้จากการคำนวณ

```
import matplotlib.pyplot as plt

plt.scatter(diabetes_X_test, diabetes_y_test, color='black')
plt.plot(diabetes_X_test, diabetes_y_pred, color='blue',
         linewidth=2)
plt.legend(['Predicted line', 'Observed data'])

plt.show()
```



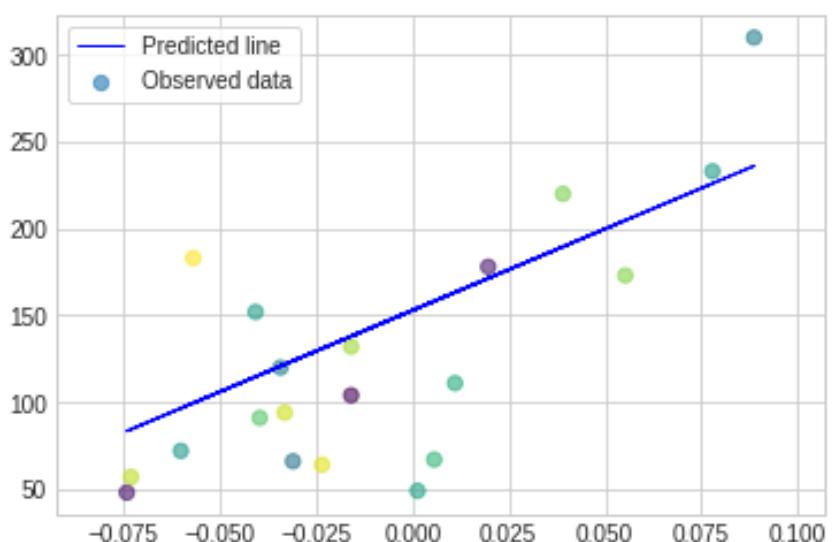
ปรับแต่งกราฟให้สวยงาม ทำได้ดังนี้

```
import numpy as np
import matplotlib.pyplot as plt

rng = np.random.RandomState(0)
colors = rng.rand(20)

fig = plt.figure()
plt.scatter(diabetes_X_test, diabetes_y_test, c=colors, s=40,
            alpha=0.6, cmap='viridis')
plt.plot(diabetes_X_test, diabetes_y_pred, color='blue',
         linewidth=1)
plt.legend(['Predicted line', 'Observed data'], frameon=True,
           loc='upper left')

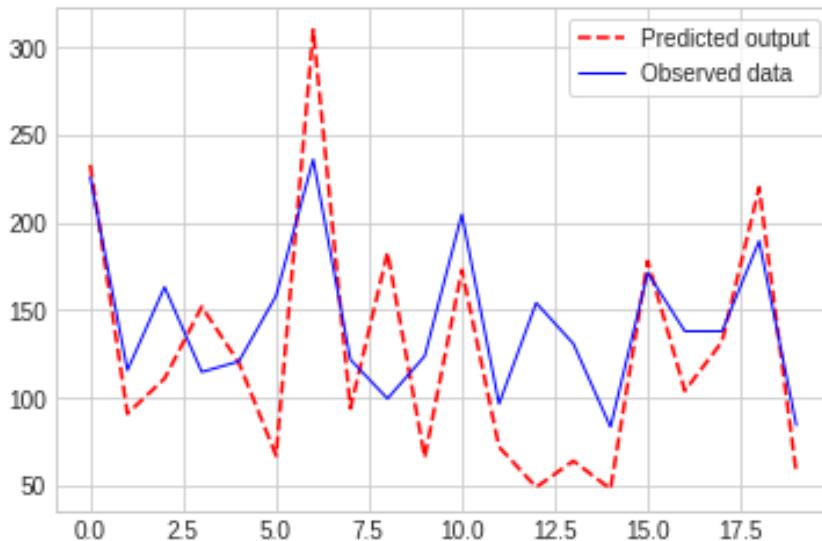
plt.show()
```



หากต้องการเปรียบเทียบระหว่าง actual target และ predict target สามารถทำได้ ดังนี้

```
plt.plot(diabetes_y_test, '--r')
plt.plot(diabetes_y_pred, '-b', linewidth=1)
plt.legend(['Predicted output', 'Observed data'],
           frameon=True, loc='upper right')

plt.show()
```



ภาพประกอบที่ 11: แสดงการผลิตค่า target จริง (Actual Target) และค่า target ที่ได้จากการพยากรณ์ (Predicted Target)

สามารถพิมพ์ค่า coefficients และค่า Mean Squared Error (MSE) ออกมาเพื่อตรวจสอบได้ดังนี้

```
# The coefficients
print('Coefficients: \n', regr.coef_)
# The mean squared error
print("Mean squared error: %.2f"
      % mean_squared_error(diabetes_y_test, diabetes_y_pred))
# Explained variance score: 1 is perfect prediction
print('Variance score: %.2f' % r2_score(diabetes_y_test,
                                         diabetes_y_pred))
```

```
('Coefficients: \n', array([ 938.23786125]))
Mean squared error: 2548.07
Variance score: 0.47
```

## การพยากรณ์ข้อมูล Housing ด้วย Linear Regression

อิมพอร์ตไลบรารีที่จำเป็นสำหรับการทำ Linear Regression

```
import pandas as pd
import numpy as np
from sklearn import linear_model
from sklearn.cross_validation import train_test_split
from sklearn.metrics import mean_squared_error, r2_score
```

โหลดข้อมูล boston housing ที่อยู่ใน scikit-learn มาใช้งาน

```
from sklearn.datasets import load_boston # housing dataset
boston = load_boston()
```

ตัวแปร boston ถูกจัดเก็บอยู่ในรูปแบบ dictionary สามารถเรียกดูรายละเอียดของการจัดเก็บข้อมูลด้วยคำสั่ง keys()

```
print(boston.keys())
```

```
['data', 'feature_names', 'DESCR', 'target']
```

หากต้องการดูรายละเอียดของชุดข้อมูล Boston housing สามารถทำได้โดย

```
print(boston.DESCR) หรือคำสั่ง print(boston['DESCR'])
```

Boston House Prices dataset

=====

Notes

-----

Data Set Characteristics:

:Number of Instances: 506

:Number of Attributes: 13 numeric/categorical predictive

:Median Value (attribute 14) is usually the target

:Attribute Information (in order):

- CRIM per capita crime rate by town  
- ZN proportion of residential land zoned for lots over 25,000

sq.ft.

- INDUS proportion of non-retail business acres per town

- CHAS Charles River dummy variable (= 1 if tract bounds river; 0 otherwise)

- NOX nitric oxides concentration (parts per 10 million)

- RM average number of rooms per dwelling

- AGE proportion of owner-occupied units built prior to 1940

- DIS weighted distances to five Boston employment centres

```

- RAD      index of accessibility to radial highways
- TAX      full-value property-tax rate per $10,000
- PTRATIO  pupil-teacher ratio by town
- B        1000(Bk - 0.63)^2 where Bk is the proportion of blacks by
town
- LSTAT    % lower status of the population
- MEDV     Median value of owner-occupied homes in $1000's

:Missing Attribute Values: None

```

หากต้องการทราบขนาดของชุดข้อมูล Boston housing สามารถทำได้โดย

```

print("shape of the data", boston.data.shape)
#print("shape of the data", boston['data'].shape)
boston['data'][::2, :] # row = 2, col = all

('shape of the data', (506, 13))

array([[ 6.32000000e-03,   1.80000000e+01,   2.31000000e+00,
       0.00000000e+00,   5.38000000e-01,   6.57500000e+00,
       6.52000000e+01,   4.09000000e+00,   1.00000000e+00,
       2.96000000e+02,   1.53000000e+01,   3.96900000e+02,
       4.98000000e+00],
 [ 2.73100000e-02,   0.00000000e+00,   7.07000000e+00,
       0.00000000e+00,   4.69000000e-01,   6.42100000e+00,
       7.89000000e+01,   4.96710000e+00,   2.00000000e+00,
       2.42000000e+02,   1.78000000e+01,   3.96900000e+02,
       9.14000000e+00]])

```

ข้อมูลชุด Boston housing มีจำนวน 506 instance และมี feature ทั้งสิ้น 13 attribute หากต้องการดู Label ของข้อมูลสามารถทำได้โดยใช้คำสั่ง `boston['target']` และใช้คำสั่ง `shape` เพื่อดูขนาดของข้อมูล

```

print("shape of the target", boston['target'].shape)
boston['target'][::10]

('shape of the target', (506,))
array([ 24. ,  21.6,  34.7,  33.4,  36.2,  28.7,  22.9,  27.1,  16.5,  18.9])

```

เพื่อช่วยในการแสดงข้อมูลสามารถแปลงข้อมูลให้อยู่ในรูปแบบของ pandas DataFrame ดังต่อไปนี้

```

df_x = pd.DataFrame(boston.data, columns=boston.feature_names)
df_y = pd.DataFrame(boston.target)

```

สามารถดูรายละเอียดของข้อมูลโดยเรียกผ่าน DataFrame ดังต่อไปนี้

**df\_x.describe()**

|              | CRIM       | ZN         | INDUS      | CHAS       | NOX        | RM         | AGE        | DIS        | RAD        |
|--------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|
| <b>count</b> | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 |
| <b>mean</b>  | 3.593761   | 11.363636  | 11.136779  | 0.069170   | 0.554695   | 6.284634   | 68.574901  | 3.795043   | 9.549407   |
| <b>std</b>   | 8.596783   | 23.322453  | 6.860353   | 0.253994   | 0.115878   | 0.702617   | 28.148861  | 2.105710   | 8.707259   |
| <b>min</b>   | 0.006320   | 0.000000   | 0.460000   | 0.000000   | 0.385000   | 3.561000   | 2.900000   | 1.129600   | 1.000000   |
| <b>25%</b>   | 0.082045   | 0.000000   | 5.190000   | 0.000000   | 0.449000   | 5.885500   | 45.025000  | 2.100175   | 4.000000   |
| <b>50%</b>   | 0.256510   | 0.000000   | 9.690000   | 0.000000   | 0.538000   | 6.208500   | 77.500000  | 3.207450   | 5.000000   |
| <b>75%</b>   | 3.647423   | 12.500000  | 18.100000  | 0.000000   | 0.624000   | 6.623500   | 94.075000  | 5.188425   | 24.000000  |
| <b>max</b>   | 88.976200  | 100.000000 | 27.740000  | 1.000000   | 0.871000   | 8.780000   | 100.000000 | 12.126500  | 24.000000  |

ภาพประกอบที่ 12: ตัวอย่างข้อมูลที่จัดเก็บในรูปแบบของ pandas DataFrame

**df\_y.describe()**

|              |            |
|--------------|------------|
|              | 0          |
| <b>count</b> | 506.000000 |
| <b>mean</b>  | 22.532806  |
| <b>std</b>   | 9.197104   |
| <b>min</b>   | 5.000000   |
| <b>25%</b>   | 17.025000  |
| <b>50%</b>   | 21.200000  |
| <b>75%</b>   | 25.000000  |
| <b>max</b>   | 50.000000  |

เมื่อเตรียมข้อมูลเรียบร้อยแล้ว จากนั้นทำการสร้างโมเดลของ Linear Regression

```
import pandas as pd
import numpy as np
from sklearn import linear_model
from sklearn.cross_validation import train_test_split
from sklearn.datasets import load_boston # housing dataset

boston = load_boston()
```

ในกรณีนี้จะเลือกใช้เพียง 1 attribute/feature เท่านั้นเพื่อสร้าง Model ในกรณีนี้เลือกใช้ข้อมูลจาก column ลำดับที่ 5 คือ RM

```
# select column 5 = RM
y = boston['target']
X = boston['data']
x_train, x_test, y_train, y_test = train_test_split(X[:,5], y,
test_size=0.2, random_state=4)

# create a model
reg.fit(x_train.reshape(-1, 1), y_train.reshape(-1, 1))

# prediction
y_pred = reg.predict(x_test.reshape(-1, 1))
```

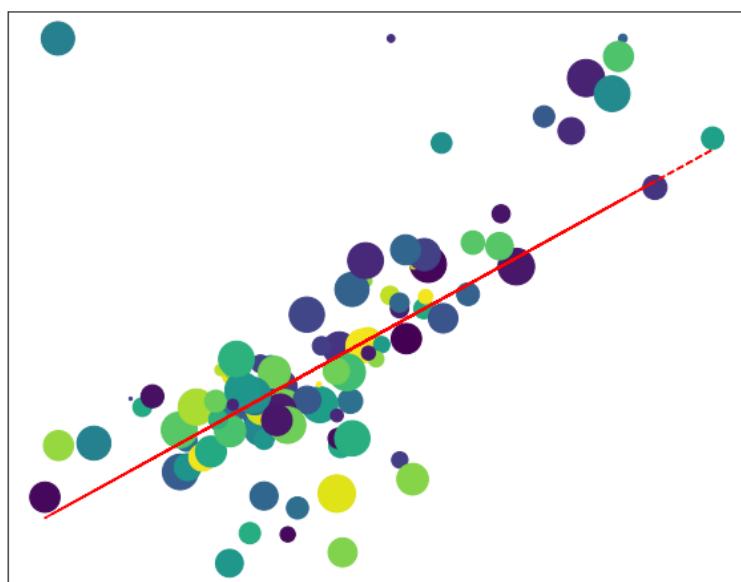
คำสั่ง fit() คือการสร้างโมเดล และ predict() คือการพยากรณ์ ผลลัพธ์ที่ได้จากการพยากรณ์ถูกเก็บไว้ในตัวแปร y\_pred

```
import numpy as np
rng = np.random.RandomState(42)
colors = rng.rand(x_test.shape[0])
sizes = 800 * rng.rand(x_test.shape[0])

plt.figure(figsize=(10,8))
plt.scatter(x_test, y_test, c=colors, s=sizes)
plt.plot(x_test, y_pred, '--r')

plt.xticks(())
plt.yticks(())

plt.show()
```

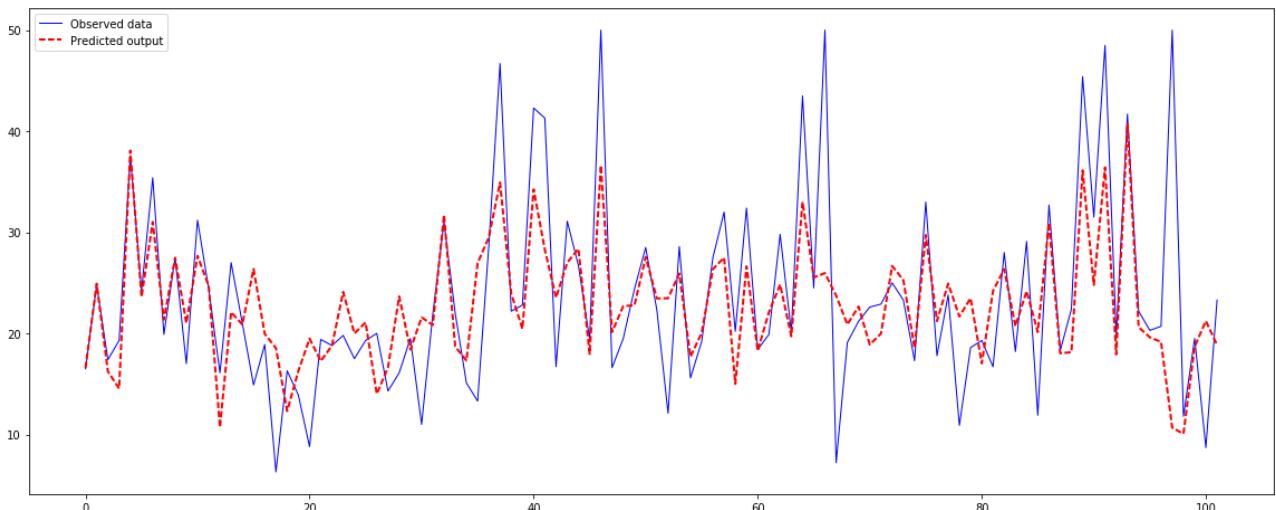


หากต้องการเปรียบเทียบระหว่างค่าจริง (Actual) และค่าที่พยากรณ์ (Predicted) สามารถสร้างกราฟเพื่อแสดงข้อมูลในลักษณะของ Visualization ได้ดังนี้

```
import matplotlib.pyplot as plt

plt.figure(figsize=(20, 8))
plt.plot(y_test, linewidth=1, linestyle='solid',
          color='blue', label='Observed data')
plt.plot(y_pred, '--r', linewidth=2, label='Predicted output')
plt.legend(frameon=True, loc='upper left')

plt.show()
```



แสดงค่า Coefficients, MSE และ Variance score

```
# The coefficients
print('Coefficients: \n', reg.coef_)
# The mean squared error
print("Mean squared error: %.2f"
      % mean_squared_error(y_test, y_pred))
# Explained variance score: 1 is perfect prediction
print('Variance score: %.2f' % r2_score(y_test, y_pred))

('Coefficients: \n', array([[ -1.14743504e-01,    4.70875035e-02,    8.70282354e-03,
   3.23818824e+00,   -1.67240567e+01,    3.87662996e+00,
  -1.08218769e-02,   -1.54144627e+00,    2.92604151e-01,
  -1.33989537e-02,   -9.07306805e-01,    8.91271054e-03,
  -4.58747039e-01]]))
Mean squared error: 25.41
Variance score: 0.73
```

ในการถ้าต้องไปจะใช้ column ลำดับที่ 2 คือ INDUS ในการสร้างโมเดล

```
x = boston['data']
x_train, x_test, y_train, y_test =
train_test_split(X[:,2], y, test_size=0.2,
random_state=4)

# create a model
reg.fit(x_train.reshape(-1, 1), y_train.reshape(-1, 1))

# prediction
y_pred = reg.predict(x_test.reshape(-1, 1))
```

จากนั้นผลลัพธ์จะเป็นรูปภาพเพื่อแสดงในลักษณะของการ Visualization

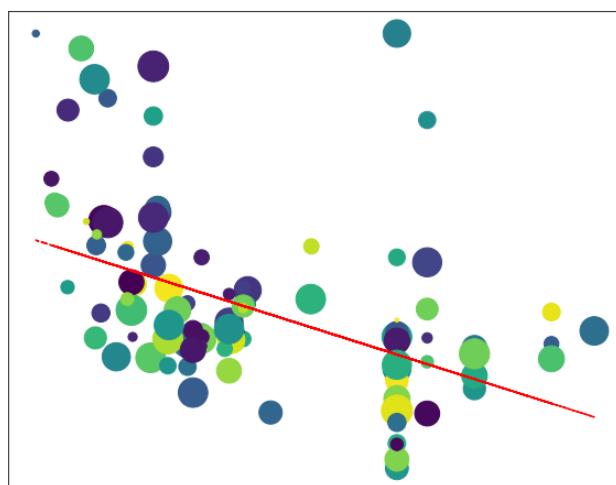
```
import numpy as np
import matplotlib.pyplot as plt

# Plot outputs
rng = np.random.RandomState(42)
colors = rng.rand(x_test.shape[0])
sizes = 800 * rng.rand(x_test.shape[0])

plt.figure(figsize=(10,8))
plt.scatter(x_test, y_test, c=colors, s=sizes)
plt.plot(x_test, y_pred, '--r')

plt.xticks(())
plt.yticks(())

plt.show()
```

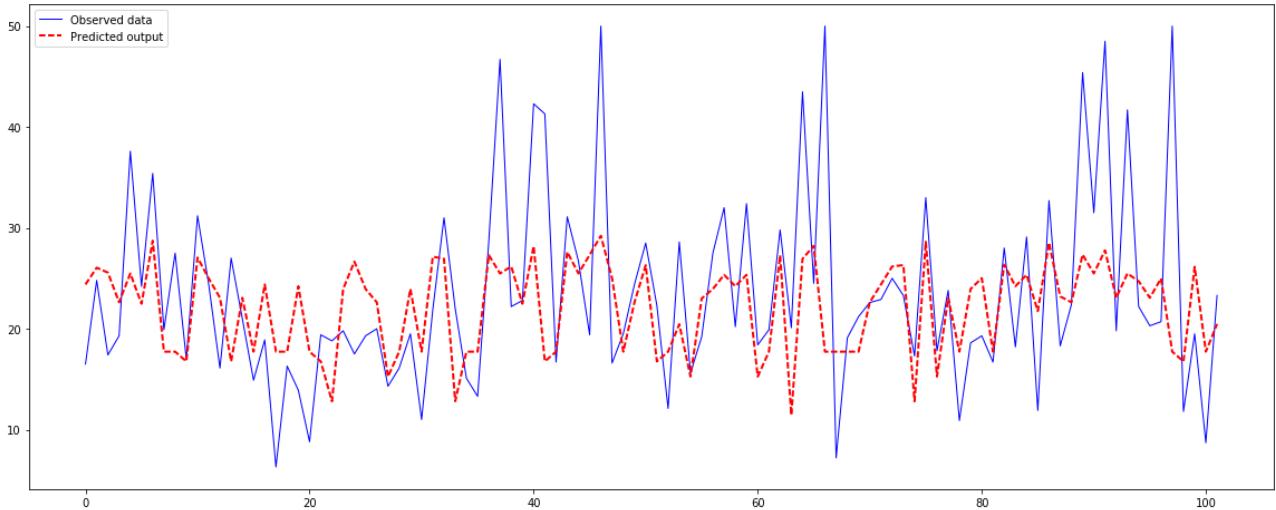


```
import matplotlib.pyplot as plt
```

76 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทยตอน

```
plt.figure(figsize=(20, 8))
plt.plot(y_test, linewidth=1, linestyle='solid', color='blue',
          label='Observed data')
plt.plot(y_pred, '--r', linewidth=2, label='Predicted output')
plt.legend(frameon=True, loc='upper left')

plt.show()
```



```
# The coefficients
print('Coefficients: \n', reg.coef_)
# The mean squared error
print("Mean squared error: %.2f"
      % mean_squared_error(y_test, y_pred))
# Explained variance score: 1 is perfect prediction
print('Variance score: %.2f' % r2_score(y_test, y_pred))

('Coefficients: \n', array([[-0.65143285]]))
Mean squared error: 75.47
Variance score: 0.19
```

## สรุปผลการทดลองด้วยวิธี Liner Regression กับข้อมูลชุด Boston housing

จากการทดลองทั้ง 2 กรณี คือใช้คอลัมน์ RM และ INDUS ประกอบว่า

**RM** มีค่า MSE 25.41 และ Variance score 0.73

**INDUS** มีค่า MSE 75.47 และ Variance score 0.19

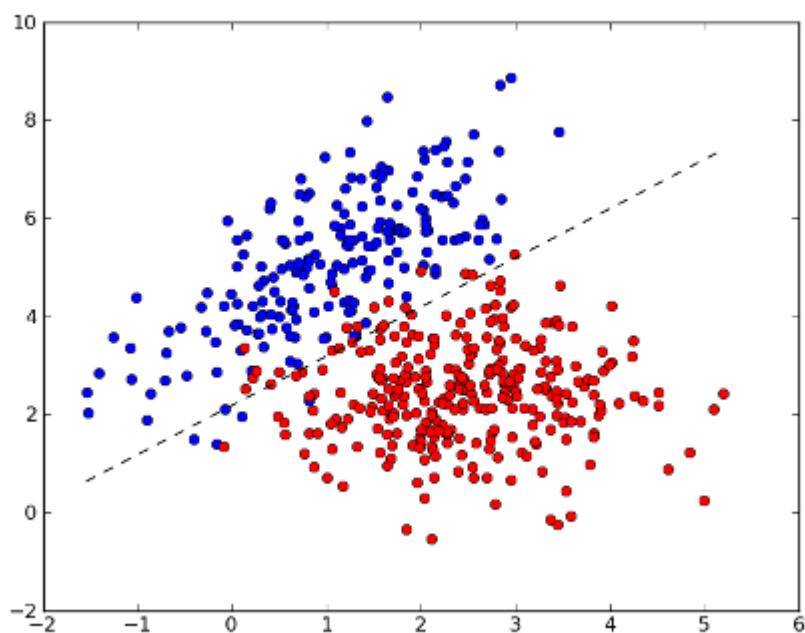
โดยที่ค่า MSE หากเข้าใกล้ 0 จะมีค่า Error น้อยที่สุด และค่า Variance score หากมีค่า เป็น 1 จะเป็นการพยากรณ์ที่แม่นยำที่สุด จึงสรุปได้ว่า หากใช้คอลัมน์ RM และ INDUS ในการ พยากรณ์ข้อมูล Boston housing คอลัมน์ RM มีประสิทธิภาพในการพยากรณ์สูงกว่า ดังนั้น หาก ต้องการนำไปใช้ในการสร้างโมเดล จึงแนะนำให้ใช้คอลัมน์ RM ในการสร้าง ทั้งนี้ อาจจะต้องลอง ทำการสร้างโมเดลด้วยวิธีอื่น เช่น Multiple Linear Regression เพื่อทดสอบประสิทธิภาพต่อไป

**78 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทย**

# บทที่ 7

## ตัวจำแนกแบบไบนารี (Binary Classifier)

ตัวจำแนกแบบไบนารี (Binary Classifier) เป็นวิธีการแบ่งกลุ่มข้อมูลออกเป็นสองกลุ่ม (Binary Class) จากตัวอย่างข้อมูลแบ่งออกเป็นสองกลุ่ม (สีน้ำเงิน และสีแดง) โดยตัวจำแนกแบบไบนารีจะสร้างเส้นสมมุติหรือเรียกว่า hyperplane เพื่อใช้สำหรับการแบ่งกลุ่มข้อมูลทั้งสองกลุ่มออกจากกัน



ภาพประกอบที่ 13: แสดงเส้น Hyperplane ที่ใช้แบ่งข้อมูลออกเป็นสองส่วน

80 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไพธอน

ในการนี้จะทดสอบการจำแนกแบบใบหน้า โดยใช้ข้อมูล MNSIT ในการทดสอบ

```
from scipy.io import loadmat

mnist_raw = loadmat("mldata/mnist-original.mat")
mnist = {
    "data": mnist_raw["data"].T,
    "target": mnist_raw["label"][0],
    "COL_NAMES": ["label", "data"],
    "DESCR": "mldata.org dataset: mnist-original",
}
X, y = mnist['data'], mnist['target']
```

จากตัวอย่างข้างต้น ใช้โปรแกรม scipy ในการโหลดไฟล์นามสกุล .mat ซึ่งบรรจุด้วยชุดข้อมูล MNSIT โดยข้อมูลสามารถดาวน์โหลดได้จาก

<https://github.com/AMPLab/datascience-sp14/blob/master/lab7/mldata/mnist-original.mat>

เมื่อโหลดข้อมูลเสร็จเรียบร้อยสามารถเรียกดูรายละเอียดของข้อมูลได้ดังนี้

```
# 70K images, 28x28 pixels/image, each pixel = 0 (white) to 255 (black)
mnist # a dict object

{'COL_NAMES': ['label', 'data'],
 'DESCR': 'mldata.org dataset: mnist-original',
 'data': array([[0, 0, 0, ..., 0, 0, 0],
               [0, 0, 0, ..., 0, 0, 0],
               [0, 0, 0, ..., 0, 0, 0],
               ...,
               [0, 0, 0, ..., 0, 0, 0],
               [0, 0, 0, ..., 0, 0, 0],
               [0, 0, 0, ..., 0, 0, 0]], dtype=uint8),
 'target': array([0., 0., 0., ..., 9., 9., 9.])}
```

ข้อมูลของตัวเลขจะถูกจัดเก็บอยู่ในรูปแบบของเวกเตอร์ ที่มีขนาด 754 attribute (28x28) ตัวนั้น จึงกำหนดให้ตัวแปร X เก็บข้อมูล Feature และ y เก็บ label ที่มีจำนวนทั้งสิ้น 70,000 ตัว

```
X, y = mnist['data'], mnist['target']
```

```
X.shape, y.shape
```

```
((70000, 784), (70000,))
```

จากนั้นทำการแยกชุดข้อมูลออกเป็น 2 ชุด คือ Training set และ Test set

```
import numpy as np

X_train, X_test, y_train, y_test = X[:60000], X[60000:], \
y[:60000], y[60000:]

shuffle_index = np.random.permutation(60000)
X_train, y_train = X_train[shuffle_index], \
y_train[shuffle_index]

print(X_train.shape, X_test.shape, y_train.shape, \
y_test.shape)

((60000, 784), (10000, 784), (60000,), (10000,))
```

ชุดข้อมูล MNIST ที่โหลดมาได้แบ่งข้อมูลเป็นที่เรียบร้อย โดยข้อมูลชุดที่ 1 – 60000 เป็นชุดเรียนรู้ โดยข้อมูลจะเรียงจาก กลุ่ม (Class) 0 ถึง Class 9 และตั้งแต่ 60001 – 70000 เป็นชุดทดสอบ ข้อมูลจะเรียงลำดับจาก Class 0 ถึง Class 9 เช่นกัน ดังนั้น สามารถใช้คำสั่งต่อไปนี้สำหรับแบ่งข้อมูล

```
X_train, X_test, y_train, y_test = X[:60000], X[60000:], \
y[:60000], y[60000:]
```

## Stochastic Descent

เริ่มต้นด้วยการกำหนดข้อมูลให้เป็น 2 กลุ่ม (Class) โดยตัวอย่างกำหนดให้กลุ่มของตัวเลข 5 มีค่าเป็น True และกลุ่มตัวเลขตั้งแต่ 0-4 และ 6-9 มีค่าเป็น False

```
y_train_5 = (y_train == 5) # create target vectors
y_test_5 = (y_test == 5)

print(y_train_5.shape, y_train_5)
print(y_test_5.shape, y_test_5)

((60000,), array([False, False, False, ..., False, False, False]))
((10000,), array([False, False, False, ..., False, False, False]))
```

## สร้างโมเดล Stochastic Descent

สำหรับ scikit-learn ให้เรียกใช้คำสั่ง SGDClassifier() เพื่อกำหนด hyperparameter ที่จำเป็น และใช้คำสั่ง fit() เพื่อสร้างโมเดล

```
from sklearn.linear_model import SGDClassifier

sgd_clf = SGDClassifier(random_state=42)
sgd_clf.fit(X_train, y_train_5)

SGDClassifier(alpha=0.0001, average=False, class_weight=None, epsilon=0.1,
    eta0=0.0, fit_intercept=True, l1_ratio=0.15,
    learning_rate='optimal', loss='hinge', n_iter=5, n_jobs=1,
    penalty='l2', power_t=0.5, random_state=42, shuffle=True, verbose=0,
    warm_start=False)
```

## การพยากรณ์ด้วยโมเดล Stochastic Descent

สำหรับโปรแกรม scikit-learn สามารถใช้คำสั่ง predict() สำหรับการพยากรณ์ข้อมูลในกรณีได้สร้างฟังก์ชัน (Function) ในภาษา Python สามารถประมวลผลฟังก์ชันด้วยคำสั่ง def ประกอบด้วย plot\_digit() และ pred\_data() เพื่อให้เรียกใช้งานได้อย่างสะดวก

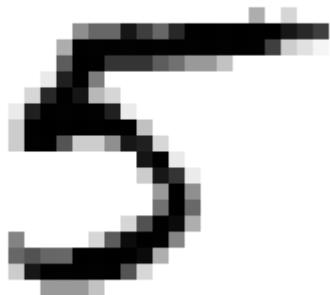
```
def plot_digit(X):
    plt.imshow(
        X.reshape(28, 28),
        cmap = plt.cm.binary,
        interpolation="nearest")

    plt.axis("off")
    plt.show()

def print_pred_data(clf, actual_y, X):
    print("Actual : ", actual_y)
    print("Prediction : ", clf.predict([X])[0])
```

ดังนั้น การพยากรณ์ข้อมูลตัวเลข และแสดงรูปภาพของตัวเลขแบบ Visualization สามารถทำได้ดังต่อไปนี้

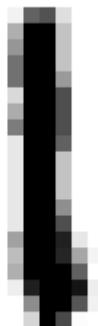
```
pred_digit = 5500
plot_digit(X_test[pred_digit])
print_pred_data(sgd_clf, y_test_5[pred_digit], \
                X_test[pred_digit])
```



```
('Actual : ', True)
('Prediction : ', True)
```

จากตัวอย่างข้างต้น ได้พยากรณ์ข้อมูลในชุดทดสอบลำดับที่ 5500 ( $X_{\text{test}}[5500]$ ) ซึ่ง Class ที่แท้จริง (Actual Class) คือ True (ตัวเลข 5) และผลการพยากรณ์ (Prediction Class) ได้คำตอบคือ True นั่นแสดงว่าเป็นการพยากรณ์ที่ถูกต้อง

```
pred_digit = 1000
plot_digit(X_test[pred_digit])
print_pred_data(sgd_clf, y_test_5[pred_digit], \
                X_test[pred_digit])
```



```
('Actual : ', False)
('Prediction : ', False)
```

## การวัดประสิทธิภาพ (Performance Measurement)

สำหรับการวัดประสิทธิภาพสามารถทำได้หลายวิธี ในตัวอย่างนี้จะใช้คำสั่ง cross\_val\_score() เพื่อทดสอบและวัดประสิทธิภาพของอัลกอริธึม Stochastic Descent และดังตัวอย่างต่อไปนี้

```
from sklearn.model_selection import cross_val_score
print(cross_val_score(
    sgd_clf,
    X_train,
    y_train_5,
    cv=3,
    scoring="accuracy"))
[0.9617  0.96315  0.95905]
```

ตัวอย่างข้างต้นใช้คำสั่ง cross\_val\_score() ในการวัดประสิทธิภาพ โดยค่ามาตรฐาน (Default) ของคำสั่งสำหรับการวัดค่าความถูกต้องได้กำหนดให้ k-fold มีค่าเท่ากับ 3 (cross validation: cv=3) ดังนั้น ผลลัพธ์ที่ได้ก็คือ 0.9617, 0.96315 และ 0.95905 โดยเป็นผลลัพธ์ของการทดลองครั้งที่ 1, 2 และ 3 ตามลำดับ

## การประเมินประสิทธิภาพของอัลกอริธึมด้วย Confusion Matrix

การประเมินประสิทธิภาพของอัลกอริธึมด้วย Confusion Matrix เป็นวิธีที่แสดงให้เห็นถึงผลลัพธ์จากการพยากรณ์ และทำให้รู้ได้ว่าหากผลลัพธ์ผิดพลาด ผิดพลาด ณ จุดใด การทำ Confusion Matrix ใน scikit-learn ใช้คำสั่ง confusion\_matrix() สามารถเรียกใช้ได้ดังต่อไปนี้

```
from sklearn.metrics import confusion_matrix
```

ในการนี้ได้สร้างฟังก์ชันเพื่อใช้สำหรับการแสดงผลของ Confusion Matrix แบบ Visualization โดยสร้างฟังก์ชันชื่อ `plot_confusion_matrix()` และดังต่อไปนี้

```
import matplotlib.pyplot as plt
import itertools

def plot_confusion_matrix(cm, classes,
                         title='Confusion matrix',
                         cmap=plt.cm.Blues):

    plt.imshow(cm, interpolation='nearest', cmap=cmap)
    plt.title(title)
    plt.colorbar()
    tick_marks = np.arange(len(classes))
    plt.xticks(tick_marks, classes, rotation=45)
    plt.yticks(tick_marks, classes)

    thresh = cm.max() / 2.
    for i, j in itertools.product(range(cm.shape[0]), \
                                   range(cm.shape[1])):
        plt.text(j, i, format(cm[i, j], 'd'),
                  horizontalalignment='center',
                  color='white' if cm[i, j] > thresh else 'black')

    plt.tight_layout()
    plt.ylabel('True label')
    plt.xlabel('Predicted label')
```

ในการนี้ได้ทดสอบโมเดลของ Stochastic Descent อีกครั้งโดยใช้คำสั่ง `cross_val_predict()` วิธีการทดสอบ และดังต่อไปนี้

```
from sklearn.model_selection import cross_val_predict
y_train_pred = cross_val_predict(sgd_clf, X_train, \
                                 y_train_5, cv=3)
```

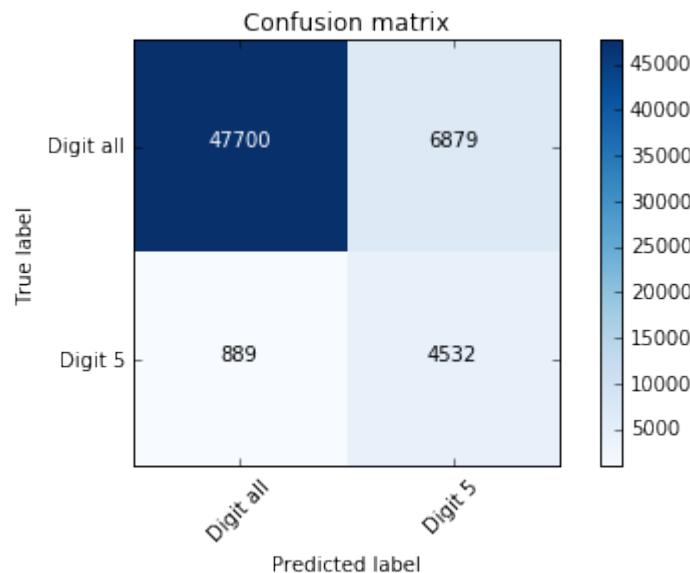
จากตัวอย่าง ทดสอบโดยใช้ชื่อมูลคุณทดสอบ (Train) เมื่อเสร็จสิ้นการทดสอบผลลัพธ์ที่ได้จากการพยากรณ์จะถูกจัดเก็บที่ตัวแปร `y_train_pred` จากนั้นจึงนำผลลัพธ์จากการพยากรณ์ (Prediction Class) `y_train_pred` และผลลัพธ์ที่แท้จริง (Actual Class) ไปคำนวณเพื่อหา Confusion Matrix ดังตัวอย่างต่อไปนี้

```
from sklearn.metrics import confusion_matrix

cm = confusion_matrix(y_train_5, y_train_pred)
print(cm)

plt.figure()
classes = ['Digit all', 'Digit 5']
plot_confusion_matrix(cm, classes)
```

```
[[47700  6879]
 [ 889  4532]]
```



จากผลลัพธ์ข้างต้น แบ่งออกเป็น 2 แคลา และ 2 คอลัมน์ เนื่องจากมีทั้งสิ้น 2 กลุ่ม ข้อมูลที่แสดงในแนวแคลา แสดงถึงกลุ่มที่ถูกต้อง (True label) และข้อมูลที่แสดงในแนวคอลัมน์ แสดงถึงผลลัพธ์จากการพยากรณ์ ตัวอย่าง เช่น ในแคลาข้อมูลชุด Digit all มีการพยากรณ์ถูกต้องจำนวน 47700 และพยากรณ์ผิดเป็น Digit 5 อยู่จำนวน 6879 ตัวเลข และในแคลาข้อมูลชุด Digit 5 มีการพยากรณ์ถูกต้องจำนวน 4532 และพยากรณ์ผิดเป็น Digit all จำนวน 889 ตัวเลข

จากนี้นั่นจึงนำผลลัพธ์ที่ได้ y\_train\_pred ไปคำนวณร่วมกับ y\_train\_5 เพื่อคำนวณหาค่า Precision, Recall และ F1 ดังต่อไปนี้

```
from sklearn.metrics import precision_score, recall_score, \
                           f1_score

print("precision:",precision_score(y_train_5, y_train_pred))
print("recall:",recall_score(y_train_5, y_train_pred))
print("f1:",f1_score(y_train_5, y_train_pred))

('precision:', 0.3971606344755061)
('recall:', 0.8360081165836561)
('f1:', 0.5384980988593155)
```

สำหรับการทดสอบโดยใช้ Training set นั้นจะเป็นการทดสอบเพื่อปรับค่าพารามิเตอร์ (Tuning Parameter) ให้เหมาะสมกับชุดข้อมูล และเพื่อให้มีประสิทธิภาพสูงสุด จากนั้นจึงนำไปทดลองที่ได้ไปทดสอบกับชุดข้อมูลชุด Test set หรือนำไปใช้งานจริงต่อไป

## การนำโมเดลไปทดสอบกับข้อมูลชุดทดสอบ

จากตัวอย่างก่อนหน้านี้ ใช้คำสั่ง precision\_score, recall\_score และ f1\_score เพื่อแสดงผลลัพธ์ ทั้งนี้ สามารถใช้คำสั่ง classification\_report() เพื่อแสดงผลลัพธ์ได้เช่นเดียวกัน แสดงดังตัวอย่างต่อไปนี้

```
from sklearn.metrics import classification_report

y_test_pred = sgd_clf.predict(x_test)

classes = ['Digit all', 'Digit 5']
print(classification_report(y_test_5, y_test_pred, \
                            target_names=classes))
```

|             | precision | recall | f1-score | support |
|-------------|-----------|--------|----------|---------|
| Digit all   | 0.99      | 0.98   | 0.98     | 9108    |
| Digit 5     | 0.80      | 0.85   | 0.83     | 892     |
| avg / total | 0.97      | 0.97   | 0.97     | 10000   |

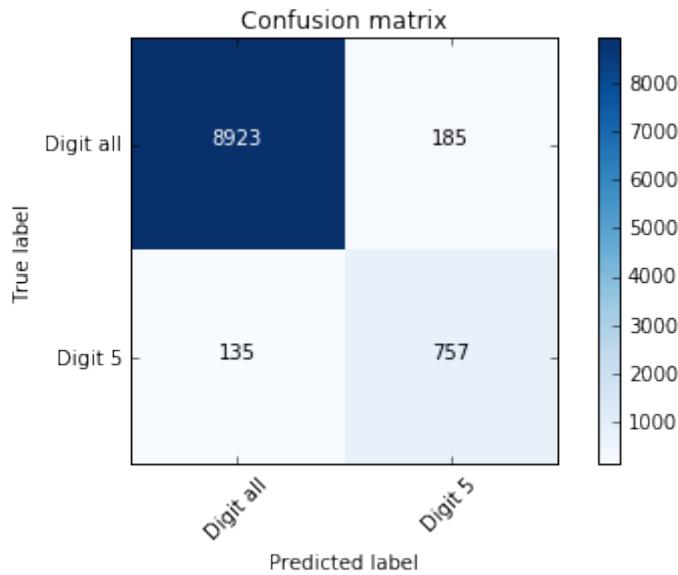
จากนั้นใช้เรียกใช้ฟังก์ชัน plot\_confusion\_matrix() เพื่อทำการ Visualization ข้อมูล

```
from sklearn.metrics import confusion_matrix

cm = confusion_matrix(y_test_5, y_test_pred)
print(cm)

plt.figure()
classes = ['Digit all', 'Digit 5']
plot_confusion_matrix(cm, classes)

[[8923  185]
 [ 135  757]]
```



เมื่อได้ทำการพยากรณ์ Test set จากนั้นจึงตรวจสอบประสิทธิภาพของอัลกอริธึมโดยใช้คำสั่ง accuracy\_score() ดังตัวอย่างต่อไปนี้

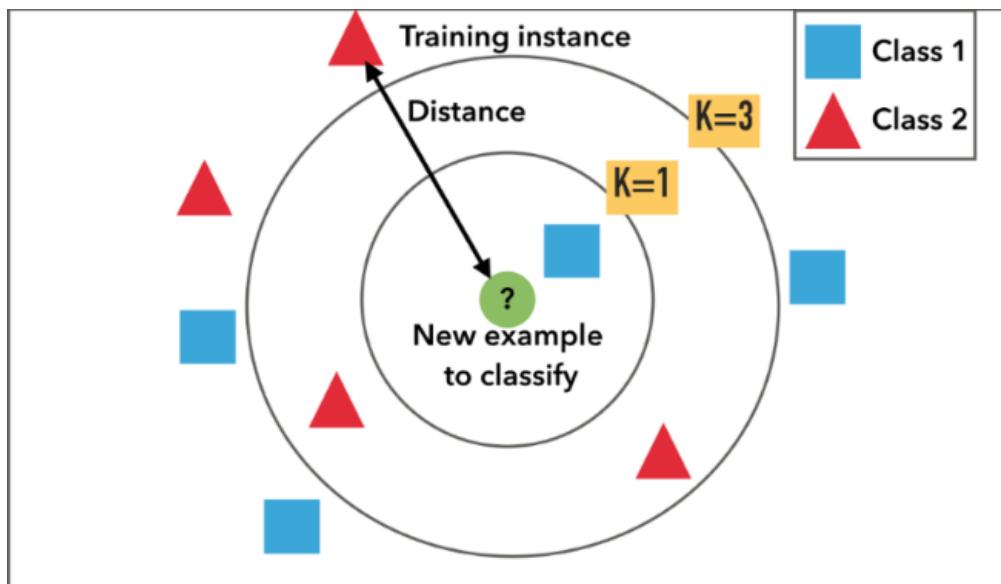
```
from sklearn.metrics import accuracy_score  
  
print("Accuracy Score", accuracy_score(y_test_5, \  
                                         y_test_pred)*100)  
  
('Accuracy Score', 96.8)
```

ผลลัพธ์ที่ได้จากการพยากรณ์ด้วยอัลกอริธึม Stochastic Descent มีความถูกต้อง (Accuracy Score/ Accuracy Result) 96.8%

# บทที่ 8

## การคำนวณเพื่อนบ้านใกล้ที่สุด k ตำแหน่ง (K-Nearest Neighbors)

การคำนวณเพื่อนบ้านใกล้ที่สุด k ตำแหน่ง (K-Nearest Neighbors) เป็นวิธีการเรียนรู้เครื่องจักรที่ใช้สำหรับจัดหมวดหมู่ข้อมูล (Classification) และเป็นวิธีที่ไม่ซ้ำซ้อน



ภาพประกอบที่ 14: แสดงลักษณะการทำงานของอัลกอริธึม KNN

อัลกอริธึมจะทำการเปรียบเทียบจุดใหม่ (New point) กับจุด (Point) ทั้งหมดที่อยู่ใน Training set เพื่อหาจุดที่ใกล้เคียงกับจุดใหม่ที่สุด โดยกำหนดจำนวนจุดที่ใกล้เคียงกับจุดใหม่จำนวน K จุด เช่น หากกำหนดให้ K=3 ดังนั้น จุดที่ใกล้เคียงกับจุดใหม่ทั้งสิ้นจำนวน 3 จุดจะถูกนำมาพิจารณา จากนั้นทำการกำหนด Label/Class ให้กับจุดใหม่ โดยตรวจสอบกับ Label ของทั้ง 3 จุด หากพบว่ามี Label ใหม่มากที่สุด (Majority Vote) ก็จะกำหนดเป็น Label ให้กับจุดใหม่นั้น

## จากตัวอย่าง

หากกำหนดให้  $K=1$  จุดที่ใกล้กับจุดใหม่ที่สุดคือ Class สีเหลือง ดังนั้น จุดใหม่นั้นจะถูกกำหนดให้มี Class เป็น สีเหลือง

หากกำหนดให้  $K=3$  จุดที่ใกล้กับจุดใหม่ที่สุดสามลำดับคือ Class สีเหลือง 1 จุด และ สีเหลือง 2 จุด ดังนั้นจุดใหม่จะถูกกำหนดให้มี Class เป็น สีเหลือง

## การสร้างโมเดลของ KNN

ตัวอย่างดังต่อไปนี้ทำการสร้างโมเดลของอัลกอริธึม KNN โดยใช้ชุดข้อมูล Iris ในการทดสอบ

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split

iris_dataset = load_iris()
X_train, X_test, y_train, y_test =
train_test_split(iris_dataset['data'], \
                  iris_dataset['target'], \
                  random_state=0)
```

จากตัวอย่างข้างต้น ทำการโหลดชุดข้อมูล Iris มาเพื่อทดสอบ โดยใช้คำสั่ง `load_iris()` จากนั้นใช้คำสั่ง `train_test_split()` เพื่อแบ่งข้อมูลออกเป็น 2 ชุด โดยข้อมูล Feature/Attribute ที่แบ่งแล้วจะถูกจัดเก็บไว้ที่ตัวแปร `X_train` และ `X_test` และข้อมูล Label/Class จะถูกเก็บไว้ที่ตัวแปร `y_train` และ `y_test`

จากนั้นใช้คำสั่ง `KNeighborsClassifier()` เพื่อกำหนดค่าพารามิเตอร์ `n_neighbors` หากไม่กำหนดค่าโปรแกรมจะใช้ค่าเริ่มต้น (Default) ซึ่งกำหนดให้มีค่าเท่ากับ 5

```
from sklearn.neighbors import KNeighborsClassifier
knn = KNeighborsClassifier(n_neighbors=1)
```

จากตัวอย่างข้างต้นได้กำหนดให้ `n_neighbors=1` โดยเก็บค่าที่กำหนดไว้ที่ตัวแปร `knn` จากนั้นทำการสร้างโมเดลโดยใช้คำสั่ง `fit()` ดังตัวอย่างต่อไปนี้

```
knn.fit(X_train, y_train)

KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                     metric_params=None, n_jobs=1, n_neighbors=1, p=2,
                     weights='uniform')
```

## การพยากรณ์โดยใช้โมเดลของ KNN

ในชุดข้อมูล Iris นั้นจะมี Label อ yogurt จำนวน 3 กลุ่ม ประกอบด้วย

|            |         |
|------------|---------|
| setosa     | กลุ่ม 0 |
| versicolor | กลุ่ม 1 |
| virginica  | กลุ่ม 2 |

ตั้งนี้ Label นี้จะใช้เป็นตัวตรวจสอบความถูกต้องของการพยากรณ์

```
print("Test data: {}".format(X_test[1]))
print("Label: {}".format(y_test[1]))
```

Test data: [6. 2.2 4. 1. ]

Label: 1

ตัวอย่างข้างต้นแสดงให้เห็นข้อมูลที่จะนำไปทดสอบ (Test) การพยากรณ์ด้วยโมเดลของ KNN

```
prediction = knn.predict([X_test[1]])
print("Prediction: {}".format(prediction))
print("Predicted target name: {}".format(
    iris_dataset['target_names'][prediction]))
```

Prediction: [1]

Predicted target name: ['versicolor']

สำหรับการพยากรณ์จะใช้คำสั่ง predict() จากตัวอย่างได้ส่งข้อมูล X\_test[1] เข้าไป คำนวณ และผลลัพธ์ที่ได้จะจัดเก็บไว้ที่ตัวแปร prediction จากการทดลองพบว่า เมื่อส่งข้อมูล X\_test[1] เข้าไปทดสอบ ผลลัพธ์ที่ได้คือ Prediction: [1] คือกลุ่ม 1 ซึ่งกลุ่ม 1 ก็คือ versicolor ซึ่งเป็นคำตอบที่ถูกต้อง

ทำการทดสอบข้อมูล x\_test[2] เพื่อตรวจสอบความถูกต้อง

```
prediction = knn.predict([X_test[2]])
print("Prediction: {}".format(prediction))
print("Predicted target name: {}".format(
    iris_dataset['target_names'][prediction]))
```

Prediction: [0]

Predicted target name: ['setosa']

จากการทดสอบผลลัพธ์ที่ได้คือกลุ่ม 0 ซึ่งก็คือกลุ่ม setosa

## การทดสอบประสิทธิภาพของโมเดล KNN

การแสดงผลลัพธ์ของการจัดกลุ่มข้อมูล (Classification Report) สามารถทำได้ดังต่อไปนี้

```
from sklearn.metrics import classification_report

print(classification_report(y_test, y_pred,
target_names=iris_dataset['target_names']))

precision    recall   f1-score   support

setosa      1.00      1.00      1.00       13
versicolor  1.00      0.94      0.97       16
virginica   0.90      1.00      0.95        9

avg / total  0.98      0.97      0.97       38
```

```
from sklearn.metrics import accuracy_score

accuracy_score(y_test, y_pred)
```

0.9736842105263158

ในการแสดงผลลัพธ์จากการทดลองในโปรแกรม scikit-learn สามารถทำได้โดยใช้คำสั่ง `classification_report()` และ `accuracy_score()` เป็นต้น จากการทดสอบโมเดลของ KNN มีประสิทธิภาพที่ 97.37%

## การแสดงผลการทดลองด้วย Confusion Matrix

```
from sklearn.metrics import confusion_matrix

print("Confusion Matrix: \n{}".format(confusion_matrix( \
y_test, y_pred)))

Confusion Matrix:
[[13  0  0]
 [ 0 15  1]
 [ 0  0  9]]
```

ในการแสดงผล Confusion Matrix ให้อยู่ในรูปแบบของการ Visualization สามารถทำได้โดยการสร้างฟังก์ชัน `plot_confusion_matrix()` ดังตัวอย่างต่อไปนี้

```
import matplotlib.pyplot as plt
import itertools

def plot_confusion_matrix(cm, classes,
                         title='Confusion matrix',
                         cmap=plt.cm.Blues):

    plt.imshow(cm, interpolation='nearest', cmap=cmap)
    plt.title(title)
    plt.colorbar()
    tick_marks = np.arange(len(classes))
    plt.xticks(tick_marks, classes, rotation=45)
    plt.yticks(tick_marks, classes)

    thresh = cm.max() / 2.
    for i, j in itertools.product(range(cm.shape[0]), \
                                   range(cm.shape[1])):
        plt.text(j, i, format(cm[i, j], 'd'),
                  horizontalalignment='center',
                  color='white' if cm[i, j] > thresh else 'black')

    plt.tight_layout()
    plt.ylabel('True label')
    plt.xlabel('Predicted label')
```

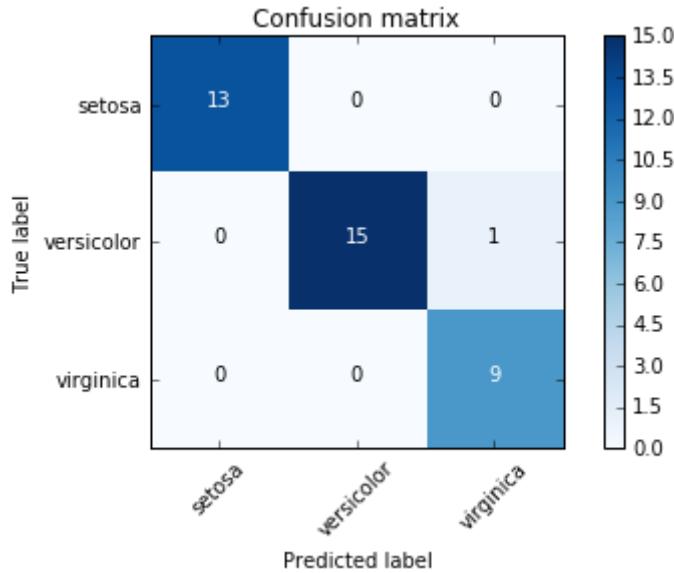
ในการคำนวณหาค่า Confusion Matrix สามารถใช้คำสั่ง `confusion_matrix()` ดังตัวอย่างต่อไปนี้

```
cm = confusion_matrix(y_test, y_pred)
np.set_printoptions(precision=2)

print('Confusion matrix, without normalization')
print(cm)

plt.figure()
classes = iris_dataset.target_names
plot_confusion_matrix(cm, classes)

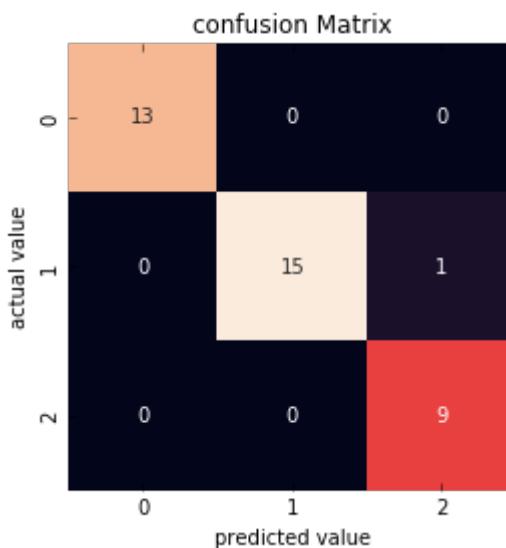
Confusion matrix, without normalization
[[13  0  0]
 [ 0 15  1]
 [ 0  0  9]]
```



ในการแสดง Confusion Matrix นอกจากจะใช้โปรแกรม matplotlib ยังสามารถใช้โปรแกรม Seaborn เป็นอีกหนึ่งทางเลือก แสดงดังต่อไปนี้

```
import seaborn as sns

sns.heatmap(cm, square=True, annot=True, cbar=False)
plt.title('confusion Matrix')
plt.xlabel('predicted value')
plt.ylabel('actual value')
plt.show()
```



ตัวอย่าง Classification Score และ Confusion Matrix ข้างต้นได้มาจากการกำหนดให้ `n_neighbors = 1` เพื่อทดสอบประสิทธิภาพ สามารถกำหนดจำนวนของ `n_neighbors` ให้เป็น 3, 5 หรือ 7 เป็นต้น

## การใช้งานอัลกอริธึม KNN กับข้อมูลโรคเบาหวาน (Diabetes Dataset)

ตัวอย่างต่อไปจะนำอัลกอริธึม KNN มาช่วยในการพยากรณ์ข้อมูลโรคเบาหวาน (Diabetes) ว่าผู้ป่วย (patient) เป็นโรคเบาหวาน หรือไม่ ข้อมูลโรคเบาหวานสามารถดาวน์โหลดได้จากเว็บไซต์

<https://www.kaggle.com/amolbhivarkar/knn-for-classification-using-scikit-learn/data>

ตัวอย่างการนำอัลกอริธึม KNN ไปใช้พยากรณ์ข้อมูลผู้ป่วยโรคเบาหวาน สามารถทำได้ดังต่อไปนี้

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

plt.style.use('ggplot')

df = pd.read_csv('mldata/diabetes.csv')
df.head()
```

จากตัวอย่างข้างต้น ไฟล์ที่ดาวน์โหลดจากเว็บไซต์อยู่ในรูปแบบของ csv จึงใช้โปรแกรม pandas เพื่อโหลดข้อมูลและแปลงให้อยู่ในรูปแบบของ DataFrame โดยเก็บไว้ที่ตัวแปร df หากต้องการแสดงข้อมูลโรคเบาหวานสามารถทำได้โดยพิมพ์คำสั่ง head()

|   | Pregnancies | Glucose | BloodPressure | SkinThickness | Insulin | BMI  | DiabetesPedigreeFunction | Age | Outcome |
|---|-------------|---------|---------------|---------------|---------|------|--------------------------|-----|---------|
| 0 | 6           | 148     | 72            | 35            | 0       | 33.6 | 0.627                    | 50  | 1       |
| 1 | 1           | 85      | 66            | 29            | 0       | 26.6 | 0.351                    | 31  | 0       |
| 2 | 8           | 183     | 64            | 0             | 0       | 23.3 | 0.672                    | 32  | 1       |
| 3 | 1           | 89      | 66            | 23            | 94      | 28.1 | 0.167                    | 21  | 0       |
| 4 | 0           | 137     | 40            | 35            | 168     | 43.1 | 2.288                    | 33  | 1       |

ข้อมูลโรคเบาหวานประกอบด้วย 8 Attribute และผลลัพธ์ที่ได้มีค่าเป็น 0 หรือ 1 ซึ่งอยู่ใน Attribute ที่ชื่อ Outcome ซึ่งก็คือ Output/Label/Class และหากต้องการที่จะทราบจำนวนของข้อมูลสามารถทำได้โดยใช้คำสั่ง shape

`df.shape`

(768, 9)

ข้อมูลโรคเบาหวานที่ใช้ในการทดลองประกอบด้วย 768 instance แต่ละ instance มีจำนวน 8 attribute และอีก 1 attribute เป็นผลลัพธ์

กำหนดข้อมูลที่จะนำไปใช้ในอัลกอริธึม KNN สามารถทำได้โดย

```
from sklearn.model_selection import train_test_split

X = df.drop('Outcome', axis=1).values
y = df['Outcome'].values
X_train, X_test, y_train, y_test =
train_test_split(X, y, test_size=0.4, \
random_state=42, stratify=y)
```

จากตัวอย่างข้อมูลที่เป็น Feature จะถูกเก็บไว้ที่ตัวแปร X และข้อมูลของ Class จะถูกเก็บไว้ที่ตัวแปร y จากนั้นใช้คำสั่ง train\_test\_split() เพื่อแบ่งข้อมูลเป็นชุดเรียนรู้ และชุดทดสอบ โดยกำหนดให้ขนาดของชุดทดสอบมีขนาดเป็น 40% โดยการกำหนด test\_size=0.4

```
from sklearn.neighbors import KNeighborsClassifier

neighbors = np.arange(1,9)
train_accuracy = np.empty(len(neighbors))
test_accuracy = np.empty(len(neighbors))

for i,k in enumerate(neighbors):
    #Setup a knn classifier with k neighbors
    knn = KNeighborsClassifier(n_neighbors=k)

    #Fit the model
    knn.fit(X_train, y_train)

    #Compute accuracy on the training set
    train_accuracy[i] = knn.score(X_train, y_train)

    #Compute accuracy on the test set
    test_accuracy[i] = knn.score(X_test, y_test)
```

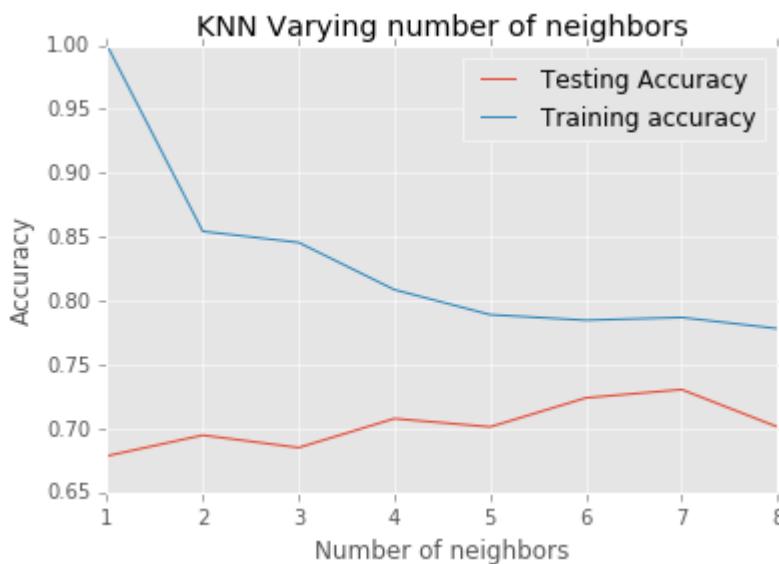
จากตัวอย่างจะทำการทดสอบประสิทธิภาพของอัลกอริธึมโดยกำหนดจำนวนของ n\_neighbors โดยใช้คำสั่ง neighbors = np.arange(1,9) ซึ่งผลลัพธ์ที่ได้จากการคำนวณคือ array([1, 2, 3, 4, 5, 6, 7, 8])

โปรแกรมจะทดสอบทั้งสิ้นจำนวน 8 รอบ และเก็บผลลัพธ์ไว้ที่ตัวแปร train\_accuracy และ test\_accuracy เพื่อใช้ในการแสดงผลลัพธ์

```

plt.title('KNN Varying number of neighbors')
plt.plot(neighbors, test_accuracy, label='Testing Accuracy')
plt.plot(neighbors, train_accuracy, label='Training accuracy')
plt.legend()
plt.xlabel('Number of neighbors')
plt.ylabel('Accuracy')
plt.show()

```



ภาพประกอบที่ 15: กราฟแสดงประสิทธิภาพของอัลกอริธึม KNN เมื่อเปลี่ยนค่าพารามิเตอร์  $n_{neighbors}$

จากราฟข้างต้น ประกอบด้วยข้อมูลจำนวน 2 เส้น เส้นสีแดง แทน Testing Accuracy และเส้นสีน้ำเงินแทน Training Accuracy จะเห็นความแตกต่างระหว่างการทดสอบกับ Training set และ Test set ดังนี้ ในการ Training ยังกำหนดให้จำนวน  $n_{neighbors}$  มากเท่าไหร่ผลที่ได้จากการทดลองจะต่ำลงโดยกำหนดให้  $n_{neighbors}=2$  จะมีประสิทธิภาพสูงที่สุด ในทางกลับกัน เมื่อทดสอบกับ Test set จำนวนของ  $n_{neighbors}$  ที่ให้ประสิทธิภาพสูงที่สุดมีค่าเท่ากับ 7 ดังนั้น การกำหนดค่าพารามิเตอร์  $n_{neighbors}$  จึงมีอยู่กับข้อมูลที่นำมาใช้

## สร้างโมเดล KNN ด้วยค่า $n_{neighbor}$ ที่ได้จากการทดลอง

จากการทดสอบทำให้ได้ค่า  $n_{neighbor}=7$  ซึ่งเป็นค่าที่ดีที่สุดในการทดสอบกับ Test set ดังนั้น หากต้องการทราบประสิทธิภาพของอัลกอริธึม KNN จึงต้องทดสอบโดยการสร้างโมเดลอีกครั้ง ดังตัวอย่างต่อไปนี้

```

knn = KNeighborsClassifier(n_neighbors=7)
knn.fit(X_train,y_train)

```

```

KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
metric_params=None, n_jobs=1, n_neighbors=7, p=2,
weights='uniform')

```

จากนั้นใช้คำสั่ง score() เพื่อแสดงค่าความถูกต้อง (Accuracy) ซึ่งผลลัพธ์ที่ได้คือ 73.05%

```
print("Accuracy", knn.score(X_test,y_test)*100)  
('Accuracy', 73.05194805194806)
```

หากต้องการแสดงผลการทดสอบด้วย Confusion Matrix สามารถทำได้ดังนี้

```
from sklearn.metrics import confusion_matrix  
  
y_pred = knn.predict(X_test)  
confusion_matrix(y_test,y_pred)  
  
array([[165, 36],  
       [ 47,  60]])
```

## คำสั่ง Pandas Crosstab

ในโปรแกรม Pandas สามารถใช้คำสั่ง crosstab() เพื่อสร้าง Confusion Matrix ได้ เช่นเดียวกัน สามารถทำได้ดังตัวอย่างต่อไปนี้

```
pd.crosstab(y_test, y_pred, rownames=['True'], colnames=['Predicted'], margins=True)
```

| Predicted | 0   | 1  | All |
|-----------|-----|----|-----|
| True      |     |    |     |
| 0         | 165 | 36 | 201 |
| 1         | 47  | 60 | 107 |
| All       | 212 | 96 | 308 |

## แสดงผลลัพธ์จากการทดสอบด้วย Classification Report

```
from sklearn.metrics import classification_report  
  
print(classification_report(y_test,y_pred))  
  
precision    recall   f1-score    support  
  
      0          0.78      0.82      0.80      201  
      1          0.62      0.56      0.59      107  
  
avg / total     0.73      0.73      0.73      308
```

## การทดสอบค่าพารามิเตอร์ (Hyperparameter Tuning) ด้วยวิธี Grid Search

จากการทดสอบข้างต้นทำให้ได้ค่า n\_neighbors=7 แต่การทดสอบสามารถทำได้หลายวิธี เช่นวิธี Grid Search เป็นต้น วิธีการทำ Grid Search สามารถทำได้ดังนี้

```
from sklearn.model_selection import GridSearchCV
import numpy as np

param_grid = {'n_neighbors':np.arange(1,50,2)}
```

ผลลัพธ์ที่ได้จากคำสั่ง np.arange(1,50,2) แสดงดังต่อไปนี้

```
array([ 1,  3,  5,  7,  9, 11, 13, 15, 17, 19, 21, 23, 25, 27, 29, 31, 33, 35,
       37, 39, 41, 43, 45, 47, 49])
```

```
knn = KNeighborsClassifier()
knn_cv= GridSearchCV(knn,param_grid,cv=5)
knn_cv.fit(X,y)
```

```
GridSearchCV(cv=5, error_score='raise',
            estimator=KNeighborsClassifier(algorithm='auto', leaf_size=30,
                                           metric='minkowski',
                                           metric_params=None, n_jobs=1, n_neighbors=5, p=2,
                                           weights='uniform'),
            fit_params={}, iid=True, n_jobs=1,
            param_grid={'n_neighbors': array([ 1,  3,  5,  7,  9, 11, 13, 15, 17, 19,
                                              21, 23, 25, 27, 29, 31, 33, 35, 37, 39, 41, 43, 45, 47, 49])},
            pre_dispatch='2*n_jobs', refit=True, return_train_score=True,
            scoring=None, verbose=0)
```

เมื่อกระบวนการของการทำ Grid Search เสร็จแล้วสามารถใช้คำสั่งดังต่อไปนี้เพื่อแสดงผลลัพธ์

```
knn_cv.best_score_
```

```
0.7552083333333334
```

```
knn_cv.best_params_
```

```
{'n_neighbors': 13}
```

ผลลัพธ์ที่ได้คือเมื่อกำหนดให้พารามิเตอร์ n\_neighbors=13 จะมีความถูกต้องที่ 75.52%

## การจัดหมวดหมู่ชุดข้อมูล MNIST ด้วยอัลกอริธึม KNN

ตัวอย่างต่อไปนี้ เป็นการใช้อัลกอริธึม KNN เพื่อจัดหมวดหมู่ชุดข้อมูล MNIST โดยใช้โปรแกรม scipy ในการโหลดข้อมูล

```
from scipy.io import loadmat

mnist_raw = loadmat("mldata/mnist-original.mat")
mnist = {
    "data": mnist_raw["data"].T,
    "target": mnist_raw["label"][0],
    "COL_NAMES": ["label", "data"],
    "DESCR": "mldata.org dataset: mnist-original",
}

X, y = mnist['data'], mnist['target']
```

จากตัวอย่างข้างต้นใช้คำสั่ง loadmat() ในการโหลดข้อมูลนามสกุล .mat และเก็บข้อมูลไว้ที่ตัวแปร X และ Label ไว้ที่ตัวแปร y ในกรณีนี้จะทำการสลับข้อมูล (shuffle) เพื่อให้ข้อมูลที่จะนำมา Visualization มีความหลากหลาย

```
import numpy as np

shuffle_index = np.random.permutation(70000)
X, y = X[shuffle_index], y[shuffle_index]
```

จากตัวอย่างทำการสลับข้อมูลทั้งหมด 70,000 ชุด ด้วยคำสั่ง permutation() โปรแกรมจะสลับและคืนค่าตำแหน่ง (index) เก็บไว้ในตัวแปร shuffle\_index

```
X_train, X_test, y_train, y_test = X[:20000], X[69000:],  
y[:20000], y[69000:]  
  
print(X_train.shape, X_test.shape, y_train.shape,  
      y_test.shape)  
(20000, 784), (1000, 784), (20000,), (1000,))
```

จากนั้น เลือกข้อมูลเพื่อใช้ในการเรียนรู้ (X\_train) จำนวน 20,000 ชุด (x[:20000]) และเลือกข้อมูลเพื่อใช้ในการทดสอบ (X\_test) จำนวน 1,000 ชุด (x[69000:]) โดยรูปภาพตัวเลขมีขนาด 28x28 จึงทำให้ Feature ที่ใช้มีทั้งสิ้น 784 attribute

ในความเป็นจริงข้อมูล mnist-originl.mat จะกำหนดให้ข้อมูลชุดที่ 1-60000 ใช้สำหรับเรียนรู้ และชุดที่ 60001-70000 ใช้สำหรับทดสอบ

## KNN Classifier

ในขั้นตอนนี้ ทำการเลือกใช้โมเดล KNN เพื่อทดสอบกับชุดข้อมูล MNIST โดยมีข้อมูลสำหรับเรียนรู้จำนวน 20,000 instance และ ข้อมูลสำหรับทดสอบจำนวน 1,000 instance การเลือกโมเดล KNN และกำหนดพารามิเตอร์ n\_neighbors=1 ทำได้ดังต่อไปนี้

```
from sklearn.neighbors import KNeighborsClassifier
knn = KNeighborsClassifier(n_neighbors=1)
knn.fit(X_train, y_train)

KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                     metric_params=None, n_jobs=1, n_neighbors=1, p=2,
                     weights='uniform')
```

จากนั้นจึงสร้างโมเดลด้วยคำสั่ง fit() โมเดลที่สร้างจะถูกเก็บไว้ในตัวแปรที่ชื่อ knn

```
from sklearn.metrics import accuracy_score
y_model = knn.predict(X_test)
accuracy_score(y_test, y_model)
```

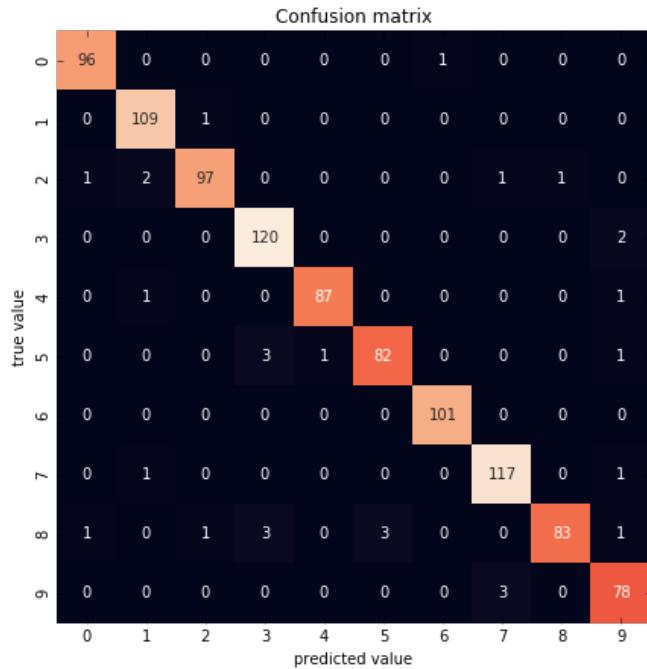
0.97

จากตัวอย่างข้างต้น นำโมเดล knn ไปพยากรณ์ข้อมูล X\_test ด้วยคำสั่ง predict() และแสดงผลความถูกต้องด้วยคำสั่ง accuracy\_score() และมีความถูกต้องที่ 0.97 หรือ 97% สามารถคำนวณค่า และแสดงตาราง Confusion Matrix ได้ดังต่อไปนี้

```
from sklearn.metrics import confusion_matrix
import seaborn as sns

mat = confusion_matrix(y_test, y_model)

plt.figure(figsize=(7,7))
plt.title("Confusion matrix")
sns.heatmap(mat, square=True, annot=True, cbar=False, fmt="d")
plt.xlabel('predicted value')
plt.ylabel('true value')
plt.show()
```



จากตัวอย่าง เส้นทางด้านคือผลลัพธ์ของโมเดล KNN ที่พยากรณ์ถูกต้อง และตัวเลขที่กระจายทั่ว Confusion Matrix คือตัวเลขที่พยากรณ์ผิดพลาด

สุดท้ายแล้วสามารถแสดงข้อมูลการพยากรณ์แบบ Visualization ได้ดังต่อไปนี้

```
import matplotlib.pyplot as plt

fig, axes = plt.subplots(10, 10, figsize=(8, 8),
                       subplot_kw={'xticks':[], 'yticks':[]},
                       gridspec_kw=dict(hspace=0.1, wspace=0.1))

for i, ax in enumerate(axes.flat):
    ax.imshow(X_test[i].reshape((28,28)), cmap='binary', \
              interpolation='nearest')
    ax.text(0.05, 0.05, str(int(y_model[i])), \
            transform=ax.transAxes, \
            color='blue' if(y_test[i] == y_model[i])\
            else 'red')

plt.show()
```

|   |   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|---|
| 5 | 2 | 9 | 9 | 1 | 8 | 6 | 6 | 7 | 3 |
| 0 | 0 | 1 | 4 | 0 | 7 | 8 | 0 | 3 | 0 |
| 4 | 3 | 1 | 5 | 6 | 3 | 7 | 9 | 7 | 2 |
| 8 | 7 | 1 | 0 | 8 | 2 | 9 | 3 | 1 | 7 |
| 3 | 6 | 4 | 8 | 9 | 7 | 3 | 6 | 6 | 5 |
| 1 | 1 | 3 | 8 | 5 | 1 | 1 | 3 | 7 | 9 |
| 2 | 7 | 4 | 5 | 2 | 4 | 2 | 1 | 1 | 9 |
| 1 | 3 | 3 | 3 | 8 | 2 | 2 | 8 | 4 | 9 |
| 6 | 4 | 7 | 3 | 7 | 6 | 0 | 0 | 2 | 3 |
| 3 | 6 | 6 | 7 | 2 | 3 | 1 | 9 | 3 | 8 |

จากตัวอย่าง ตัวเลขสีน้ำเงินคือผลลัพธ์จากการพยากรณ์ที่ถูกต้อง และตัวเลขสีแดงคือการพยากรณ์ผิดพลาด



## บทที่ 9

# การจัดหมวดหมู่ข้อมูลด้วย Naive Bayes (Naive Bayes Classification)

Naive Bayes Classification เป็นการจัดหมวดหมู่ข้อมูลแบบที่มีการเรียนการสอน (Supervised Learning) โดยใช้หลักความน่าจะเป็นเข้ามาช่วยคำนวณ

ตัวอย่างต่อไปนี้ใช้ไลบรารี่ Seaborn ในการเรียกใช้ข้อมูล Iris Dataset

```
import seaborn as sns
```

```
iris = sns.load_dataset('iris')
print("Type", type(iris))

iris.head()
```

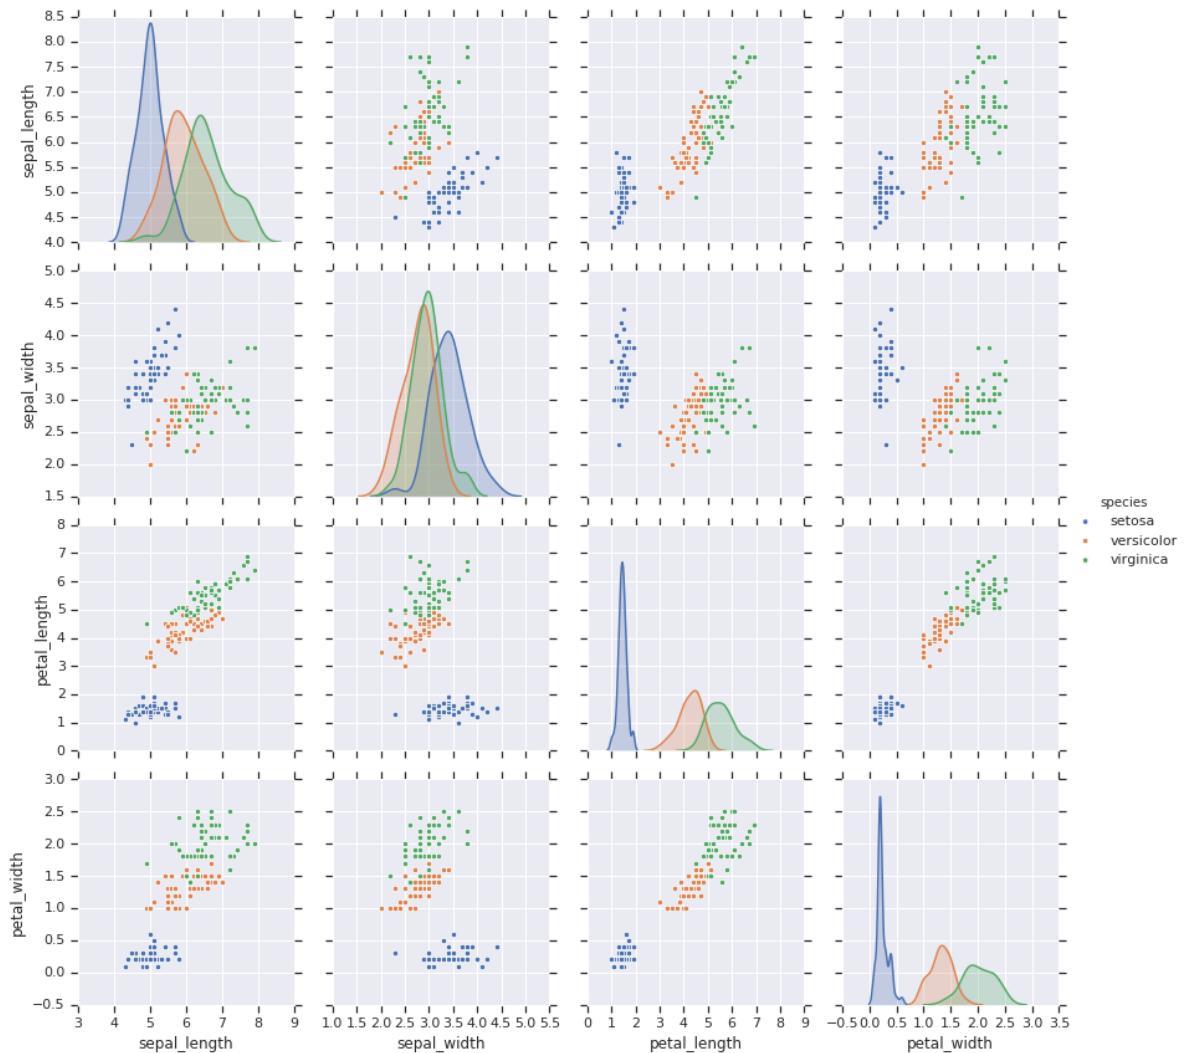
```
('Type', <class 'pandas.core.frame.DataFrame'>)
```

ข้อมูลที่โหลดมาจะจัดเก็บอยู่ในตัวแปร iris โดยที่ตัวแปร iris จะเก็บข้อมูลแบบ pandas DataFrame

|   | sepal_length | sepal_width | petal_length | petal_width | species |
|---|--------------|-------------|--------------|-------------|---------|
| 0 | 5.1          | 3.5         | 1.4          | 0.2         | setosa  |
| 1 | 4.9          | 3.0         | 1.4          | 0.2         | setosa  |
| 2 | 4.7          | 3.2         | 1.3          | 0.2         | setosa  |
| 3 | 4.6          | 3.1         | 1.5          | 0.2         | setosa  |
| 4 | 5.0          | 3.6         | 1.4          | 0.2         | setosa  |

สามารถใช้ไลบรารี Seaborn เพื่อ Visualization ข้อมูล Iris ได้ วิธีการผลิตทำได้ดังต่อไปนี้

```
import matplotlib.pyplot as plt  
sns.set()  
sns.pairplot(iris, hue='species', size=3)  
plt.show()
```



## การเตรียมข้อมูลเพื่อใช้ในการเรียนรู้

ชุดข้อมูล Iris มีจำนวน 150 instance และแบ่งออกเป็น 3 กลุ่ม ในตัวอย่างต่อไปนี้จะใช้คำสั่ง train\_test\_split เพื่อแบ่งข้อมูลออกเป็นชุด Train และ Test

```
from sklearn.cross_validation import train_test_split

Xtrain, Xtest, ytrain, ytest = train_test_split(X_iris, \
                                                y_iris, random_state=1)
```

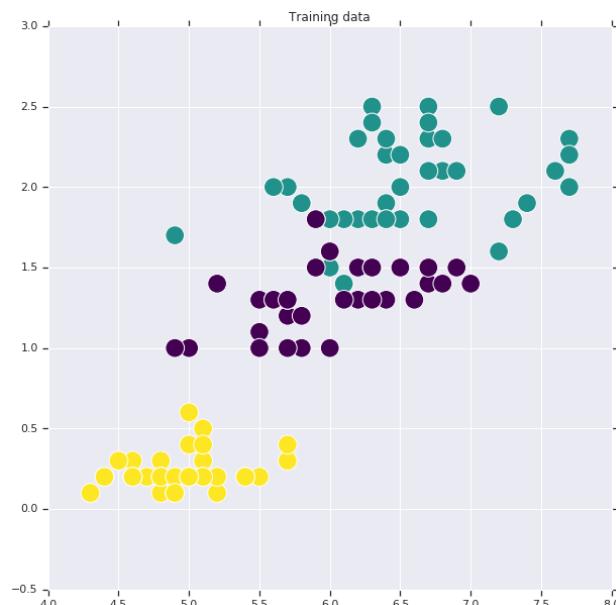
จากนั้นสามารถplot ข้อมูล iris เพื่อดูการกระจายของข้อมูล แต่ทั้งนี้จะต้องแปลง Label ที่อยู่ในรูปแบบของตัวอักษร ให้เป็นตัวเลขเลี้ยงก่อน

```
ytrain[ytrain.iloc[0:] == 'versicolor'] = 1
ytrain[ytrain.iloc[0:] == 'virginica'] = 2
ytrain[ytrain.iloc[0:] == 'setosa'] = 3
```

เมื่อแปลง Label ให้มีค่าเป็น 1,2 และ 3 จากนั้นจึงplot ข้อมูล iris โดยใช้คำสั่งต่อไปนี้

```
import matplotlib.pyplot as plt

plt.figure(figsize=(10,10))
plt.scatter(Xtrain.iloc[:,0:1], Xtrain.iloc[:,3:4], \
            c=ytrain[:], s=350, cmap='viridis')
plt.title('Training data')
plt.show()
```



## สร้างโมเดล Naive Bayes

สามารถใช้คำสั่ง GaussianNB() ชึ้นก็คือ Gaussian Naive Bayes ในการสร้างโมเดล และคำสั่ง fit() สำหรับเรียนรู้ข้อมูล

```
from sklearn.naive_bayes import GaussianNB  
  
model = GaussianNB()  
model.fit(Xtrain, ytrain)  
  
GaussianNB(priors=None)
```

## พยากรณ์ข้อมูลด้วยโมเดล Naive Bayes และแสดงประสิทธิภาพของโมเดล

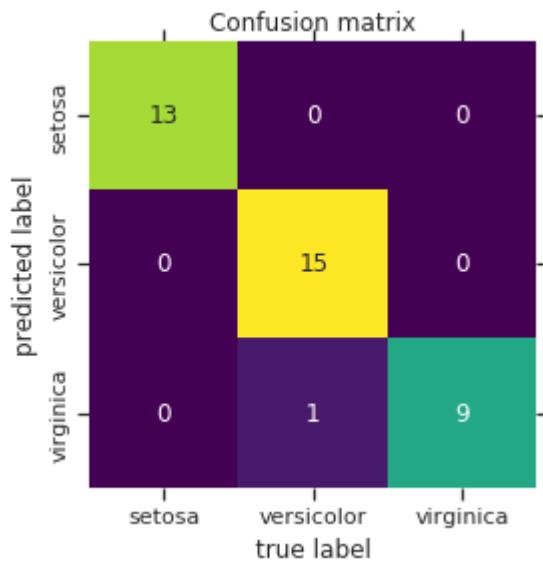
การพยากรณ์ทำได้โดยใช้คำสั่ง predict() และการแสดงผลความถูกต้องใช้คำสั่ง accuracy\_score() สุดท้ายแล้วใช้ Confusion Matrix เพื่อดูลักษณะการพยากรณ์ข้อมูล ดังตัวอย่างต่อไปนี้

```
from sklearn.metrics import accuracy_score  
  
y_model = model.predict(Xtest)  
accuracy_score(ytest, y_model)
```

0.9736842105263158

ผลลัพธ์ที่ได้จากการพยากรณ์คือ 97.37% จากนั้นใช้คำสั่งดังต่อไปนี้เพื่อแสดงค่า Confusion Matrix

```
from sklearn.metrics import confusion_matrix  
  
mat = confusion_matrix(ytest, y_model)  
sns.heatmap(mat.T, square=True, annot=True, fmt='d', \  
             cbar=False, cmap='viridis',  
             xticklabels=['setosa', 'versicolor', 'virginica'],\br/>             yticklabels=['setosa', 'versicolor', 'virginica'])\br/>  
plt.title('Confusion matrix')  
plt.xlabel('true label')  
plt.ylabel('predicted label');  
plt.show()
```



110 ความรู้พื้นฐานทางด้านการเรียนรู้เครื่องจักร และการวิเคราะห์ข้อมูลด้วยโปรแกรมภาษาไทย

# บทที่ 10

## การวิเคราะห์องค์ประกอบหลัก (Principal Component Analysis)

การวิเคราะห์องค์ประกอบหลัก (Principal Component Analysis: PCA) เป็นวิธีที่ใช้เพื่อวิเคราะห์ข้อมูลที่มีหลายตัวแปร (Variable) เพื่อหาความสัมพันธ์ของตัวแปรเหล่านั้น ทำให้เกิดการลดขนาดเมตริกซ์ (Matrix) ที่มีความซับซ้อนเล็กลงง่ายต่อการอธิบาย<sup>1</sup> นักวิจัยจึงใช้วิธี PCA เพื่อนำมาลดขนาดของคุณลักษณะพิเศษ (Feature) ให้มีเล็กลง<sup>2</sup> ทำให้ลดเวลาในการสร้างโมเดล

### การสร้างโมเดล PCA

ตัวอย่างต่อไปนี้ใช้ชุดข้อมูล Iris ในการทดสอบ ชิ่งชุดข้อมูล Iris มีทั้งสิ้น 4 attribute ชิ่ง โหลดข้อมูลโดยใช้ไลบรารี Seaborn

```
import seaborn as sns

iris = sns.load_dataset('iris')
X_iris = iris.drop('species', axis=1)
y_iris = iris['species']
```

ข้อมูล feature ทั้ง 4 column จะถูกจัดเก็บไว้ที่ตัวแปร X\_iris และข้อมูล Label จะถูกเก็บอยู่ที่ตัวแปร y\_iris

```
from sklearn.decomposition import PCA

model = PCA(n_components=2)
model.fit(X_iris)

PCA(copy=True, iterated_power='auto', n_components=2, random_state=None,
    svd_solver='auto', tol=0.0, whiten=False)
```

1 การวิเคราะห์ส่วนประกอบสำคัญ: <http://www.edu.tsu.ac.th/major/eva/files/journal/PRINCIPAL.pdf>

2 PCA: <https://www.gotoknow.org/posts/566063>

การสร้างโมเดลจะเรียกใช้คำสั่ง PCA() เพื่อกำหนดค่าพารามิเตอร์ และคำสั่ง fit() เพื่อเรียนรู้ลักษณะของข้อมูล โดยโมเดลจะถูกเก็บไว้ที่ตัวแปรชื่อ model

สามารถตรวจสอบจำนวนของ component ที่ได้จากการคำนวณด้วย PCA โดยใช้คำสั่งดังต่อไปนี้

```
print("check number of components", model.n_components_)

('check number of components', 2)
```

ขั้นตอนต่อไปคือเปลี่ยนรูปแบบของข้อมูล (Transform the data) ให้ตรงกับรูปแบบของ scikit-learn จากตัวอย่างใช้วิธีการดังต่อไปนี้

```
X_2D = model.transform(X_iris)
print("show first row of data", X_2D[0, :])

print model.transform(X_iris.iloc[0, :].
    as_matrix().reshape(1, -1))
```

จากนั้นทดสอบข้อมูล X\_2D โดยเลือกแถวที่ 0 มาแสดง ดังตัวอย่างต่อไปนี้

```
print("show first row of data", X_2D[0, :])
('show first row of data', array([-2.68412563,  0.31939725]))
```

ตัวอย่างต่อไปแสดงให้เห็นถึงการแปลงข้อมูล X\_iris เลพะແລວที่ 1 โดยใช้คำสั่ง transform()

```
print model.transform(X_iris.iloc[0, :].as_matrix().reshape(1, -1))

[[-2.68412563  0.31939725]]
```

## การเพิ่มข้อมูลจากตัวแปรเข้าไปเก็บเพิ่มใน DataFrame

จากตัวแปร iris ที่โหลดมาโดยใช้ไลบรารี seaborn สามารถเพิ่มข้อมูลเข้าไปใหม่ได้ ดังตัวอย่างต่อไปนี้

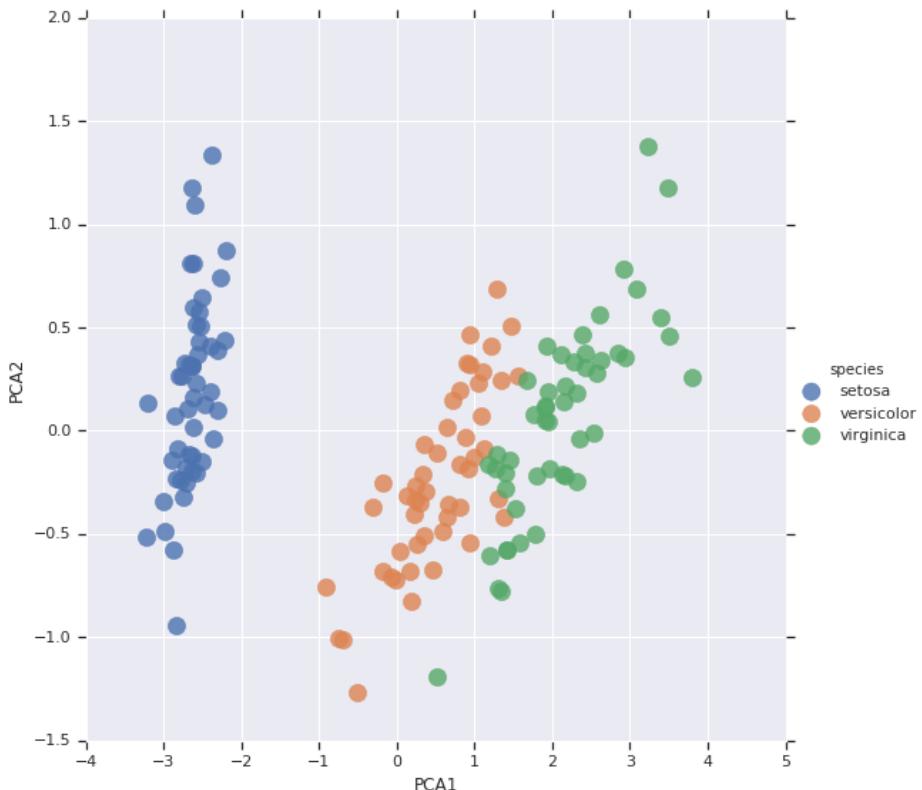
```
iris['PCA1'] = X_2D[:, 0]
iris['PCA2'] = X_2D[:, 1]
```

จากตัวอย่างข้างต้น ได้เพิ่มข้อมูล X\_2D เข้าไปในตัวแปร iris จำนวน 2 คอลัมน์ โดยกำหนดให้ชื่อของข้อมูลคือ PCA1 และ PCA2

การผลิตข้อมูลด้วยไลบรารี seaborn เพื่อดูลักษณะการกระจายของข้อมูลที่ได้จากการคำนวณด้วยวิธี PCA

```
import seaborn as sns

sns.lmplot("PCA1", "PCA2", hue='species', data=iris, \
fit_reg=False, size=8, scatter_kws={"s": 150})
```



## เปลี่ยนจำนวนของ Components

สามารถเปลี่ยนจำนวนของ Components ด้วยการกำหนดที่ตัวแปร n\_components ตั้งตัวอย่างต่อไปนี้

```
from sklearn.decomposition import PCA

model = PCA(n_components=5)
model.fit(X_iris)
X_2D = model.transform(X_iris)
```

---

```
-----  
ValueError                                Traceback (most recent call last)  
<ipython-input-58-acad37c053c8> in <module>()  
      2  
      3 model = PCA(n_components=5)      # 2. Instantiate the model with  
hyperparameters
```

```

----> 4 model.fit(X_iris)           # 3. Fit to data. Notice y is not
specified!
      5 X_2D = model.transform(X_iris) # 4. Transform the data to two
dimenstions

/usr/local/lib/python2.7/dist-packages/sklearn/decomposition/pca.pyc in
fit(self, X, y)
    305         Returns the instance itself.
    306     """
--> 307     self._fit(X)
    308     return self
    309

/usr/local/lib/python2.7/dist-packages/sklearn/decomposition/pca.pyc in
_fit(self, X)
    366         # Call different fits for either full or truncated SVD
    367         if svd_solver == 'full':
--> 368             return self._fit_full(X, n_components)
    369         elif svd_solver in ['arpack', 'randomized']:
    370             return self._fit_truncated(X, n_components, svd_solver)

/usr/local/lib/python2.7/dist-packages/sklearn/decomposition/pca.pyc in
_fit_full(self, X, n_components)
    381         raise ValueError("n_components=%r must be between 0 and "
    382                         "n_features=%r with svd_solver='full'" %
--> 383                         (n_components, n_features))
    384
    385     # Center data

ValueError: n_components=5 must be between 0 and n_features=4 with
svd_solver='full'

```

ในกรณีที่กำหนดให้ `n_components` มีค่าเท่ากับ 5 จะเกิด error ดังข้อความ error ข้างต้น ทั้งนี้เนื่องจากชุดข้อมูล Iris มีเพียง 4 attribute เท่านั้น ดังนั้น ในการคำนวณด้วยวิธี PCA จะต้องคำนึงถึงจำนวนของ attribute เป็นหลัก ซึ่งไม่สามารถกำหนดให้ `n_components` มีค่ามากกว่า จำนวนของ attribute

```

from sklearn.decomposition import PCA

model = PCA(n_components=3)
model.fit(X_iris)
X_2D = model.transform(X_iris)

iris['PCA1'] = X_2D[:,0]
iris['PCA2'] = X_2D[:,1]
iris['PCA3'] = X_2D[:,2]

iris.head()

```

|   | sepal_length | sepal_width | petal_length | petal_width | species | PCA1      | PCA2      | PCA3      |
|---|--------------|-------------|--------------|-------------|---------|-----------|-----------|-----------|
| 0 | 5.1          | 3.5         | 1.4          | 0.2         | setosa  | -2.684126 | 0.319397  | -0.027915 |
| 1 | 4.9          | 3.0         | 1.4          | 0.2         | setosa  | -2.714142 | -0.177001 | -0.210464 |
| 2 | 4.7          | 3.2         | 1.3          | 0.2         | setosa  | -2.888991 | -0.144949 | 0.017900  |
| 3 | 4.6          | 3.1         | 1.5          | 0.2         | setosa  | -2.745343 | -0.318299 | 0.031559  |
| 4 | 5.0          | 3.6         | 1.4          | 0.2         | setosa  | -2.728717 | 0.326755  | 0.090079  |

จากตัวอย่างข้างต้น ทดสอบด้วยการกำหนด n\_components ให้มีค่าเท่ากับ 3 และแสดงข้อมูลที่ได้จากการคำนวณด้วยวิธี PCA ซึ่งเก็บอยู่ในตัวแปร PCA1, PCA2 และ PCA3

## สร้างโมเดล Naive Bayes ด้วยคุณลักษณะพิเศษที่ได้จากการ PCA

เพื่อทดสอบประสิทธิภาพของอัลกอริธึม ในกรณีนี้ได้นำคุณลักษณะพิเศษที่ได้จากการคำนวณด้วยวิธี PCA มาใช้เพื่อสร้างโมเดลด้วยวิธี Naive Bayes

```
from sklearn.cross_validation import train_test_split

X_iris = iris.drop('species', axis=1)
y_iris = iris['species']

Xtrain, Xtest, ytrain, ytest = train_test_split(X_iris,\n                                                y_iris, random_state=1)
```

เริ่มต้นด้วยการแบ่งข้อมูลออกเป็นชุดเรียนรู้ และชุดทดสอบ ด้วยคำสั่ง train\_test\_split() จากนั้นใช้คำสั่ง Xtrain.head() เพื่อดูข้อมูลและลำดับของข้อมูลที่ผ่านการสลับจากคำสั่ง train\_test\_split()

```
X_train.head()
```

|     | sepal_length | sepal_width | petal_length | petal_width | PCA1      | PCA2      | PCA3      |
|-----|--------------|-------------|--------------|-------------|-----------|-----------|-----------|
| 54  | 6.5          | 2.8         | 4.6          | 1.5         | 1.088103  | 0.074591  | -0.307758 |
| 108 | 6.7          | 2.5         | 5.8          | 1.8         | 2.321229  | -0.243832 | -0.348304 |
| 112 | 6.8          | 3.0         | 5.5          | 2.1         | 2.165592  | 0.216276  | 0.033327  |
| 17  | 5.1          | 3.5         | 1.4          | 0.3         | -2.648297 | 0.311849  | 0.026668  |
| 119 | 6.0          | 2.2         | 5.0          | 1.5         | 1.300792  | -0.761150 | -0.344995 |

ขั้นตอนสุดท้าย เลือกข้อมูลในคอลัมน์ PCA1, PCA2, PCA3 เพื่อใช้สำหรับการเรียนรู้ และการทดสอบ

```
Xtrain = Xtrain.ix[:, ['PCA1', 'PCA2', 'PCA3']]
Xtrain.head()
```

|     | PCA1      | PCA2      | PCA3      |
|-----|-----------|-----------|-----------|
| 54  | 1.088103  | 0.074591  | -0.307758 |
| 108 | 2.321229  | -0.243832 | -0.348304 |
| 112 | 2.165592  | 0.216276  | 0.033327  |
| 17  | -2.648297 | 0.311849  | 0.026668  |
| 119 | 1.300792  | -0.761150 | -0.344995 |

```
Xtest = Xtest.ix[:, ['PCA1', 'PCA2', 'PCA3']]
Xtest.head()
```

|     | PCA1      | PCA2      | PCA3      |
|-----|-----------|-----------|-----------|
| 14  | -2.644750 | 1.178765  | -0.151628 |
| 98  | -0.906470 | -0.756093 | -0.012600 |
| 75  | 0.900174  | 0.328504  | -0.316209 |
| 16  | -2.623528 | 0.810680  | 0.138183  |
| 131 | 3.230674  | 1.374165  | -0.114548 |

จากนั้นนำข้อมูลจากตัวแปร Xtrain และ Xtest ข้างต้น มาสร้างโมเดลด้วยวิธี Naive Bayes ดังต่อไปนี้

```
from sklearn.naive_bayes import GaussianNB
model = GaussianNB()
model.fit(Xtrain, ytrain)
```

```
GaussianNB(priors=None)
```

## การพยากรณ์คุณลักษณะพิเศษที่ได้จาก PCA ด้วยอัลกอริธึม Naive Bayes และประสิทธิภาพจากการพยากรณ์

ทำการพยากรณ์ข้อมูลด้วยคำสั่งต่อไปนี้

```
y_model = model.predict(Xtest)
```

จากนั้นทำการคำนวณหาค่าความถูกต้อง ดังตัวอย่างต่อไปนี้

```
from sklearn.metrics import accuracy_score
accuracy_score(ytest, y_model)
```

0.9473684210526315

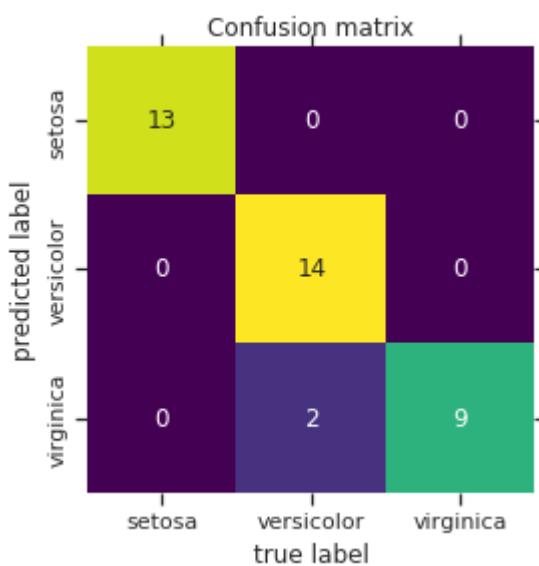
ความถูกต้องที่ได้จากการนำคุณลักษณะพิเศษของ PCA จำนวน 3 components ไปทำการสร้างโมเดล และทดสอบ ปรากฏว่ามีความถูกต้อง 94.74%

```
from sklearn.metrics import confusion_matrix
mat = confusion_matrix(ytest, y_model)

sns.heatmap(mat.T, square=True, annot=True, fmt='d',
            cbar=False, cmap='viridis',
            xticklabels=['setosa', 'versicolor', 'virginica'],
            yticklabels=['setosa', 'versicolor', 'virginica'])
```

สุดท้ายแสดงผลการคำนวณค่า Confusion matrix เพื่อถูกความลูกต้องของการพยากรณ์ข้อมูล

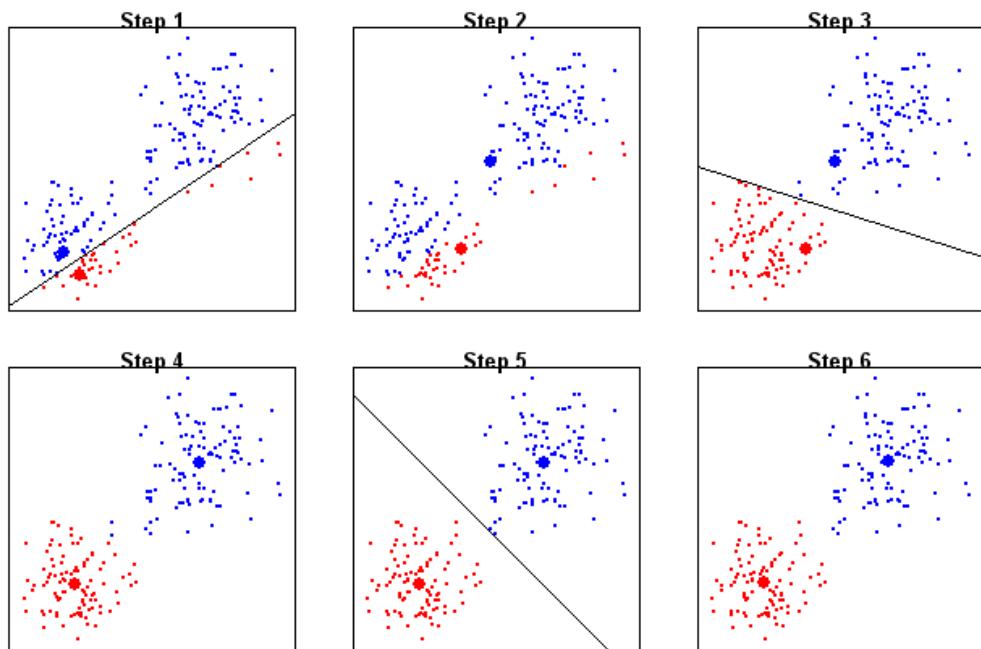
```
plt.title('Confusion matrix')
plt.xlabel('true label')
plt.ylabel('predicted label');
plt.show()
```



# บทที่ 11

## การจัดกลุ่มด้วยอัลกอริธึม K-Means (K-Means Clustering)

อัลกอริธึม K-Means เป็นวิธีที่ใช้สำหรับค้นหาจำนวนของคลัสเตอร์ (Cluster) จากชุดข้อมูลที่ไม่ประกอบด้วยคลาส (Class) หรือไม่มี Label ซึ่งจะเรียกว่า Unlabeled Data วิธีนี้จึงเป็นวิธี Unsupervised Learning หรือวิธี Clustering



ภาพประกอบที่ 16: ตัวอย่างการจัดกลุ่มด้วยวิธี K-Means โดยแสดงให้ดูทีละขั้นตอน

จากภาพประกอบที่ 16 หากดูด้วยตาเปล่าข้อมูลสามารถแบ่งออกเป็น 2 กลุ่ม โดยจำลองให้เป็นกลุ่มสีแดง และกลุ่มสีน้ำเงิน

**Step 1** ต้องสุ่มเลือกค่ากลาง (Centroid) เพื่อใช้เป็นตัวแทนของกลุ่มสีแดง และสีน้ำเงิน

เพื่อใช้สำหรับคำนวณหาค่าระยะห่าง (Distance Measurement) เพื่อเปรียบเทียบระหว่าง จุดข้อมูลและค่า Centroid ทั้ง 2 กลุ่ม (สีแดง และสีน้ำเงิน) หากจุดนั้นใกล้กลุ่มใดที่สุดจะถูกกำหนด (Assign) ให้อยู่ในกลุ่มนั้น เช่น หากใกล้กลุ่มสีแดง จุดนั้นก็จะถูกกำหนดให้เป็นสีแดง

**Step 2** เมื่อเปลี่ยนค่าให้กับทุกจุดข้อมูลเป็นที่เรียบร้อย จากนั้นให้คำนวณเพื่อหาค่า Centroid ใหม่ ในกรณีที่คำนวณหาค่า Centroid ของกลุ่มสีน้ำเงิน จะนำข้อมูลทุกจุดที่เป็น สีน้ำเงินมาคำนวณ เช่นเดียวกันกับสีแดง ดังนั้น จะได้จุด Centroid ใหม่ ที่ใช้เป็นตัวแทนของกลุ่ม ต่อไป

**Step 3** คำนวณหาค่า Distance ระหว่าง Centroid ทั้ง 2 กลุ่ม และจุดข้อมูลทุกจุด เพื่อจัด กลุ่มข้อมูลใหม่ ทำไปจนกระทั่งจุดแต่ละจุดไม่มีการเปลี่ยนแปลง หรือมีการเปลี่ยนแปลงน้อยที่สุด (Step 4-5) โปรแกรมจะหยุดการทำงาน

**Step 6** เมื่อไม่มีการเปลี่ยนแปลงกลุ่มของข้อมูล ให้คำนวณหา Centroid เพื่อใช้เป็นโมเดล สามารถนำไปทดสอบกับชุดข้อมูล Test set และหากได้ผลดี ก็สามารถนำไปใช้งานจริงได้

## จำลองข้อมูลเพื่อใช้ในอัลกอริธึม K-Means

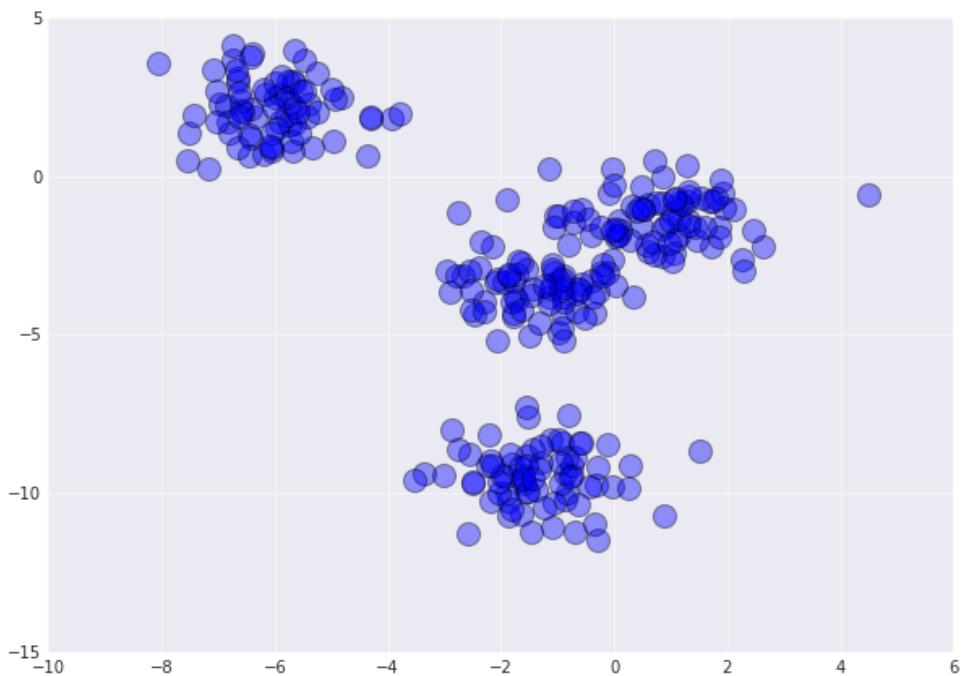
```
import matplotlib.pyplot as plt
import numpy as np
from sklearn.datasets.samples_generator import make_blobs

rng = np.random.RandomState(0)
colors = rng.rand(300)

X, y_true = make_blobs(n_samples=300, centers=4,
                       cluster_std=0.85, random_state=2)

plt.style.use('seaborn-darkgrid')
plt.figure(figsize=(10,7))
plt.scatter(X[:, 0], X[:, 1], s=200, alpha=0.4,
            cmap='viridis');
plt.show()
```

จากตัวอย่าง ทำการจำลองข้อมูลด้วยคำสั่ง make\_blobs() โดยกำหนดให้มีข้อมูลทั้งสิ้น 300 ชุดข้อมูล (n\_samples) และแบ่งข้อมูลออกเป็น 4 กลุ่ม (centers) จากนั้นทำการ Visualization เพื่อดูลักษณะการกระจายของข้อมูล ดังรูปภาพต่อไปนี้



## สร้างโมเดลของอัลกอริธึม K-Means

```
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=4)
kmeans.fit(X)

KMeans(algorithm='auto', copy_x=True, init='k-means++', max_iter=300,
       n_clusters=4, n_init=10, n_jobs=1, precompute_distances='auto',
       random_state=None, tol=0.0001, verbose=0)
```

## การพยากรณ์ด้วยอัลกอริธึม K-Means

สำหรับการพยากรณ์ด้วย K-Means ในโปรแกรม scikit-learn จะใช้ฟังก์ชัน predict() เช่นเดียวกับอัลกอริธึมอื่น ๆ

```
y_kmeans = kmeans.predict(X)
print("output", y_kmeans[0:20])
('output', array([0, 0, 1, 0, 3, 2, 0, 2, 1, 0, 3, 0, 0, 2, 2, 2, 3, 1, 2, 3, 0],
                 dtype=int32))
```

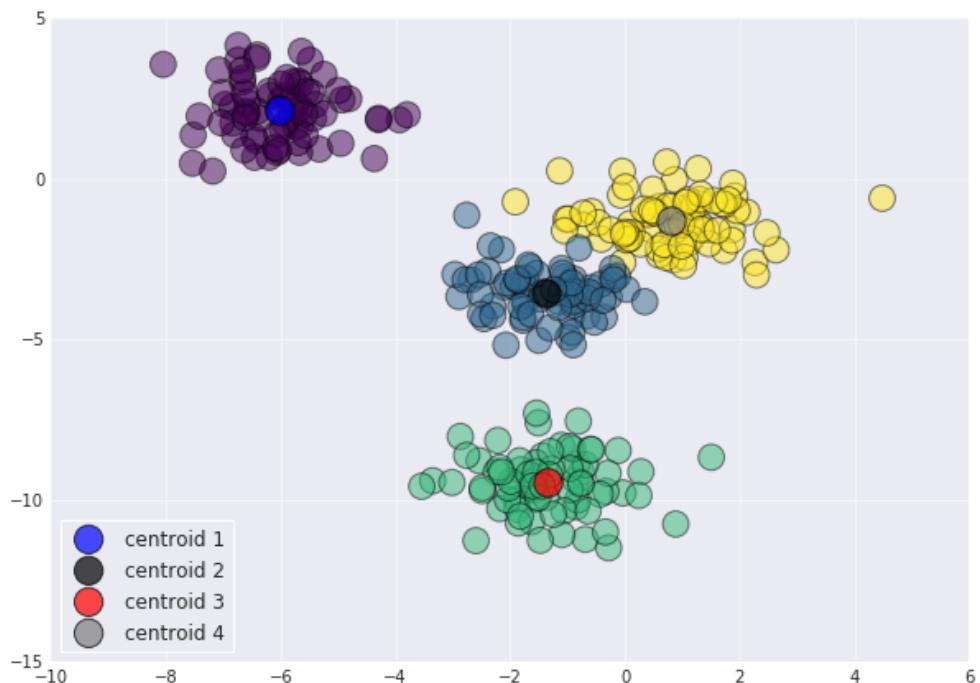
จากนี้จะแสดงผลการพยากรณ์จำนวน 20 ผลลัพธ์ เพื่อตรวจสอบค่าตอบ จากนี้ทำการผลลัพธ์เพื่อดูจุด Centroid และการแบ่งกลุ่มข้อมูล

```
plt.figure(figsize=(10,7))

# plot group of data
plt.scatter(X[:, 0], X[:, 1], c=y_kmeans, s=250, alpha=0.5,
            cmap='viridis')
centers = kmeans.cluster_centers_

# plot cluster/centroid
plt.scatter(centers[0, 0], centers[0, 1], c='blue', s=300, alpha=0.7,
            label='centroid 1')
plt.scatter(centers[1, 0], centers[1, 1], c='black', s=300, alpha=0.7,
            label='centroid 2')
plt.scatter(centers[2, 0], centers[2, 1], c='red', s=300, alpha=0.7,
            label='centroid 3')
plt.scatter(centers[3, 0], centers[3, 1], c='gray', s=300, alpha=0.7,
            label='centroid 4')

plt.legend(frameon=True, loc='lower left')
plt.show()
```



## สร้างข้อมูลใหม่เพื่อทดสอบการแบ่งกลุ่มด้วยอัลกอริธึม K-Means

ทำการสร้างข้อมูลจำนวน 10 ชุดเพื่อใช้สำหรับการทดสอบโมเดลของ K-Means ดังต่อไปนี้

```
X_test, y_test_true = make_blobs(n_samples=10, centers=4,
                                 cluster_std=0.85, random_state=2)
```

```
X_test.shape
```

```
(10, 2)
```

ขั้นตอนถัดไป ทำการผลิตข้อมูลที่สร้างขึ้นมาใหม่ เพื่อให้ทราบว่าข้อมูลที่สร้างขึ้นมาไปกระจายอยู่จุดใดของกราฟ สามารถทำได้ดังต่อไปนี้

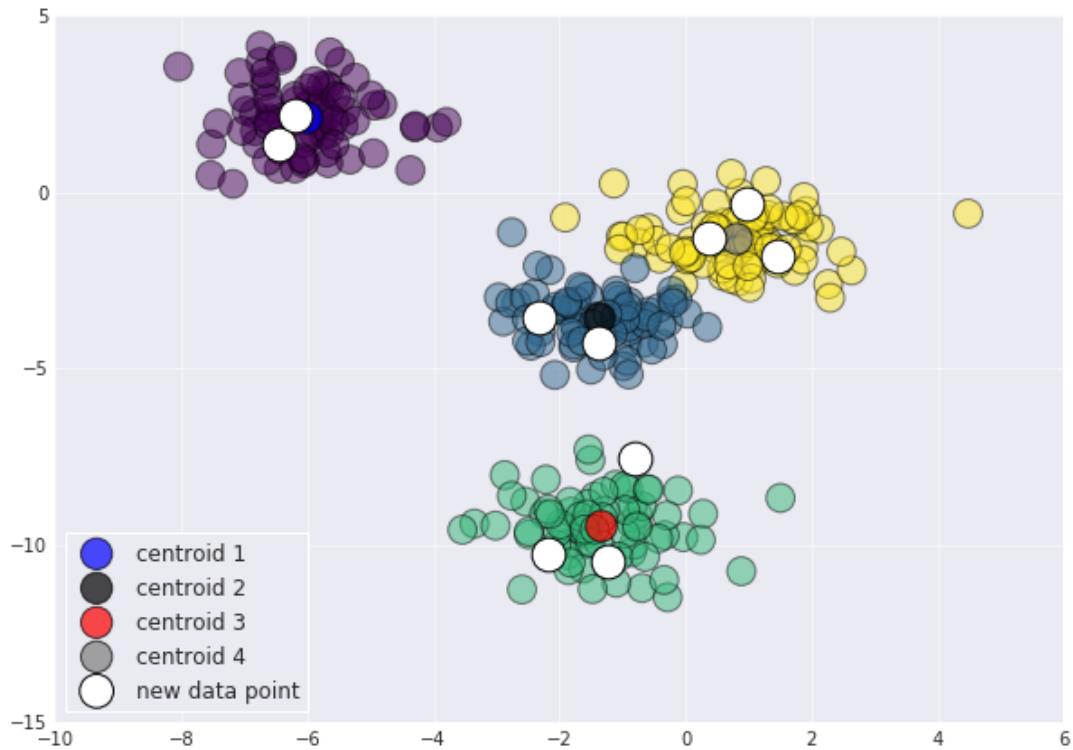
```
plt.figure(figsize=(10,7))

# plot group of data
plt.scatter(X[:, 0], X[:, 1], c=y_kmeans, s=250, alpha=0.5,
            cmap='viridis')
centers = kmeans.cluster_centers_

# plot cluster/centroid
plt.scatter(centers[0, 0], centers[0, 1], c='blue', s=300, alpha=0.7,
            label='centroid 1')
plt.scatter(centers[1, 0], centers[1, 1], c='black', s=300, alpha=0.7,
            label='centroid 2')
plt.scatter(centers[2, 0], centers[2, 1], c='red', s=300, alpha=0.7,
            label='centroid 3')
plt.scatter(centers[3, 0], centers[3, 1], c='gray', s=300, alpha=0.7,
            label='centroid 4')

# plot new data point
plt.scatter(X_test[:, 0], X_test[:, 1], c='white', s=350, alpha=1,
            label='new data point')
plt.legend(frameon=True, loc='lower left')

plt.show()
```



## พยากรณ์ข้อมูลที่สร้างขึ้นมาใหม่ด้วยอัลกอริธึม K-Means

ในขั้นตอนการพยากรณ์จะทำการพยากรณ์ข้อมูล  $X_{\text{test}}$  ที่มีจำนวนทั้งสิ้น 10 ชุดข้อมูล โดยผลลัพธ์ที่ได้จากการพยากรณ์จะเก็บไว้ที่ตัวแปร  $y_{\text{test\_kmeans}}$

```
y_test_kmeans = kmeans.predict(X_test)
y_test_kmeans
array([1, 3, 1, 3, 2, 2, 0, 3, 2, 0], dtype=int32)
```

จากนั้นplotกราฟเพื่อแสดงผลแบบ Visualization

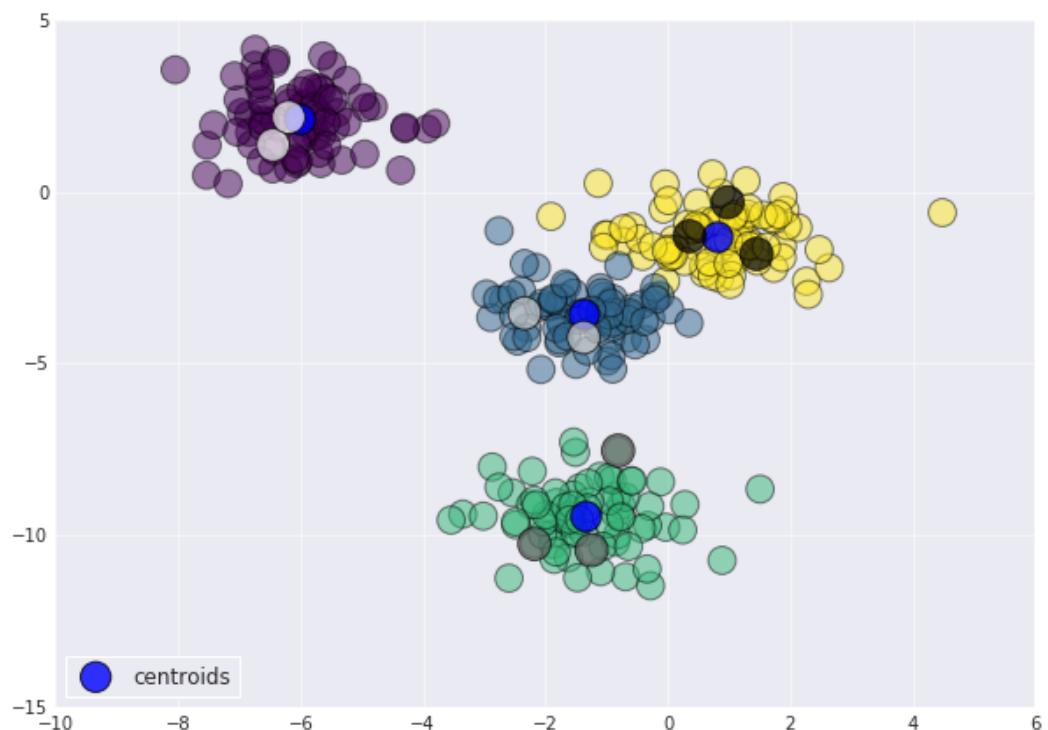
```
plt.figure(figsize=(10,7))

# plot group of data
plt.scatter(X[:, 0], X[:, 1], c=y_kmeans, s=250, alpha=0.5,
            cmap='viridis')
centers = kmeans.cluster_centers_

# plot cluster/centroid
plt.scatter(centers[:, 0], centers[:, 1], c='blue', s=300,
            alpha=0.8, label='centroids')
```

```
# plot new data point
plt.scatter(X_test[:, 0], X_test[:, 1], c=y_test_kmeans,
            s=350, alpha=0.7)
plt.legend(frameon=True, loc='lower left')

plt.show()
```





# บทที่ 12

## การรู้จำใบหน้า (Face Recognition)

สำหรับการรู้จำใบหน้า ในกรณีนี้ได้ทดสอบกับชุดข้อมูล lfw โดยใช้วิธี Principal Component Analysis (PCA) เพื่อลดขนาดของ Feature และส่งต่อไปยัง Support Vector Machine (SVM) เพื่อเรียนรู้และสร้างโมเดล การรู้จำใบหน้าสามารถทำได้ดังต่อไปนี้

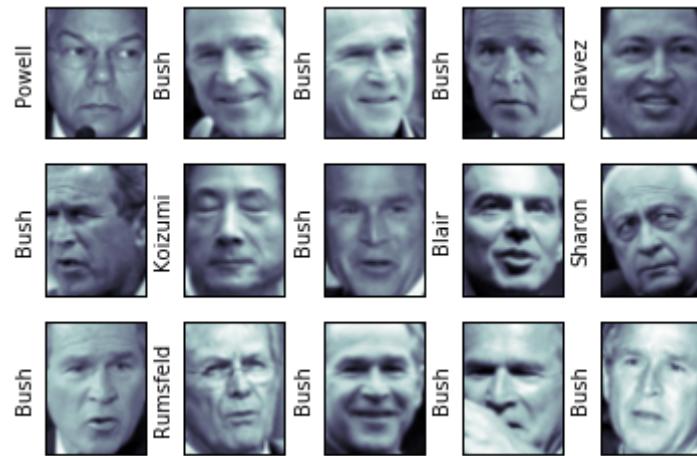
```
from sklearn.datasets import fetch_lfw_people
faces = fetch_lfw_people(min_faces_per_person=60)
print(faces.target_names)
print(faces.images.shape)

['Ariel Sharon' 'Colin Powell' 'Donald Rumsfeld' 'George W Bush'
 'Gerhard Schroeder' 'Hugo Chavez' 'Junichiro Koizumi' 'Tony Blair']
(1348, 62, 47)
```

ข้อมูลใบหน้าที่นำมาใช้ในการรู้จำ (Recognition) สามารถโหลดได้จาก scikit-learn โดยใช้คำสั่ง fetch\_lfw\_people จากนั้นทำการplotเพื่อดูรูปภาพบุคคล และรายชื่อของแต่ละบุคคล ที่นำมาใช้ในการรู้จำใบหน้า

```
import matplotlib.pyplot as plt

#plt.figure(figsize=(15,15))
fig, ax = plt.subplots(3, 5)
for i, axi in enumerate(ax.flat):
    axi.imshow(faces.images[i], cmap='bone')
    axi.set(xticks=[], yticks[])
    axi.set_ylabel(faces.target_names[faces.target[i]].split()
                  [-1], color='black')
plt.show()
```



ภาพประกอบที่ 17: ตัวอย่างใบหน้าจากชุดข้อมูล lfw ที่นำมาใช้ในการรู้จำใบหน้า

## สร้างโมเดลของอัลกอริธึม SVM

ในกรณีนี้ การสร้างโมเดลด้วย SVM จะใช้ข้อมูลที่ได้จากการคำนวณด้วย PCA โดยกำหนดให้ `n_components=150` ดังนั้น ข้อมูลทั้งหมด 150 component จึงเรียกว่าเป็นคุณลักษณะพิเศษ (Feature Extraction) ที่จะส่งต่อไปยัง SVM เพื่อเรียนรู้และสร้างอุปกรณ์เป็นโมเดล ดังตัวอย่างต่อไปนี้

```
from sklearn.svm import SVC
from sklearn.decomposition import RandomizedPCA
from sklearn.pipeline import make_pipeline

pca = RandomizedPCA(n_components=150, whiten=True,
                     random_state=42)
svc = SVC(kernel='rbf', class_weight='balanced')
model = make_pipeline(pca, svc)
```

จากนั้น แบ่งข้อมูลออกเป็น 2 ส่วน เพื่อใช้สำหรับการเรียนรู้ และทดสอบโดยใช้คำสั่ง `train_test_split()`

```
from sklearn.cross_validation import train_test_split
Xtrain, Xtest, ytrain, ytest = train_test_split(faces.data,
                                                faces.target, random_state=42)
```

จากตัวอย่างข้างต้น ในการสร้างโมเดลนี้ เป็นการใช้ค่าเบื้องต้นในการสร้างโมเดล ดังนั้น ประสิทธิภาพอาจไม่ดีมาก ดังนั้น ควรที่จะปรับเปลี่ยนพารามิเตอร์ (Tuning Parameter) เพื่อให้โมเดลที่สร้างนั้นมีประสิทธิภาพดีที่สุด สามารถทำได้โดยใช้คำสั่ง `GridSearchCV()`

```

from sklearn.grid_search import GridSearchCV

param_grid = {'svc__C': [1, 5, 10, 50],
              'svc__gamma': [0.0001, 0.0005, 0.001, 0.005]}
grid = GridSearchCV(model, param_grid)

%time grid.fit(Xtrain, ytrain)
print(grid.best_params_)

CPU times: user 1min 14s, sys: 1min, total: 2min 15s
Wall time: 33.8 s
{'svc__gamma': 0.001, 'svc__C': 5}

```

ค่าพารามิเตอร์ที่ใช้ในการปรับเปลี่ยนได้แก่ค่า **svc\_\_C** และ **svc\_\_gamma** ซึ่งเป็นค่าพารามิเตอร์ของ RBF Kernel โดยค่าที่ดีที่สุดในการทดสอบคือ **svc\_\_gamma = 0.001** และ **svc\_\_C = 5** จากนั้นนำค่าทั้ง 2 ค่าไปสร้างโมเดล ดังนี้

```
model = grid.best_estimator_
```

โมเดลที่สร้างด้วยตัวแปรที่ดีที่สุดจะถูกจัดเก็บไว้ที่ตัวแปรชื่อว่า **model** จากนั้นจึงสามารถนำไปเพื่อพยากรณ์ข้อมูลชุดทดสอบ ดังต่อไปนี้

```
yfit = model.predict(Xtest)
```

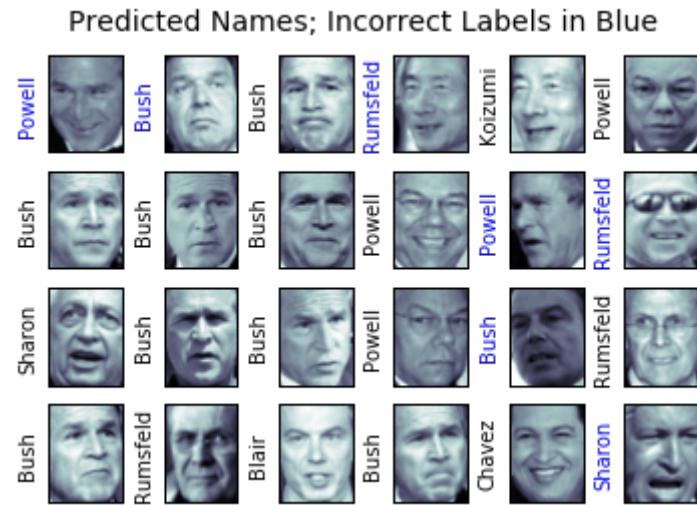
โดยผลลัพธ์ที่ได้จากการพยากรณ์จะถูกจัดเก็บไว้ที่ตัวแปร **yfit** จากนั้นสามารถ Visualization รูปภาพใบหน้า และแสดงคำตอบในการพยากรณ์ ดังต่อไปนี้

```

fig, ax = plt.subplots(4, 6)

for i, ax in enumerate(ax.flat):
    ax.imshow(Xtest[i].reshape(62, 47), cmap='bone')
    ax.set(xticks=[], yticks[])
    ax.set_ylabel(faces.target_names[yfit[i]].split()[-1],
                 color='black' if yfit[i] == ytest[i]
                 else 'blue')
fig.suptitle('Predicted Names; Incorrect Labels in Blue',
size=14);

```



**ภาพประกอบที่ 18:** ผลลัพธ์ที่ได้จากการพยากรณ์ใบหน้าด้วยวิธี PCA และ SVM

จากภาพประกอบที่ 18 รายชื่อสีฟ้าเงิน คือการพยากรณ์ที่ผิดพลาด และรายชื่อสีดำคือการพยากรณ์ที่ถูกต้อง

## การวัดประสิทธิภาพของการรู้จำใบหน้า (Classification Report)

การวัดประสิทธิภาพของการรู้จำใบหน้า ในกรณีนี้ใช้คำสั่ง `classification_report()` เพื่อที่จะตรวจสอบค่า `precision`, `recall` และ `f1-score`

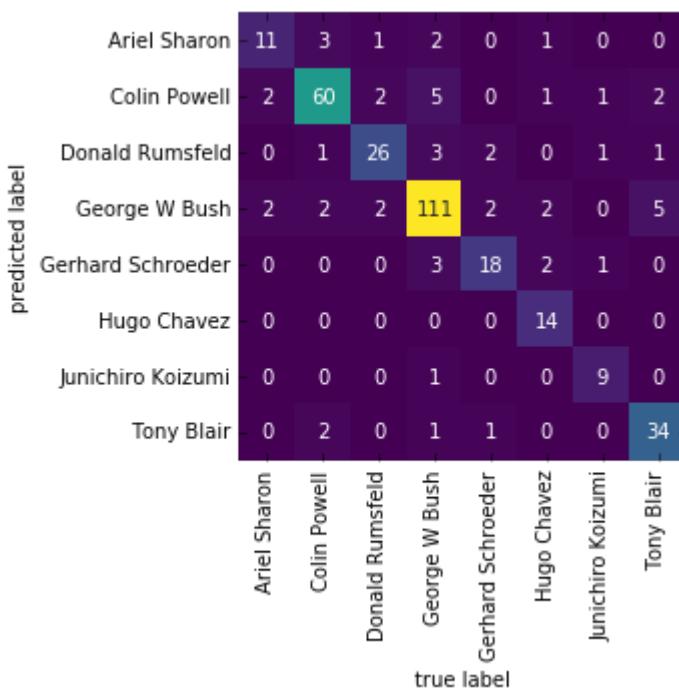
```
from sklearn.metrics import classification_report
print(classification_report(ytest, yfit,
                            target_names=faces.target_names))
```

|                   | precision | recall | f1-score | support |
|-------------------|-----------|--------|----------|---------|
| Ariel Sharon      | 0.61      | 0.73   | 0.67     | 15      |
| Colin Powell      | 0.82      | 0.88   | 0.85     | 68      |
| Donald Rumsfeld   | 0.76      | 0.84   | 0.80     | 31      |
| George W Bush     | 0.88      | 0.88   | 0.88     | 126     |
| Gerhard Schroeder | 0.75      | 0.78   | 0.77     | 23      |
| Hugo Chavez       | 1.00      | 0.70   | 0.82     | 20      |
| Junichiro Koizumi | 0.90      | 0.75   | 0.82     | 12      |
| Tony Blair        | 0.89      | 0.81   | 0.85     | 42      |
| avg / total       | 0.85      | 0.84   | 0.84     | 337     |

## การแสดงความถูกต้องของการพยากรณ์ด้วย Confusion Matrix

```
from sklearn.metrics import confusion_matrix
import seaborn as sns

mat = confusion_matrix(ytest, yfit)
sns.heatmap(mat.T, square=True, annot=True, fmt='d', cbar=False,
            cmap='viridis',
            xticklabels=faces.target_names,
            yticklabels=faces.target_names)
plt.xlabel('true label')
plt.ylabel('predicted label');
```



## อัตราความถูกต้อง (Accuracy Result) ของการพยากรณ์รูปภาพใบหน้า

การคำนวณความถูกต้อง (Accuracy Result) ของอัลกอริธึม SVM สามารถใช้คำสั่ง `accuracy_score()` โดยผลลัพธ์ที่ได้จากการพยากรณ์คือ 83.97%

```
from sklearn.metrics import accuracy_score

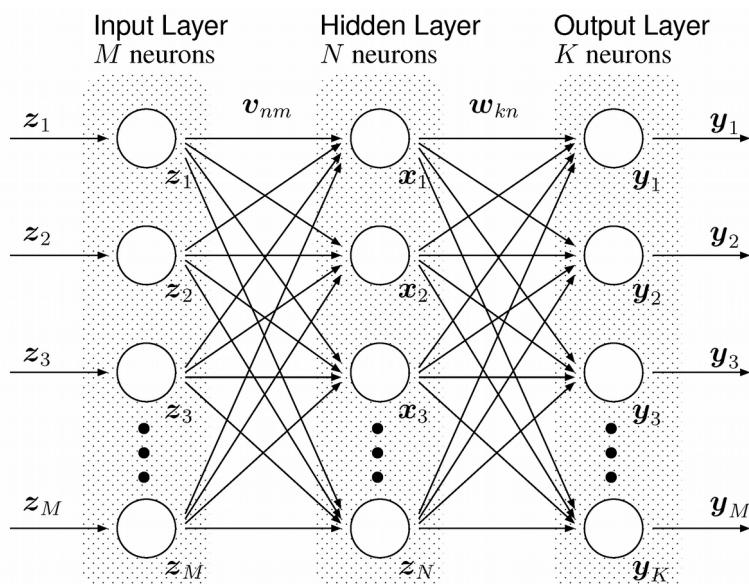
print("Accuracy", accuracy_score(ytest, yfit)*100)
('Accuracy', 83.97626112759644)
```



# บทที่ 13

## การรู้จำตัวอักษร (Character Recognition)

การรู้จำตัวอักษร (Character Recognition) ด้วยนิวรอลเน็ตเวิร์ก แบบ Multi-Layer Perceptron (MLP) ในกรณีนี้ทดสอบกับชุดข้อมูล MNIST โดยคุณลักษณะพิเศษ (Feature Extraction) ที่นำมาใช้คือค่าสีเทาของแต่ละพิกเซล ดังนั้น รูปภาพขนาด  $28 \times 28$  พิกเซลจะมีคุณลักษณะพิเศษจำนวน 784 attribute ที่จะนำไปเรียนรู้



ภาพประกอบที่ 19: ตัวอย่างโครงสร้างของ Multi-Layer Perceptron (MLP)

จากภาพประกอบที่ 19 โครงสร้างของนิวรอลเน็ตเวิร์กแบบ MLP ประกอบด้วย 3 ชั้น (Layer) คือ Input Layer, Hidden Layer และ Output Layer โดยทั้ง 3 ชั้นจะมีการเชื่อมต่อกันของ minden อย่างสมบูรณ์ (Fully-Connected)

เมื่อนำมาปรับใช้กับชุดข้อมูลรูปภาพตัวอักษรที่มีขนาด  $28 \times 28$  พิกเซล ดังนั้น ในชั้น Input Layer จึงกำหนดให้มีจำนวน 784 โหนด และในชั้น Output Layer ถูกกำหนดให้เป็น 10 โหนด

ตามจำนวนของตัวเลข 0-9 ส่วนในชั้น Hidden Layer นั้น จะต้องทำการคำนวณเพื่อหาจำนวน โภนดที่เหมาะสมที่สุดกับชุดข้อมูล

ในการนี้ใช้ชุดข้อมูล MNIST ที่มีจำนวน 70,000 ตัวเลข โดยใช้โปรแกรม scipy ในการโหลด

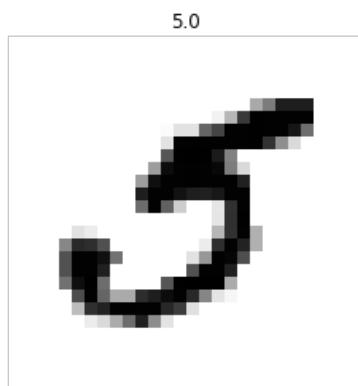
```
from scipy.io import loadmat
mnist_raw = loadmat("mldata/mnist-original.mat")
mnist = {
    "data": mnist_raw["data"].T,
    "target": mnist_raw["label"][0],
    "COL_NAMES": ["label", "data"],
    "DESCR": "mldata.org dataset: mnist-original",
}
X, y = mnist['data'], mnist['target']
X.shape, y.shape
((70000, 784), (70000,))
```

จากนี้ใช้คำสั่งดังต่อไปนี้เพื่อ Visualization รูปภาพตัวเลข

```
import matplotlib.pyplot as plt
some_digit = X[36000]
some_digit_image = some_digit.reshape(28, 28)

plt.imshow(
    some_digit_image,
    cmap = plt.cm.binary,
    interpolation="nearest")

plt.title(y[36000])
plt.axis("off")
plt.show()
```



เนื่องจากในชุดข้อมูลดังกล่าว ตั้งแต่ชุดข้อมูลที่ 1-60,000 และชุดข้อมูลที่ 60,001-70,000 ข้อมูลได้ถูกจัดเรียงตามตัวเลข 0-9 ดังนั้น หากต้องการข้อมูลบางส่วนมาเพื่อทดสอบ จึงควรที่จะสับ (Shuffle) ข้อมูลเสียก่อน การสับข้อมูลสามารถทำได้ดังต่อไปนี้

```
import numpy as np

shuffle_index = np.random.permutation(70000)
X, y = X[shuffle_index], y[shuffle_index]

X_train, X_test, y_train, y_test = X[:60000], X[60000:],
y[:60000], y[60000:]
print(X_train.shape, X_test.shape, y_train.shape,\n
      y_test.shape)

((60000, 784), (10000, 784), (60000,), (10000,))
```

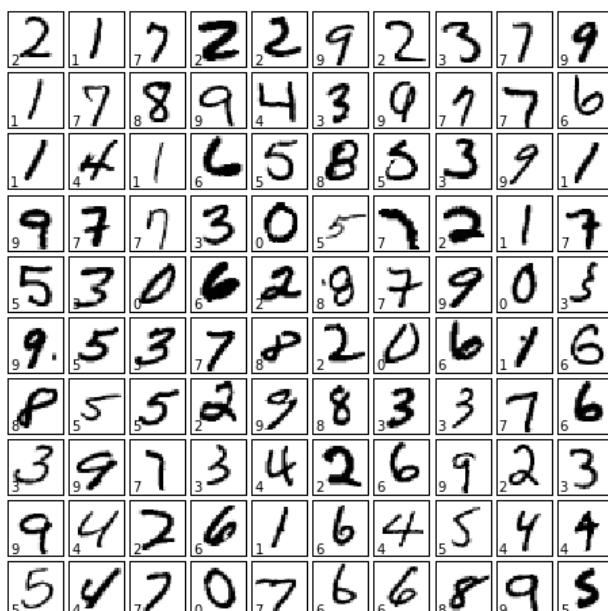
จากนั้นสามารถแสดงข้อมูล โดยแสดงแบบ Visualization และแสดง Label ประกอบ ดังนี้

```
import matplotlib.pyplot as plt

fig, axes = plt.subplots(10, 10, figsize=(8, 8),
                       subplot_kw={'xticks':[], 'yticks':[]},
                       gridspec_kw=dict(hspace=0.1, wspace=0.1))

for i, ax in enumerate(axes.flat):
    ax.imshow(X_train[i].reshape((28,28)), cmap='binary',
              interpolation='nearest')
    ax.text(0.05, 0.05, str(int(y_train[i])),
            transform=ax.transAxes, color='black')

plt.show()
```



## สร้างโมเดลของอัลกอริธึม MLP

การใช้งาน MLP ให้ scikit-learn จะต้องใช้โมดูล MLPClassifier โดยในตัวอย่างได้กำหนดให้ Hidden Layer มีขนาด 100 โหนด (hidden\_layer\_sizes) และทำการทดสอบจำนวน 10 รอบ (max\_iter) และกำหนดอัตราการเรียนรู้ที่ 0.001 (learning\_rate\_init) จากนั้นใช้คำสั่ง fit() เพื่อสร้างโมเดล และเก็บโมเดลไว้ที่ตัวแปร mlp

```
from sklearn.neural_network import MLPClassifier

mlp = MLPClassifier(hidden_layer_sizes=(100,), max_iter=10,
                     alpha=1e-4,
                     solver='sgd', verbose=10, tol=1e-5,
                     random_state=1,
                     learning_rate_init=0.001)

mlp.fit(X_train, y_train)

Iteration 1, loss = 1.81871326
Iteration 2, loss = 1.05944149
Iteration 3, loss = 0.69554161
Iteration 4, loss = 0.50766222
Iteration 5, loss = 0.38525626
Iteration 6, loss = 0.33714014
Iteration 7, loss = 0.30388212
Iteration 8, loss = 0.28367218
Iteration 9, loss = 0.26573927
Iteration 10, loss = 0.25603315

MLPClassifier(activation='relu', alpha=0.0001, batch_size='auto', beta_1=0.9,
               beta_2=0.999, early_stopping=False, epsilon=1e-08,
               hidden_layer_sizes=(100,), learning_rate='constant',
               learning_rate_init=0.001, max_iter=10, momentum=0.9,
               nesterovs_momentum=True, power_t=0.5, random_state=1, shuffle=True,
               solver='sgd', tol=1e-05, validation_fraction=0.1, verbose=10,
               warm_start=False)
```

## การวัดประสิทธิภาพของการเรียนรู้

ในการนี้ ใช้คำสั่ง score() เพื่อดูผลการทดสอบกับข้อมูลชุดเรียนรู้ และข้อมูลชุดทดสอบ โดยใช้คำสั่งดังต่อไปนี้

```
print("Training set score: %f" % mlp.score(X_train, y_train))
print("Test set score: %f" % mlp.score(X_test, y_test))
```

## การพยากรณ์และวัดประสิทธิภาพของการรู้จำ

ในการพยากรณ์ให้ใช้คำสั่ง predict() เพื่อพยากรณ์ข้อมูล X\_test ดังตัวอย่างต่อไปนี้

```
yfit = mlp.predict(X_test)

from sklearn.metrics import classification_report

tn = ['0','1','2','3','4','5','6','7','8','9']
print(classification_report(y_test, yfit,
                            target_names=tn))
```

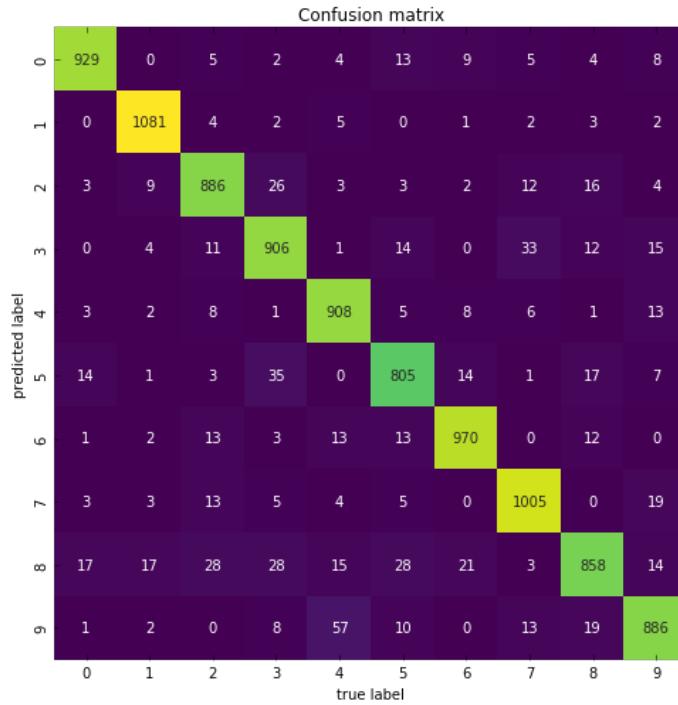
|             | precision | recall | f1-score | support |
|-------------|-----------|--------|----------|---------|
| 0           | 0.95      | 0.96   | 0.95     | 971     |
| 1           | 0.98      | 0.96   | 0.97     | 1121    |
| 2           | 0.92      | 0.91   | 0.92     | 971     |
| 3           | 0.91      | 0.89   | 0.90     | 1016    |
| 4           | 0.95      | 0.90   | 0.92     | 1010    |
| 5           | 0.90      | 0.90   | 0.90     | 896     |
| 6           | 0.94      | 0.95   | 0.95     | 1025    |
| 7           | 0.95      | 0.93   | 0.94     | 1080    |
| 8           | 0.83      | 0.91   | 0.87     | 942     |
| 9           | 0.89      | 0.92   | 0.90     | 968     |
| avg / total | 0.92      | 0.92   | 0.92     | 10000   |

## แสดงผลลัพธ์จากการพยากรณ์ด้วย Confusion Matrix

```
from sklearn.metrics import confusion_matrix
import seaborn as sns

mat = confusion_matrix(y_test, yfit)

fig, ax = plt.subplots(figsize=(8,8))
sns.heatmap(mat.T, square=True, annot=True, fmt='d', cbar=False, cmap='viridis',
            xticklabels=tn,
            yticklabels=tn,
            ax=ax)
plt.title('Confusion matrix')
plt.xlabel('true label')
plt.ylabel('predicted label');
```



แสดงอัตราความถูกต้องจากการพยากรณ์ โดยผลลัพธ์ที่ได้จากการพยากรณ์คือ 92.34%

```
from sklearn.metrics import accuracy_score
print("Accuracy", accuracy_score(y_test, yfit)*100)
('Accuracy', 92.34)
```

## การ Visualization รูปภาพตัวเลข และแสดงผลการพยากรณ์

เพื่อให้สะดวกต่อการเปรียบเทียบระหว่างค่าที่แท้จริง และค่าที่พยากรณ์ สามารถ Visualization ข้อมูลได้ดังต่อไปนี้

```
import matplotlib.pyplot as plt
fig, axes = plt.subplots(10, 10, figsize=(8, 8),
                       subplot_kw={'xticks':[], 'yticks':[]},
                       gridspec_kw=dict(hspace=0.1, wspace=0.1))

for i, ax in enumerate(axes.flat):
    ax.imshow(X_test[i].reshape((28,28)), cmap='binary',
              interpolation='nearest')
```

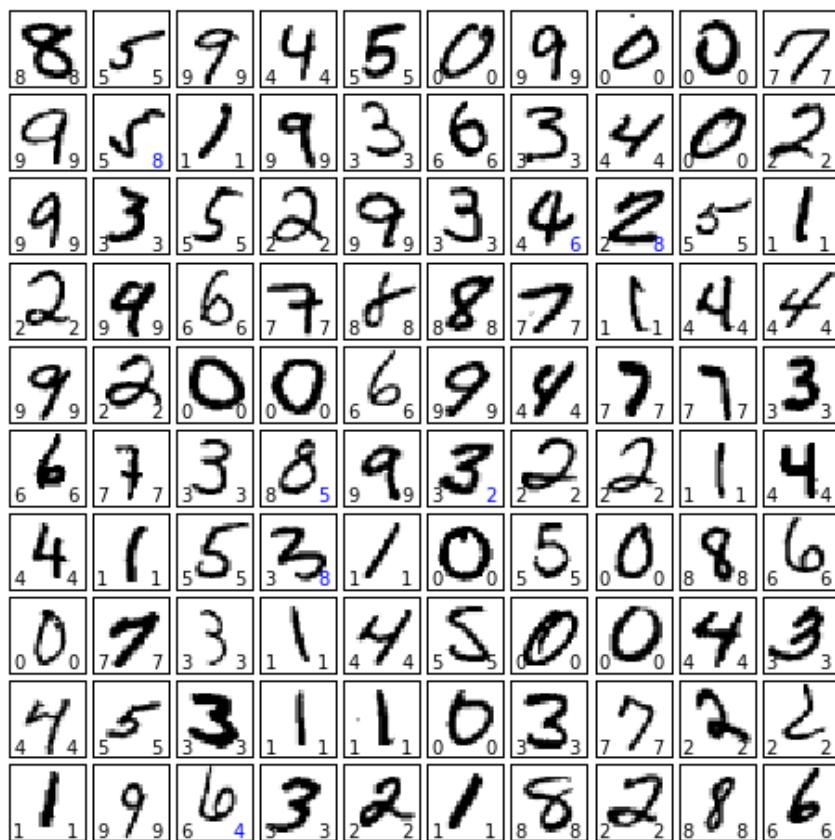
```

# actual class
ax.text(0.05, 0.05, str(int(y_test[i])),
        transform=ax.transAxes,
        color='black')

# predict class
ax.text(0.75, 0.05, str(int(yfit[i])),
        transform=ax.transAxes,
        color='black' if yfit[i] == y_test[i] else 'blue')

plt.show()

```



ภาพประกอบที่ 20: เปรียบเทียบระหว่างค่าที่แท้จริง และค่าที่ได้จากการพยากรณ์

จากภาพประกอบที่ 20 ในแต่ละรูปจะมีตัวเลขกำกับ 2 ตัวเลข โดยตัวเลขทางด้านซ้ายมือคือ Label ของตัวเลขนั้น ๆ ส่วนตัวเลขทางด้านขวาคือผลลัพธ์ที่ได้จากการพยากรณ์ ดังนั้น หากเป็นการพยากรณ์ที่ผิดพลาดจะแสดงเป็นสีน้ำเงิน แต่หากพยากรณ์ถูกต้องก็จะแสดงเป็นสีดำ





